

大模型调研报告

陈天乐 无 25
ctl22@mails.tsinghua.edu.cn

2025 年 4 月 9 日

目录

1	调研背景	2
2	模型选取	2
2.1	文心一言	2
2.1.1	模型背景	2
2.1.2	模型架构	2
2.1.3	核心技术	2
2.2	豆包	3
2.2.1	模型背景	3
2.2.2	模型架构	3
2.2.3	核心技术	3
3	实验测试与分析	3
3.1	任务 1: 图像增强 (低照度增强、对比度增强、去噪)	3
3.1.1	文心一言	4
3.2	任务 2: 物体检测	5
3.2.1	文心一言	5
3.2.2	豆包	6
3.3	任务 3: 人脸识别	6
3.3.1	文心一言	6
3.3.2	豆包	7
4	模型评估与改进建议	8
4.1	文心一言	8
4.2	豆包	9

1 调研背景

随着人工智能的迅速发展，大模型不仅在自然语言处理领域取得了突破性进展，还在计算机视觉等多模态任务中展现出强大的潜力。近年来，大模型与图像处理技术的融合成为研究热点，为图像增强、目标检测和人脸识别等任务提供了新的解决方案。本次作业旨在探索大模型在图像处理任务中的适用性，分析其在不同任务下的性能表现，培养对跨模态 AI 技术的理解与批判性思维能力。

2 模型选取

2.1 文心一言

2.1.1 模型背景

文心一言（英文名：ERNIE Bot）是百度全新一代知识增强大语言模型，文心大模型家族的新成员，能够与人对话互动、回答问题、协助创作，高效便捷地帮助人们获取信息、知识和灵感。

2.1.2 模型架构

Transformer 模型

文心一言的核心架构采用了 Transformer 模型，该模型是一种基于自注意力机制的神经网络结构。它能够处理变长序列，并通过自注意力机制捕捉输入序列中单词之间的依赖关系。Transformer 模型是文心一言的基础，它由编码器（Encoder）和解码器（Decoder）两部分组成。编码器负责处理输入文本，将其转化为一系列的向量表示（称为“嵌入”或“嵌入向量”）。这些向量不仅包含了文本中单词的信息，还融入了上下文语境的信息。解码器则根据这些向量表示生成输出文本。

在 Transformer 模型中，自注意力机制（Self-Attention Mechanism）是关键。它允许模型在处理文本时，同时关注文本中的每个单词，并计算它们之间的相关性。这使得模型能够捕捉文本中的长距离依赖关系，从而更准确地理解文本的含义。

2.1.3 核心技术

1. 知识增强

文心一言融合了知识图谱和百科知识等先验知识，将这些知识引入模型训练中。通过知识增强，模型能够更准确地理解文本中的实体、概念及其关系，提高生成文本的准确性和丰富性。

2. 上下文感知

模型能够充分考虑文本的上下文信息，理解文本中的语义和语境。在处理文本时，模型会关注文本中的每个单词，并计算它们之间的相关性。这使得模型能够捕捉文本中的长距离依赖关系，并理解文本中的语义和语境。因此，模型能够生成连贯、流畅的文本，避免语义上的矛盾和冲突。

3. 监督精调

在预训练的基础上，文心一言会针对特定的任务进行微调。微调是通过在标注数据上训练模型来完成的，目的是让模型更好地适应特定任务的需求。微调过程可以进一步优化模型的性能。

4. 人类反馈的强化学习 (RLHF)

RLHF 的核心思想是将人类反馈作为奖励信号，指导模型在环境中采取合适的动作。通过不断的试错和反馈，模型可以优化其行为策略，以实现特定目标或任务。

2.2 豆包

2.2.1 模型背景

豆包是字节跳动公司基于云雀模型开发的 AI 工具，提供多种功能，旨在帮助用户获取信息并提高工作效率。

2.2.2 模型架构

混合专家 (MoE) 架构

豆包的核心架构采用了 MoE 架构，并且基于字节跳动团队提出的 UltraMem 稀疏模型架构，豆包对传统 MoE 进行了创新优化。MoE 通过稀疏激活专家 (Expert) 将计算与参数解耦，训练阶段可降低计算量。但在推理时，由于模型需逐 token 生成 (batch size 小)，少量 token 即可激活所有专家，导致访存压力剧增，推理速度变慢且成本高昂。而 UltraMem 架构将单一 Memory Layer 拆分为多层，均匀分布在 Transformer 中，并引入 skip-layer 机制，使访存与计算并行，减少延迟。并且采用 Tucker 分解查询 - 键检索 (TDQKR)，提升 value 检索的准确性和复杂度，确保稀疏参数高效利用。同时通过虚拟内存扩展 (IVE)，在不增加物理显存的前提下，隐式扩展稀疏参数规模 (如 4 倍扩展)，提升模型容量。

2.2.3 核心技术

1. UltraMem 混合专家模型

基于字节跳动自研的 UltraMem 稀疏模型架构，通过分层 Memory Layer 设计、TDQKR 检索增强和 IVE 虚拟内存扩展，解决传统 MoE 推理效率瓶颈。

2. 纯视觉动态建模

业内首个无需语言依赖的视频生成模型，采用 潜在动态模型 (LDM) 压缩帧间冗余，结合自回归 Transformer 与 VQ-VAE，实现复杂任务推理 (如围棋 5 段水平)。

3. STRING 算法与 300 万窗口

通过 STRING 上下文关联算法和稀疏化分布式方案，实现百万 tokens 处理延迟仅 15 秒，支持海量文献分析等场景。

4. 多模态生成

语言、视觉、语音、视频、音乐五大模态协同，支持复杂场景 (如自动驾驶、智能座舱)。

3 实验测试与分析

3.1 任务 1：图像增强 (低照度增强、对比度增强、去噪)

选取了三张照片，分别让文心一言和豆包模型对其进行图像增强，由于测试发现豆包模型无法在原图的基础上进行图像增强，因此只给出了文心一言的结果。

3.1.1 文心一言

首先让文心一言对一张模糊照片进行去噪操作，结果如下：




图 2: 模糊照片原图



图 3: 文心一言生成结果

从照片质量来看，去噪效果还是非常不错的，生成图片比原图片清晰很多。但是模型给出的图片并不和原图一模一样，而是基于原图生成了一个类似的清晰图片。

将一张雾霾天气的城市图片输入给文心一言，令其增强对比度，得到的结果如下：



图 4: 雾霾照片原图



图 5: 文心一言生成结果

这个任务中，文心一言生成出的照片和原有图片相去甚远，虽然是完成了增强对比度的任务，但是这并不是我们希望得到的。

最后，将一张低照度的照片输入给文心一言，令其进行图像增强，得到的结果如下：




图 6: 低照度照片原图



图 7: 文心一言生成结果

同样，从照片质量看，文心一言生成的图片在尽量和原图相近下也提高了照片的质量，增强低照度，但是仍然不是在原图的基础上做的图像增强。

3.2 任务 2：物体检测

在这个任务中，分别将一张包含多个水果的图片输入给文心一言和豆包，进行物体检测，分析其识别准确性。


3.2.1 文心一言



图 7: 文心一言识别结果

可以看到，文心一言对这张包含多个物体的识别结果还是较为准确的，不仅识别出来各种水果、蔬菜的种类，还精准地定位了各个物体的位置。

3.2.2 豆包



这张图片中都有哪些物体？

→ 分享 ...

图中的物体有一个装满果蔬的柳条篮，以及散落在篮子周围的物品。篮子里有青椒、香蕉、红葡萄，篮子外有火龙果、小青椒、青枣、几颗散落的红葡萄、一颗鸡蛋和一些葱。

青椒富含维生素 C，可用于多种菜肴的配菜；香蕉是常见的水果，富含钾元素；红葡萄甜美多汁，可鲜食也可酿酒；火龙果原产于中美洲，富含膳食纤维；青枣口感脆甜，营养丰富。

图 8: 豆包识别结果

可以看到，豆包同样对这张包含多个物体的识别较为准确。但是和文心一言相比，其对物体的方位描述比较模糊，但是给出了一些关于图中物体的其他相关信息。

3.3 任务 3：人脸识别

在这个任务中，输入了三张合照给文心一言和豆包，由于涉及到隐私等问题，这两个大模型无法直接在原图上框选出人脸位置，因此采用 prompt 的方式令其告知照片中一共有多少人，分别有几个男生和几个女生。

3.3.1 文心一言





可以看到，文心一言对三张照片的表现还算不错，除了第二张照片对男生个数的识别出错之外，识别的还是非常精准的。

3.3.2 豆包



这张照片中有几个人？几个男生？几个女生？

这张照片中共有 10 个人，其中 6 个男生，4 个女生。

分享 ... 点赞 评论



这张照片中有几个人？几个男生？几个女生？

这张照片中共有 6 个人，其中 4 个男生，2 个女生。

🔊 📄 ↺️ ➦ 分享 ... 🌟 📌



这张照片中有几个人？几个男生？几个女生？

📄 ➦ ➦ 分享 ...

这张照片中有 4 个人，2 个男生（一位成年男性和一位小男孩），2 个女生（一位成年女性和一位小女孩）。

🔊 📄 ↺️ ➦ 分享 ... 🌟 📌

可以看到，豆包对三张照片的表现还算不错，除了第一张照片对总人数和男生个数的识别出错之外，识别的还是非常精准的。并且相较于文心一言，豆包在第三张家庭合照中还准确识别了图中男性、女性的年龄。

4 模型评估与改进建议

4.1 文心一言

对于文心一言模型，其巨大的优势在于多模态处理非常好，在图像增强、物体检测和人脸识别等任务中表现都很出色，但不足之处也很明显：在图像增强任务中无法在原图的基础上做处理，只能根据 prompt 和图片生成新图片，这会缩小其适用范围。同时，其在处理一些物体比较密集的图片时可能会出现错误（例如人脸识别的第二个任务）。在处理复杂场景或具有特殊要求的图像时，可能也无法完全理解用户的需求，导致生成的图像与预期不符。

根据其表现，我认为文心一言模型在图像处理领域可以用来帮助检测物体，或者是根据所需生成一个对应的图片，至于图像增强功能，如果不要一定在原图的基础上做处理，也是可以使用

的。目前一个巨大的局限就是在对原图的直接处理上，这需要未来多进行反馈训练。同时，可以增加更多样化、高质量的训练数据，提高生成图像的质量和多样性。还可以建立一个有效的用户反馈机制，及时收集用户对生成图像的评价和建议。

4.2 豆包

对于豆包模型，其优势在于可以处理多模态任务，在物体检测和人脸识别等任务中表现都很出色，同时还具有更强的联想能力。但不足之处也很明显：因未集成图像像素级处理模型，无法直接执行图像编辑（如裁剪、调色）、生成（如 AI 绘图）、修复等操作。同时在水印识别任务中对密集人群图片的识别不太准确。

根据其表现，我认为豆包模型在图像处理领域可以用来帮助检测物体，依托自然语言处理能力，可解析图像文本描述，辅助用户快速获取图像语义内容。同时在图文混合场景中，能整合文本与图像信息，根据用户文本指令分析图像元素，为图像生成文字说明。目前一个巨大的局限正如上文所言，还无法完成在对原图的直接处理上。因此，未来可以集成多模态模型，扩展图像生成、精准识别等能力，实现“语义理解 + 视觉处理”的深度融合。并且可以结合大语言模型对多模态数据的训练，提升图像细节分析能力（如情感识别、复杂场景逻辑推理），优化图像内容解析的精准度与丰富度。