

数字图像处理

Digital Image Processing

期末总复习



数图9讲，总ppt页数约为1200

清华大学电子系 王生进


► 图像处理的两大目的:

通过对图像信息进行处理，实现以下两个主要任务：

- (1) 满足人们在视觉、心理、或内容理解应用上的需求；
- (2) 对图像进行智能识别和分析，为实现计算机视觉奠定基础



数字图像处理的内容和流程



人类通过视觉感知获取外部客观世界的信息，然而感知结果却又会受到感知特性的影响，通常所说“眼见为实”在某些环境下不准确，因此要对视觉感知的特性进行研究

了解人类视觉感知的特性，分析其特性

→ 是研究图像处理理论与方法的基础

亮度适应与亮度鉴别


空间分辨率

视觉的时间特性

感觉亮度与图像强度的非简单线性

➤视觉空间关系区分能力:

感知物体之间空间位置关系的能力



➤视觉辨别能力:


辨别相似事物的能力

➤视觉形态特征感知能力:

帮助人分辨大小、
形状的差异

➤视觉统合能力:

从不完整信息抽象物体整体能力



➤视觉轮廓感知能力:

从目标轮廓中感知某一物体



亮度适应与亮度鉴别

由于数字图像作为离散的亮点集显示，因此需要考虑人眼对不同亮度的鉴别能力

⇒人眼适应光强度级别范围很宽，从夜视阈值到强闪光

(1) 亮度适应

为适应大范围的光强变化，人眼靠改变灵敏度，来调节不同范围内的鉴别能力→即亮度适应


(2) 亮度鉴别

在任何一个适应级，除了亮度适应之外，人眼对光强的鉴别能力也十分重要

作为强度函数的典型
韦伯比 $\Delta I_c / I$ 图

➤ 小 $\Delta I_c / I$ 表示可以区分强度小的变化，代表较好的亮度区分

➤ 反之，大 $\Delta I_c / I$ 则代表亮度区分能力差



From Gonzalez' book


实验表明，当背景亮度低时，亮度鉴别能力低

视觉的时间特性

1829年，比利时著名物理学家约瑟夫·普拉托为考察人眼耐光限度，及对物象滞留时间，他曾一次长时间对着强烈日光凝目而视，结果双目失明

但他发现太阳的影子深深地印在了他的眼睛里。约瑟夫·普拉托发现了“视觉滞留”的原理，他因此也被称为电影之父

约瑟夫·普拉托，摄于1843年（图片来源：en.wikipedia.org）




人眼视觉具有暂留特性

光度学

研究光的强弱的学科，称为光度学

单位立体元 $d\Omega$ ，立体角单位是steradian(球面度)， sr



(1) 光强：点光源 Q 沿方向 $\mathbf{r}$ 的发光强度 I ，定义为沿此方向上单位立体角内发出的光通量，单位 lm


设 $d\Omega$ 内的光通量为 $d\Phi$ ，则沿 $\mathbf{r}$ 方向的发光强度为

$$I = \frac{d\Phi}{d\Omega}$$

发光强度单位为 cd (坎(德拉))
 $1\text{cd} = 1 \text{ lm/sr}$

(2) 照度

一个被光线照射的物体表面上的照度，定义为照射在单位面积上的光通量。



设面元 ds 上的光通量为 $d\Phi$ ，则此面元上的照度 E 为下式，单位为勒(克斯) lx

$$E = \frac{d\Phi}{dS} \qquad 1 \text{ lx} = 1 \text{ lm/m}^2$$

二维图像成像模型

用 $f(x,y)$ 表示图像，在坐标 (x,y) 处， f 的幅度是一个正的标量。它的值正比于光源的辐射能量

$f(x,y)$ 由2部分组成

- ① 入射到观察场景的光量，即入射分量 $i(x,y)$
- ② 场景中物体反射光的总量，即反射分量 $r(x,y)$

$$f(x,y) = i(x,y) \cdot r(x,y)$$



$$\begin{aligned} \text{其中 } 0 < i(x,y) < \infty \\ 0 < r(x,y) < 1 \end{aligned}$$

(1) 典型照射数值 $i(x, y)$

- 在晴朗的白天，太阳在地球表面产生的照度超过 $90,000 \text{ lm/m}^2$ 勒(克斯)
- 在有云的情况下，为 $10,000 \text{ lm/m}^2$
- 在晴朗的夜晚，满月时 0.1 lm/m^2



(2) 反射分量 $r(x, y)$

取决于物体表面特性，在0与1之间。反射分量0表示全吸收，1表示全反射。

一些典型的物体表面反射数值 $r(x, y)$

黑天鹅绒 0.01

不锈钢 0.65

粉刷的白墙面 0.80

镀银的器皿 0.90

白雪 0.93

雪场滑雪要带遮光镜！




从实际场景中获取的图像，需要在空间和灰度上离散化后，获得数字图像，才能由计算机进行处理

- 空间坐标的离散化称为**取样**→**数字化坐标值**
- 灰度的离散化则称为**量化**→**数字化幅度值**



取样密度由取样间隔决定，
量化值由灰度级确定



两者决定数字图像的质量

像素间运算

像素间运算，包括算术运算和逻辑运算。在图像分析和处理中运用广泛。


(1) 算术运算

一般用于灰度图像，2个像素 p 和 q 间的像素运算：

- (i) 加法： $p+q$ ： 用于图像平均减少噪声
- (ii) 减法： $p-q$ ： 用于去除固定背景信息
- (iii) 乘法： $p*q$ ： 校正光照不均匀产生的灰度阴影
- (iv) 除法： p/q ： 校正光照不均匀产生的灰度阴影

3 特征点检测

- 局部特征点是图像特征的局部表达，它反映图像上具有的局部特殊性，所以它适合于对图像局部进行匹配应用。
- 全局特征易受环境的干扰，光照、旋转、噪声等不利因素都会影响全局特征。相比而言，局部特征点受到的干扰少。




局部匹配

区域匹配

全局匹配

1. Harris角点特征

- 在图像匹配和识别中，角点是一个有效的特征点。角点易在图像中定位局部特征，并且大量存在于人造物体中（例如墙壁、门、窗户、桌子等）。
- 角点的价值在于它是两边边缘线的接合点，是一种二维特征，可以被精确地检测（即使是亚像素级精度）。Harris特征检测是检测角点的经典方法



2、Harri角点特征检测的步骤

算法核心是利用局部窗口在图像上进行移动，判断灰度是否发生较大变化。如果窗口内的灰度值（在梯度图上）都有较大的变化，那么这个窗口所在区域就存在角点

Harris 角点检测算法分为以下三步

- (1) 当窗口（局部区域）同时向 x （水平）和 y （垂直）两个方向移动时，计算窗口内部的像素值变化量 $E(x,y)$
- (2) 对于每个窗口，都计算其对应的一个角点响应函数 R
- (3) 然后对该函数进行阈值处理，如果 $R > \text{threshold}$ 表示该窗口对应一个角点特征。

第一步 建立数学模型

首先确定哪些窗口会引起较大灰度值变化。让一个窗口的中心位于灰度图像的一个位置，然后该窗口沿各方向移动一个小的位移到一个新位置，计算位置的窗口移动引起的灰度值变化。窗口函数表示窗口内各像素权重，可设所有像素的权重为1，也可以窗口中心为原点的高斯分布。如果窗口中心点像素是角点，那么窗口移动前后，中心点的灰度值变化非常强烈。

将图像窗口平移 $[u,v]$ 产生灰度变化 $E(u,v)$

$$E(u,v) = \sum_{x,y} w(x,y) [I(x+u, y+v) - I(x,y)]^2$$

3 窗口函数 2 平移后的图像灰度 1 图像灰度

4 窗口函数 $w(x,y) =$

1 in window, 0 outside 或 Gaussian

第二步 角点响应函数R

至此已得灰度变化的最终形式E，目的是要找到引起较大灰度值变化的窗口。灰度值变化的大小则取决于矩阵M，为梯度的协方差矩阵。实际中定义一个角点响应函数R，通过判定其大小来判断像素是否为角点。

计算每个窗口对应的得分（角点响应函数R定义）：

$$R = \det(M) - k(\text{trace}(M))^2$$

$$\text{其中 } \det(M) = \lambda_1 \lambda_2 \quad \text{trace}(M) = \lambda_1 + \lambda_2$$


矩阵的特征值，是一个经验常数，在范围 (0.04, 0.06) 之间

R 值取决于的特征值，对于角点很大，平坦的区域很小，边缘的为负值。

第三步 角点判定

根据R值，可判定窗口所在区域划分为平面、边缘或角点。因为特征值决定了R值，所以可以用特征值来决定

- **平面**：窗口在平坦区域滑动，窗口内灰度值基本不发生变化，值很小，在水平和竖直方向的变化量均较小，即特征值都较小
- **边缘**：R值为负数，仅在水平或竖直方向有较大的变化量，特征值只有一个较大
- **角点**：R值大，在水平、竖直两方向上变化均较大，即特征值都较大，也即R值大



1、常用关键点定位方法

- 基于Active Contour Model (ACM, 主动轮廓模型, Snake)
- 基于Active Shape Model (ASM, 主动形状模型)
- 基于Active Appearance Model (AAM, 主动表观模型)
- 基于样本学习法 (如Eigeneye, Eigennose等方法)
F.Smeraldi, PRL 2002
- SDM方法, 深度学习方法DCNN (cvpr2013)

2、主动轮廓模型（ACM，snake）

- 由图像特征如边缘、直线，改变一条闭合曲线的形状，使其收敛到物体的边缘位置
- 围线的形状变化由两种因素控制：

一是曲线形状，称为内力 (internal force)，内力改变围线形状，

$$\begin{aligned} E_{\text{int}} &= [\alpha(s) |\mathbf{v}'(s)|^2 + \beta(s) |\mathbf{v}''(s)|^2] / 2 \\ &= (\alpha_i \|v_i - v_{i-1}\|^2 + \beta_i \|2v_i - v_{i-1} - v_{i+1}\|^2) / 2 \end{aligned}$$

能量公式中第1项为弹性能量，是 $\mathbf{v}$ 的一阶导数的模，这个弹性项其实是说曲线的两个相邻点不要离得太远。第2项为弯曲能量，是 $\mathbf{v}$ 的二阶导数的模，表示不要弯曲的太厉害。

二是图像特征，称为外力 (external force)：外力使围线收敛到图像的特征位置，如边缘等，例如定义为灰度梯度

$$E_{\text{ext}}(v(s)) = -|\nabla I(v(s))|^2$$

3、主动形状模型（ASM）

ASM 利用参数化的采样形状，构成对象形状模型


(1) 形状建模

– 样本归一化


- 中心归一化
- 尺度归一化
- 角度归一化

– PCA建模

由统计学习样本，建立
描述形状的控制点的运动模型




样本



归一化

(2) 灰度分布建模

考虑到标记点周围环境的复杂性，Tim Cootes 后来引进了局部灰度分布模型^{[1][2]}，从训练图像中每个标定沿轮廓法向采样灰度，以**获得标定附近的典型局部灰度分布模型** $f(p)$



[1] T.F.Cootes, C.J.Taylor, Active Shape Models - 'Smart Snakes'. in Proc. British Machine Vision Conference. Springer-Verlag, 1992, pp.266-275.


[2] T.F.Cootes, C.J.Taylor, Active Shape Model Search using Local Grey-Level Models: A Quantitative Evaluation, in Proc. British Machine Vision Conference, (Ed. J. Illingworth), BMVA Press, 1993, pp.639-648.

1、DCNN (CVPR2013)

- 一种从粗到精的定位思想

《Deep Convolutional Network Cascade for Facial Point Detection》, CVPR2013

RCNN回顾: RCNN也是一种从粗定位, 到精识别的过程, 跟本篇paper的思想很相似



➤ 物体检测是计算机视觉的基本任务之一

计算机视觉解决什么问题

典型的计算机视觉任务

图像分类


匹配问题

物体检测


物体识别

目标跟踪

图像分割




图源: <https://cdn.pariscityvision.com/media/wysiwyg/tour-eiffel.jpg>



- **运动目标检测：** 具有运动信息
- **类目标检测：** 例如，人脸、汽车等
 - 可获得大量图像样本
 - 利用离线学习训练类别分类检测器
- **特定刚体目标检测；** 某建筑物，确定的车辆
 - 仅有少量样本的典型目标
 - 特征提取与图像匹配方法，仿射变换
- **特定可变形目标检测：** 某个人脸, 行人ReID
 - 仅有少量样本，目标表象发生时变



运动信息作为目标的一类特征，是目标检测中的一个重要研究内容。



像素累积平均法背景建模

- 利用N帧图像的平均来求取背景 $BK(n) = \sum_{i=n-N}^{i=n-1} I(i) / N$
- 背景的更新:

获得初始背景图像后，需不断更新，以保证背景图像的变化可跟上当前输入图像中光照等外界因素的变化。

使用当前检测结果作为更新依据，在前景检测区域内的像素点不作更新，被认为是背景的像素则更新。

$$B_A(k+1) = \begin{cases} (1-\alpha)B_A(k) + \alpha I_A(k), & A \text{ 不是物体像素点} \\ B_A(k), & A \text{ 是物体像素点} \end{cases}$$


α 更新率由实验确定，一般取0.2

基于高斯模型的背景建模

高斯分布背景模型分单高斯和混合高斯。单高斯适用于单模态背景情形；混合高斯用于变化背景。

即对一个背景图像，像素亮度的分布满足高斯分布，如对背景图像 **B**，每个 **(x, y)** 点的像素灰度值满足高斯分布 $\beta(x, \mu_t, \sigma_t)$ ，则可建立高斯模型。

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



动态轮廓法目标提取 (ACM, snake)


- 由图像特征如边缘、直线，改变一条闭合曲线的形状，使其收敛到物体的边缘位置
- 围线的形状变化由两种因素控制：
 - (1) 曲线形状（曲率），称为内力 (internal force)，内力改变围线形状，由计算边缘点的一次、二次导数获得：

$$\begin{aligned} E_{\text{int}} &= [\alpha(s) |\mathbf{v}'(s)|^2 + \beta(s) |\mathbf{v}''(s)|^2] / 2 \\ &= (\alpha_i \| \mathbf{v}_i - \mathbf{v}_{i-1} \|^2 + \beta_i \| 2\mathbf{v}_i - \mathbf{v}_{i-1} - \mathbf{v}_{i+1} \|^2) / 2 \end{aligned}$$

物体检测问题的目标分为2大类型：类别目标、特定目标

对于类别目标（例如，人脸和汽车等），通常可以预先收集大量的相关图像样本）。然后采用统计学习方法，离线训练目标的类别检测器，典型的方法有PCA、AdaBoost、SVM等

针对特定目标，预先没有大量样本用于离线学习的情况，因此需要采用特征提取的方法，如模板法，SIFT特征法。



1、基于PCA的物体检测

统计学习物体检测的典型的方法有PCA、AdaBoost、SVM等


在类目标识别中，可以将主成分分析（PCA）析用于类别目标表象图像的检测与识别问题。

- ◆ PCA分析的最大特点是去相关性好。

可以在 N 维特征向量中，提取 K 个主要特征， $K \ll N$ 。

K 个主要特征具有独立描述图像的性能。

- ◆ 获得 K 个具有较强分类能力的特征；
且因为特征个数减少，可降低算法复杂度。



➤ 基于PCA的人脸检测与人脸识别

以人脸检测为例，介绍PCA类目标检测算法

对人脸图像 $f(x,y)$ ，图像中的像素可以用 b_{ij} 表示

一幅 $N \times N$ 的人脸图像按列相连，构成一个 N^2 维向量：

$$\mathbf{x} = (b_{11} \ b_{21} \ b_{31} \ \dots b_{N1} \ b_{12} \ b_{22} \ \dots b_{N2} \ \dots b_{1N} \ b_{2N} \ \dots b_{NN})$$

可将其视为 N^2 维空间中的一个点

➤利用ORL人脸数据集（400张人脸图像）进行PCA训练，获得特征脸的基空间

前50个PCA基向量




2、基于Adaboost的目标检测方法

- AdaBoost算法是一种新的分类器融合方法，该算法可以将任意**略强于随即猜测的弱分类器**融合成为强分类器，并且操作简单、实用性强。
- **Viola2004**^[1]首先将AdaBoost应用于人脸检测，提出了一种基于AdaBoost算法的快速目标检测方法—**Boosting Cascade**方法。

[1] Viola P., Jones M. J., Robust Real-Time Face Detection, International Journal of Computer Vision 57(2), 137-154, 2004


- 第一步：求取第一个子分类器，并计算新的样本分布



找最小错误率 ε ，分错3个

$$\varepsilon_1 = 0.30$$

$$\alpha_1 = 0.42$$



权值 α 与 ε 成反比例

$$\alpha = \frac{1}{2} \ln \left(\frac{1-\varepsilon}{\varepsilon} \right)$$

$$D_1 = (w_{11}, w_{12}, \dots, w_{1i}, \dots, w_{1N}), \quad w_{1i} = \frac{1}{N}, \quad i = 1, 2, \dots, N$$

错误率定义 $\varepsilon = \frac{\text{未正确分类的样本数目}}{\text{所有样本数目}}$

$$D_{m+1} = (w_{m+1,1}, w_{m+1,2}, \dots, w_{m+1,i}, \dots, w_{m+1,N})$$

$$w_{m+1,i} = \frac{w_{mi}}{Z_m} \exp(-\alpha_m y_i G_m(x_i)), \quad i = 1, 2, \dots, N$$

Z_m 是归一化因子， G_m 为分类器 h

根据最小错误率，得到一个子分类器 h_1 ，形成新的样本分布 D_2 ，其中划圈的样本表示被分错的。在右边图中，比较大的“+”表示对该错分样本做了加权

4.4 深度学习物体检测

2. 基于深度学习的物体检测算法

2.1 物体检测方法框架 —— 三步走

物体检测是图像领域的一个主要研究方向，物体检测算法也多种多样。大多数基于深度学习的物体检测算法按照以下三个步骤进行：

- (1) 候选区域生成
- (2) 区域特征提取与分类
- (3) 物体定位




图2.1 基于深度学习的物体检测算法流程图

2. 基于深度学习的物体检测算法

2.2 候选区域生成:

➤ 算法功能：根据图像显著性等特性对图像进行预处理，提出可能包含物体的候选区域供后续算法处理。

算法将候选窗口数量从数万（滑动窗算法）降至数十至数千，加快了检测速度，减少了虚警率。

➤ 评价指标：#win-Recall曲线

#win：提出的候选区域数量；Recall：物体召回率

*在实际应用中也会考虑时间因素



图2.2 候选区域生成示例

2. 基于深度学习的物体检测算法

2.3 卷积神经网络 (CNN) 特征提取

- 算法功能：在物体检测中，CNN实现对候选框的特征提取+分类的作用。
- 评价指标：分类准确率




图2.6 卷积神经网络组成

2. 基于深度学习的物体检测算法

2.4 非极大值抑制NMS:

2.4.1 Non-Maximum Suppression (NMS):

- 算法功能：消除多余检测框，输出物体最佳位置。
- 评价指标：物体位置准确率。
- 算法流程：
 - 检测框按照评分从高到低排序，最高分的检测框直接设为输出框
 - 对余下检测框，依次进行操作：若检测框与之前某个输出框的交并比大于阈值，则抑制该检测窗，否则将其设为输出框




图2.12 NMS算法作用——从检测框（左）得到输出框（右）

2. 基于深度学习的物体检测算法

2.5 算法实例 —— 从R-CNN到Faster R-CNN:

2.5.1 R-CNN^[8]: 物体检测的基础性框架

- Selective Search做region proposal
- AlexNet提取region的feature, SVM对region分类
- NMS筛选窗口并输出




图2.13 R-CNN物体检测框架

2. 基于深度学习的物体检测算法

2.5.2 Fast R-CNN^[9]: 共享的卷积层特征

- Selective Search做region proposal (2k个object proposal)
- AlexNet conv5 ROI pooling得到region的feature, 统一到一样的尺度 (对于AlexNet是6x6)。
- 网络的Softmax层对region分类
- Bounding Box Regression 规范窗口并输出




图2.14 Fast R-CNN流图

2. 基于深度学习的物体检测算法

2.5.3 Faster R-CNN^[10]: 一步到位的检测网络

- 与检测网络共享卷积层的region proposal network (RPN)提出窗口
- ROI pooling得到窗口特征
- Bounding Box Regression 规范输出窗口




图2.15 Faster R-CNN中的窗口提出机制RPN

目标识别是指一个将一个特殊目标（或一种类型的目标）标注标签的过程。它既包括两个相同、或相似目标的识别，也包括一种类型目标的识别。


目标识别是基于分类（Classification）的识别（Recognition），即在给定数据中，分类出哪些是目标。通常不是pixel，而是给定的模板区域，或定义的一个对象（Object），或图像自身。

目标识别有不同层次
（像素，部件，物体）


（目标识别）是深度学习
图像处理第一重境界




(a) Image classification



(b) Object localization



(c) Semantic segmentation



(d) Instance segmentation

在计算机视觉、目标检测、识别，以及图像理解中，图像匹配技术起着重要作用。

也是多传感器图像融合、特别像素级图像融合的关键技术。——图像识别，立体视觉，图像拼接，……


在实际图像处理中，匹配可以在不同层次上进行。
常用的匹配空间有：

图像空间匹配：

特征空间匹配：

关系空间匹配：

根据特征间拓扑关系的相似性



匹配基元

匹配基元是指匹配算法的最小匹配对象，它由特征抽取算法产生。在建立目标检测系统时，须根据环境特点和应用领域选择适当的匹配基元。

匹配基元可以是以下要素：

- (1) 过零点 (zero-crossings),
- (2) 边界与线片段 (edge and line fragments),
- (3) 线性特征 (linear features), 如Radon变换和Hough变换
- (4) 边缘轮廓 (object boundaries),
- (5) 特征算子抽取的特征点 (如角点, SIFT点等)
- (6) 特征区域 (如模板, 深度学习中的特征图, 等)

图像匹配方法

图像匹配就是在两幅图像的匹配基元之间建立对应关系的过程，任何计算机视觉系统中都包含一个作为其核心的图像匹配算法。

研究如何找到彼此对应的部分，即匹配方式，一般有两种计算途径：

- (1) 灰度分布相关性， 属基于区域相关的方法
- (2) 特征分布相似性。


因而就有两类匹配算法：

- (1) 基于灰度的算法 (intensity based),
- (2) 基于特征的算法 (feature based)

在基于特征的匹配中，是采用特征提取算子，从图像中提取特征，**对图像用特征向量进行描述。**


基于特征的匹配算法，适用于具有显著主导特征的目标和环境，如车辆，行人，人脸，特定建筑物等。

该方法在特征提取的前提下，具有匹配精度高、具有平移、缩放、旋转鲁棒的特点。



1、HoG特征描述子

以Harris角点等特征点为中心的一定区域范围内，提取HoG特征，实现对特征点的特征描述



SIFT描述子的长度: $4 * 4 * 8 = 128$ 维






Image gradients



Histogram of Oriented Gradients

确定主方向 Orientation Assignment

- Create gradient histogram
 - Weighted by magnitude and Gaussian window
- Peaks of histogram determine orientation





8 x 8邻域的梯度方向和梯度方向直方图

特征描述

以特征点为中心，将坐标轴旋转为特征点的主方向，确保旋转不变性。然后基于局部梯度方向直方图建立特征点描述（特征向量）。


在SIFT算法中，Lowe建议采用以特征点为中心的一个 16×16 的邻域作为采样窗口，该邻域又分为 4×4 的小区域。

在每个小区域内，按8个方向计算方向直方图，得到一个 $4 \times 4 \times 8 = 128$ 维向量作为特征向量。



2、Harris角点检测

Harris角点检测算法已经在第3讲中介绍，这里介绍角点匹配



角点匹配

SSD匹配方法

SSD (Sum of Squared Differences, 平方差和) 是一种常用的图像块匹配方法。其基本思想是：在图像中提取两个块（通常是邻域窗口），然后计算这两个块的像素差的平方和，差值越小，表示两个块越相似，匹配的可能性越高。

使用SSD方法对两幅图像中的角点进行匹配。通过计算图像窗口之间的平方差和 (SSD)，找到最匹配的角点对。

加权SSD计算：计算每个角点周围窗口的SSD值，使用高斯加权减少噪声的影响。

最小SSD匹配：选择最小SSD值的匹配点。

仿射变换和RANSAC算法


5.3 虹膜与指静脉识别

一、虹膜识别

1、虹膜识别流程

虹膜采集

- 图像获取
- 虹膜分割
- 特征编码
- 分类



编码、分类





基于深度学习的人脸识别

以人工神经网络为基础的深度学习是一种End-to-end的学习F分类器的方法（全步骤一次性学习）

DNN (Deep Neural Network)

- Nonlinear transform learning
- Feature learning,
- Representation learning




(1) 人脸识别关键技术步骤

- **人脸检测** 判断输入图像中是否存在人脸；如果存在人脸，返回人脸所在的位置
- **关键点定位** 确定人脸中眼角、鼻尖和嘴角等关键点所在的位置，为人脸的对齐和归一化做准备
- **人脸对齐归一** 根据关键点的位置，采用相似变换，将人脸对齐到标准脸关键点，并裁剪成统一大小
- **特征提取** 主要是利用海量数据，训练卷积神经网络；将人脸图像表示成具有高层语义信息的特征向量
- **人脸识别** 主要是利用Metric Learning技术，进一步提升准确率




人脸识别流程





本章的数字图像处理研究图像构成成分的划分

其特点是→输入是一幅图像，输出是从该图像中提取出的区域属性，即区域边界




图像分割是数字图像处理中一个重要技术

图像分割的目标，是将图像分为构成它的子区域或对象，当感兴趣的目标被分离出来后，分割任务完成



图像分割主要包括4种技术：


- 并行边界分割技术；
- 串行边界分割技术；
- 并行区域分割技术；
- 串行区域分割技术



(1) 并行边界分割技术;

对图像的每一点上所做的处理，不依赖于其它的点处理结果，逐点独立计算。

如求导，Sobel算子，Laplacian算子。



(2) 串行边界分割技术;


串行边界分割技术，通常是通过顺序的搜索边缘点来工作的，

先求梯度，找到梯度最大点，进行边界跟踪。

(3) 并行区域分割技术;

并行区域分割主要有两种方法:

阈值分割, 聚类。



(4) 串行区域分割技术

串行区域分割一般可分为两种方法:

一种是区域生长, 二是分裂合并。

6.2 基于梯度和阈值的图像分割

Tsinghua

6.2.1 边缘检测与梯度算子

1. 边缘检测的概念

边缘检测，对于灰度级变化的检测是最为有效的检测方法。

2. 一阶梯度算子

(1) $f(x, y)$ 在 (x, y) 的梯度定义

(2) 近似处理 $|\nabla f| \approx |G_x| + |G_y|$

$$\overline{\nabla f} = \begin{bmatrix} G_x \\ G_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix}$$

一阶微分最简单的近似处理

$$G_x = z8 - z5 \quad G_y = z6 - z5$$

z1	z2	z3
z4	z5	z6
z7	z8	z9


Robert在1965年提出了交叉差分定义

$$G_x = z_9 - z_5 \quad G_y = z_8 - z_6$$

Robert算子模板

$$|\nabla f| \approx |z_9 - z_5| + |z_8 - z_6|$$

z1	z2	z3
z4	z5	z6
z7	z8	z9



Sobel算子

$$|\nabla f| \approx |(z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3)| \\ + |(z_3 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7)|$$

二阶梯度算子-拉普拉斯算子

二维函数 $f(x, y)$ 的拉普拉斯算子是如下定义的二阶导数

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$


拉普拉斯算子的一种模板

$$\begin{aligned} \nabla^2 f = & -[f(x+1, y) + f(x-1, y) \\ & + f(x, y+1) + f(x, y-1) \\ & - 4f(x, y)] \end{aligned}$$

0	-1	0
-1	4	-1
0	-1	0

Canny边缘检测算子

Canny 边缘检测算子是John F. Canny于 1986年提出的一个多级边缘检测算法。



Canny边缘检测算法步骤

step1: 用高斯滤波器平滑图象；

step2: 用一阶偏导的有限差分来计算梯度的幅值和方向；

step3: 对梯度幅值进行非极大值抑制；

step4: 用双阈值算法检测和连接边缘。




门限概念

所示直方图对应于一幅图像：亮目标和深背景

►对象和背景具有的灰度像素分成2组不同模式

从背景中**提取目标**的一种方法是选择门限阈值**T**，将模式分开。



a b


FIGURE 10.26 (a) Gray-level histograms th old, and (b) multiple thresholds.



分割的目的是将图像划分为不同区域。

前面几种方法所依据的物理基础：

- 根据灰度不连续性，进行边缘检测
- 通过搜寻区域之间的边界划分区域
- 用以像素性质的分布为基础的门限分割



本节讨论以直接寻找区域为基础的分割

1. 区域生长

是一种根据事先定义的准则，将像素或子区域聚合成更大区域的过程。

基本方法：

以一组“种子”点开始，将与种子性质相似(如灰度或颜色)的相邻像素附加到生长区域的每个种子上，

- 有关连通性和相邻性的信息用于区域生长；
- 在没有像素满足加入某个区域条件时，生长停止。

2. 区域分离与合并

区域生长是从一组种子点开始的。

作为替换方法，是在开始时，也可以将图像分割为一系列任意不相交的区域。

然后，通过一定的规则，对它们进行聚合合并，或分拆，以满足相应条件。

→ 四叉树分割方法：

如果区域 R_i 内80%像素具有性质： $|z_j - m_i| < 2\sigma_i$ 则构成一个区域。

其中 z_j 是 R_i 内第 j 个像素的灰度级， m_i 灰度是区域 R_i 的灰度级均值， σ_i 是区域内灰度级标准差。

a b c

FIGURE 10.43

(a) Original image. (b) Result of split and merge procedure. (c) Result of thresholding (a).



原图像



拆分和聚合的结果
保留了叶茎




比较：对(a)门限处理的结果：叶茎被
错误消除了

1. Graph Cut 分割的基本原理

GraphCut是一种性能出色的基于能量优化的图像分割算法，在计算机视觉领域广泛用于前景分割（Image segmentation）、立体视觉（stereo vision）、抠图（Image matting）等。


它把分割问题与图最小割（min cut）问题相关联。

用无向图 $G = \langle V, E \rangle$ 表示要分割的图像， V 和 E 分别是顶点和边的集合



一个分割被定义为 E 的子集 E' ，如下图的橙色的线条：

E' 定义的分割切分 n-link，且属于前景的节点与 S 连接开，属于背景的节点与 T 连接。一次分割结束后，分成的两个子集就对应于图像的前景和背景，相当于完成了图像分割



图像标签（每个像素）为 $A = \{A_1, A_2, \dots, A_p\}$ ，其中 A_i 为 0（背景）或 1（目标），则图像分割结果为 A 时，图像能量函数可表示为：

$$E(A) = \lambda R(A) + B(A) \quad \lambda > 0$$

$R(A)$ 是区域项 (region properties)，衡量 t-link 被切断的损失

$B(A)$ 边界项 (boundary properties)，衡量 n-link 被切断的损失

6.4 深度学习图像语义分割FCN


6.4.2 图像语义分割FCN算法

- 计算机视觉任务:

分类classification 检测 detection 分割segmentation 识别recognition



(a) Image classification



(b) Object localization




(c) Semantic segmentation



(d) This work


2、全卷积神经网络(FCN)

- CNN对分类效果好，不适合直接做分割（前面的CNN分割例子）
- CNN模型的输入维度固定
- FCN是对CNN改进，适合直接用于分割的模型
- 输入：任意大小图片
- 输出：各个像素对应的类别




3、网络结构

- 只有卷积层，没有全连接层
- 上采样(upsampling)




FCN将这3层表示为卷积层，卷积核的大小(通道数，宽，高)分别为(4096,1,1)、(4096,1,1)、(1000,1,1)。所有的层都是卷积层，故称为全卷积网络

FCN采用反卷积层对最后一个卷积层的feature map进行上采样,使它恢复到输入图像相同的尺寸,从而可以对每个像素都产生了一个预测,同时保留了原始输入图像中的空间信息,最后在上采样的特征图上进行逐像素分类。



• 上采样（up sampling）


普通池化缩小了图片的尺寸
通过反卷积得到和原图等大的分割图



对于最后一层的输出图像，需要进行32倍的上采样，以得到原图一样的大小。


• 反卷积 Deconvolution

普通池化缩小了图片的尺寸，通过反卷积得到和原图等大的分割图



• 上池化和上采样


普通池化缩小了图片的尺寸，过反卷积得到和原图等大的分割图



两种方式

(a)

上池化




(b)

上采样

• FCN-xs的网络结构

- 卷积化 (Convolutional)
- 上采样 (Upsample)
- 跳跃结构 (Skip Layer)



7.1 空域图像增强

图像增强具有十分重要的意义，已经成为一类基本的图像处理技术——图像预处理。

其目的是对图像进行加工处理，以得到对于视觉和识别应用而言，更好、更有用的图像。




图像增强在 **图像传感器、日常生活照片、安防视频** 等都有很多应用需求



7.1.2.1 基本灰度变换 Basic grayscale transform

基本灰度变换，是简单的空域变换增强方法。在空间域变换增强中，基本灰度变换有以下几种方法：

图像求反、增强对比度、动态范围调整（压缩）、灰度切分



(1) 直方图均衡化的基本思想

直方图均衡是以**累积分布函数**变换为基础，将原始图像的直方图，由不均匀变换为均匀分布

一幅图像中**灰度级 s_k** 出现的概率(直方图)为

$$p_s(s_k) = n_k / n \quad k = 0, 1, \dots, L-1$$

其中 **$p_s(s_k)$** 代表第 **k** 个灰度级出现的概率， **s_k** 常被归一化到 **$[0, 1]$** 区间

(2) 选择一个合适的变换函数是核心问题

考察图像处理中一个重要的变换函数：

累积分布函数 (CDF) cumulative distribution function

p_s 是概率密度函数

$$t = EH(s) = \int_0^s p_s(w) dw$$

随机变量 s 的累积分布函数

一幅图像的灰度级可被视为归一化到 $[0, 1]$ 区间的随机变量。随机变量的基本描述是概率密度函数。故上式满足前面条件 (a), (b)

(3) 对于数字图像的离散灰度级值，通常采用概率之和的形式， s_k 和 t_k 被归一化到 $[0, 1]$ 区间

$$p_s(s_k) = n_k / n \quad k = 0, 1, \dots, L-1$$

$$t_k = EH(s_k) = \sum_{i=0}^k p_s(s_i) = \sum_{i=0}^k \frac{n_i}{n}$$


$p_s(s_k)$ 的曲线称为图像灰度直方图。

上式给出的变换 称为直方图均衡化
上式将输入图像灰度级 $s_k \rightarrow$ 变换到输出 t_k

3. 直方图规定化

直方图均衡化的优点，是可以自动地增强图像全体的对比度。

缺点是，只能产生近似均匀的直方图，
并且是全局均衡化直方图，
增强效果不易控制。




实际中，需要变换直方图，使之成为特定的形状，
以便有选择地增强某个范围灰度值。

上述例子表明，直方图均衡化不是万能的，需要有选择地增强某个范围灰度值。

➤ 解决方案：

采用较为灵活的直方图规定化方法，
有的书亦称为直方图匹配



➤ 关键技术：

正确选择规定化的函数，使输出图像
具有规定的概率密度函数

图像间运算的目的

在许多实际应用场合，通过多幅图像间的相互运算，可以实现对图像的增强。

相减运算

图像的相减运算是一种常用算法
→ 突出两幅图像间的差异

$$g(x, y) = f(x, y) - h(x, y)$$

图像平均

→ 用于在图像采样中消除噪声

假定 $g(x, y)$ 为混入噪声的图像，可表示为

$$g(x, y) = f(x, y) + e(x, y)$$

一系列 $g(x, y)$ 相加求图像平均去除噪声

$$\bar{g}(x, y) = \frac{1}{M} \sum_{i=1}^M g_i(x, y)$$

滤波原理与分类

空间滤波是在图像空间由模板操作，进行邻域变换的方法

按模板特点，可分为线性滤波、非线性滤波

➤ 线性滤波

线性系统的传递函数和脉冲函数构成傅里叶变换对，故线性滤波器的设计常基于对傅氏变换的分析。


➤ 非线性滤波

通常，直接对邻域进行变换操作


平滑滤波器特性

图像中高频分量对应→边缘、噪点等灰度值变化快的区域，

平滑滤波器的作用是低通，可以减弱或消除傅里叶空间的高频分量






→可以滤除灰度变化剧烈成份，使图像变平滑但并不影响低频分量，整体灰度不受影响



空域实现滤波器方式，可利用模板卷积

- (1) 模板在图中滑动，中心与像素重合
- (2) 模板系数与对应像素值相乘
- (3) 所有乘积相加
- (4) 将和赋予与模板中心对应的像素




均值滤波器——线性平滑滤波器

(1) 作用

线性平滑滤波器用于模糊处理和减小噪声
→提取大目标时消除细节，缝隙

线性平滑滤波器的输出，是包含在滤波模板内像素的简单平均值




因此，也称为均值滤波器，根据其性质，它属于低通滤波器

中值滤波器——非线性平滑滤波器

Median filter

- 依靠 $n*n$ 的模板对图像进行中值平滑处理
利用区域的中值进行平滑
- 进行中值滤波的目的：
让与周围像素灰度值相差较大的像素改取与周围灰度值接近的值
 - 消除孤立噪声能力强，
 - 不是简单取均值，产生模糊较少，保持细节

线性高通滤波器是最常用的线性锐化滤波器。



由上图空域锐化滤波器的特性可知，模板中心系数应为正，周围应为负

基于二阶微分的图像增强-拉普拉斯算子

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

拉普拉斯算子的模板

$$\begin{aligned} \nabla^2 f = & -[f(x+1, y) + f(x-1, y) \\ & + f(x, y+1) + f(x, y-1) \\ & - 4f(x, y)] \end{aligned}$$

0	-1	0
-1	4	-1
0	-1	0

-1	-1	-1
-1	8	-1
-1	-1	-1

右图为拉普拉斯扩展算子，包括对角线邻域

一阶导数可以用于检测图像中的一个点是否是边缘的点

二阶导数的符号可以用于判断一个边缘像素是在边缘亮的一边还是暗的一边

基于一阶微分的图像增强——梯度法

(1) 梯度算子

$f(x, y)$ 在 (x, y) 的梯度定义 $\nabla f = \begin{bmatrix} G_x \\ G_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix}$

向量的模
称为梯度

$$|\nabla f| = \sqrt{G_x^2 + G_y^2}$$


梯度向量的分量本身是线性算子，但它的模不是线性的，因为用到了平方和开方运算

一阶导数可以用于检测图像中的一个点是否是边缘的点

二阶导数的符号可以用于判断一个边缘像素是在边缘亮的一边还是暗的一边

频域图像增强，主要借助滤波器实现


不同滤波器，根据其滤除的频率和保留的频率不同，从而实现不同的增强效果



滤除高频、保留低频：消除噪声、平滑

滤除低频、保留高频：获得边缘、增强

7.2.1 在频率域中进行增强的算法基础是傅里叶变换和卷积理论。



$g(x, y) = h(x, y) * f(x, y)$ 邻域模板处理

$G(u, v) = H(u, v)F(u, v)$ 在频域计算

$g(x, y) = F^{-1}[H(u, v)F(u, v)]$

常用频域增强方法：

低通滤波，高通滤波，带通和带阻滤波等

低通处理：使图像中低频分量通过，
抑制高频分量。

目的：模糊图像中的边缘，滤除高频噪声


a b

FIGURE 4.19

(a) Sample text of poor resolution (note broken characters in magnified view).

(b) Result of filtering with a GLPF (broken character segments were joined).

Historically, certain computer programs were written using only two digits rather than four to define the applicable year. Accordingly, the company's software may recognize a date using "00" as 1900 rather than the year 2000.




Historically, certain computer programs were written using only two digits rather than four to define the applicable year. Accordingly, the company's software may recognize a date using "00" as 1900 rather than the year 2000.




理想低通滤波器

图像中的细节、边缘和噪声对应傅里叶变换中高频部分

→ 可选择合适 $H(u, v)$ 减弱高频分量




剖面图




透视图

巴特沃斯低通滤波器

由于实际应用中理想低通难于物理实现



物理上可以实现的，是巴特沃斯低通滤波器 (Butterworth)




N 阶巴特沃斯低通滤波器传递函数定义


$$H(u, v) = \frac{1}{1 + [D(u, v) / D_0]^{2n}}$$

理想高通滤波器

图像中的边缘对应傅里叶变换中高频部分
→ 锐化图像可选择高通滤波。




剖面图




透视图

2D 理想高通滤波器传递函数满足

$$H(u, v) = \begin{cases} 0 & \text{若 } D(u, v) \leq D_0 \\ 1 & \text{若 } D(u, v) > D_0 \end{cases}$$



但类似理想低通の場合，




理想高通滤波器也无法用实际器件实现。

巴特沃斯高通滤波器

n 阶巴特沃斯高通滤波器传递函数定义

$$H(u, v) = \frac{1}{1 + [D_0 / D(u, v)]^{2n}}$$

1 阶巴特沃斯高通滤波器，高低频间连续过渡



带通和带阻滤波器，是通过或抑制某个区间频率成分的一种滤波方法

(1) 带阻滤波器

$$H(u, v) = \begin{cases} 1 & \text{当 } D(u, v) < D_0 - \frac{W}{2} \\ 0 & D_0 - \frac{W}{2} \leq D(u, v) \leq D_0 + \frac{W}{2} \\ 1 & D(u, v) > D_0 + \frac{W}{2} \end{cases}$$

W为带宽, D_0 为半径

N 阶巴特沃斯带阻滤波器:

$$H(u, v) = \frac{1}{1 + \left[\frac{D(u, v)W}{D^2(u, v) - D_0^2} \right]^{2n}}$$

W 为带宽
D₀ 为半径

(2) 带通滤波器:

执行与带阻滤波器相反的操作，帮助提取噪声模式

$$H_{bp}(u, v) = 1 - H_{br}(u, v)$$

带阻滤波器传递函数

光的三基色

根据人眼结构和特性，所有颜色都可以看作是3个基本颜色的不同组合而成，即

R, G, B (红Red, 绿Green, 蓝Blue)

人所感受到的物体颜色，主要取决于来自于物体表面的反射光的特性：

均匀反射各种光谱 → 物体是白色

对某些光谱反射较多 → 物体呈现相应的颜色

颜色的基本特性

区分颜色常用3种基本特性量：

辉度，色调，饱和度



◆辉度：

与物体的反射率成正比，
无彩色时只有辉度量。

对彩色光而言，颜色中加入白色越多越明亮


色度图（1931年，CIE制定）

用组成某一颜色的三基色比例来规定这一颜色。

色调和饱和度合称色度，它确定光谱成分。
颜色用亮度和色度表示。

CIE1931色度图有很大的实用价值，任何颜色，无论是光源色还是表面色，都可在该色度图上标定出，使得颜色的描述简便而准确。

例如，为了保证颜色标志的正确辨认和交通安全的管制，在CIE1931色度图上规定了具体的范围，它适用于各种警告信号和颜色标志。



1931 CIE (Commission
International de
l'Eclairage 国际照明协会)¹¹²

建立颜色模型的目的

是为了用基本量描述所需的颜色。通常，建立3D坐标系，每一个空间点代表某一种颜色

颜色模型分类

常用有RGB, HSI等，用于彩色处理和彩色显示，**R** (红 red), **G**(绿 green), **B**(蓝 blue);

HIS 也称为用户直观的色彩模型，

H (色调 hue),

S (饱和度 saturation),


I (密度或明度 V intensity, 对应亮度)

RGB彩色模型

- (1) 彩色模型用坐标系统和子空间描述。
位于系统中的每种颜色都由单个点表示

彩色模型→也称为彩色空间、彩色系统

图像处理中，最通用的模型是红，绿，蓝(RGB)
彩色模型。



该模型基于笛卡尔坐标系统，彩色
子空间是立方体

HSI彩色模型

RGB模型虽然与人眼很强地感觉红、绿、蓝三原色的事实能很好地匹配，

➤ **但RGB模型不能很好地适应人解释的颜色**

它没有涉及用组成某物体颜色的、每一原色的百分比，给出一个物体的颜色描述（如汽车的颜色）




当人们观察一个彩色物体时，习惯用色调、色饱和度和亮度描述这个物体

→可以更加直观地描述彩色物体，HSI模型

HSI也称为用户直观的色彩模型，

H(色调 hue)，**S**(饱和度 saturation)，

I(密度或明度V, intensity, 对应图像亮度)



HIS模型对于开发基于彩色描述的图像处理方法是一个理想的工具


8.3.1 伪彩色图像增强

伪彩色图像的处理，包括以下几种主要的处理方法：

- (1) 等密度分层伪彩色技术——亮度分层
亦称为灰度分层；
- (2) 灰度级转换为彩色处理；
- (3) 频域滤波处理
对不同频率成分赋予不同彩色。

方法一：等密度分层伪彩色技术—亮度分层 (Intensity Slicing)

如果一幅图像可以被看作是一个二维的亮度函数，可以采用亮度分层处理实现增强。




此方法可以描述为：


定义一组平行于坐标平面的平面，每个平面在与亮度函数相交处分割亮度函数。

方法二：从灰度到彩色的变换

不同于亮度分层方法，该方法对输入的像素灰度级，进行3个独立的变换




其结果，构成 R、G、B的3个值，由此合成显示一幅图像。



此方法获得的彩色内容，受变换函数的特性所调制，可显示出不同的色彩。

频域滤波处理

根据图像中各区域的不同频率含量给区域赋予不同颜色




彩色分层增强

突出图像中特殊的彩色区域，对从其周围区域中分离出目标物体有重要作用。

基本处理方法

- (1) 显示感兴趣的颜色，以利从背景分离
- (2) 像模板一样，使用由彩色定义的区域




不能采用各通道灰度切分增强的办法，
因为彩色像素是一个 n 维向量。

直方图处理

在单色图像条件下，直方图均衡使直方图分布均匀，

⇒但彩色图像由多个分量组成，独立进行各个分量的均衡会产生不正确的彩色。




考虑适应多于一个分量的直方图均衡。采用方法是均匀扩展彩色强度，保留色彩本身(色调)

- (1) RGB→HSI转换后对I分量增强
- (2) 然后进行HSI→RGB

退化和复原过程的物理模型








一个简单的通用图像退化模型如下：

输入图像为 $f(x, y)$ ，外加噪声 $n(x, y)$ ，
退化图像为 $g(x, y)$ ，



常见具体退化模型

4种常见退化模型示意图。其中，
(a), (b), (c) 为空间不变：只与输入有关，与位置无关；
(b), (c), (d) 为线性退化。



(a)


(b)

(c)

(d)

由退化模型可以得到

$$g = Hf + n \Rightarrow n = g - Hf$$



在频域表示为

$$G(u, v) = H(u, v) \cdot F(u, v) + N(u, v)$$

当 n 未知时, 希望找到一个 f 的估计 $\hat{f}$, 使得 $H\hat{f}$ 在最小平方意义上近似于 g

即使得 $\|n\|^2 = \|g - H\hat{f}\|^2$ 为最小。

基本原理

$$\hat{f} = H^{-1}g$$

$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)}$$

逆滤波中讨论 $\hat{F}(u, v), G(u, v), H(u, v)$ 的求解方法，也称反向滤波，是一种无约束复原。

可利用矩阵运算解决复原问题；但分块循环矩阵H较大，计算量大。将其对角化后的运算较为简单

当考虑噪声时（前面的讨论未考虑噪声）

$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)} = F(u, v) + \frac{N(u, v)}{H(u, v)}$$

问题1：

$N(u, v)$ 为随机噪声，其傅里叶变换未知。所以，即使已知退化函数 $H(u, v)$ ，也不能准确复原未退化的原始图像。

因此要准确复原图像需要增加约束条件

问题2：如果 $H(u, v)$ 很小或为0，则导致复原结果不稳定；且 $N(u, v)/H(u, v)$ 值过大，掩盖真实信号 $F(u, v)$ ，使复原图像失真

⇒实际中的确存在这种情况：

$H(u, v)$ 随 u, v 与原点距离增加而迅速减小，而噪声 $N(u, v)$ 却变化缓慢。

必须采取一种折衷方法解决 $H(u, v)$ 零点问题

9.2.2 Eliminate linear uniform motion blur

本小节以运动模糊为例，讨论如何估计 $H(u, v)$

运动模糊模型

获取图像时，由于景物和摄像机之间相对运动，往往造成图像模糊。

- 假设图像 $f(x, y)$ 有一个平面运动；
- $x_0(t), y_0(t)$ 为 x, y 方向上的变化分量；
- 记录介质的总曝光量是在快门打开到关闭这段时间 T 的积分， $g(x, y)$ 为模糊图像

在无约束图像复原中，只要已知退化函数即可进行图像复原。

但是实际图像存在噪声！！

前节提到，在考虑噪声的情况下，存在2个问题：

随机噪声未知； 零点问题

$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)} = F(u, v) + \frac{N(u, v)}{H(u, v)}$$

有约束复原

有约束复原，是指除了已知退化系统传递函数外，还要根据其
其他条件作为约束：

- 噪声统计特性，或
- 噪声与图像的相关信息进行复原

寻找一个 $\hat{f}$ ，使下述准则函数为最小

$$L(\hat{f}) = \|Q \hat{f}\|^2 + \lambda (\|g - H \hat{f}\|^2 - \|n\|^2)$$

其中，常数 λ 为拉格朗日系数。

用已知原始图像的某种变换性质 Qf ，
作为一种附加的约束，或者 $Qf = d$


1. 复原特性

该复原方法是建立在认为图像和噪声是随机过程的基础上，目标是找一个未模糊图像 f 的估计 $\hat{f}$ ，并且

⇒能够使两者之间的均方误差为最小

$$e^2 = E\{(f - \hat{f})^2\} \quad \text{即有约束复原}$$

$E\{\bullet\}$ 表示期望值。



即 维纳滤波器

前面讨论的逆滤波，没有很好地解决如何处理噪声的问题。

维纳滤波器

假定噪声和图像不相关，误差度量由下式给出

$$e^2 = E\{(f - \hat{f})^2\}$$

其中 $\hat{f} = [H^T H + sQ^T Q]^{-1} H^T g$

定义： $Q^T Q = R_f^{-1} R_n$

其中， R_f, R_n 分别是原始图像和噪声的相关矩阵

实现方法

寻找一种准则函数，由此导出的复原对每一幅具体图像确定一个最优的评判标准

是不是有点像
离散KL变换？

(1) 确定最大平滑测度准则

在逆滤波中，由于 $H(u, v)$ 的病态性质，导致在其零点附近数值变化起伏过大，产生多余噪声和边缘，会造成图像严重失真，



(2) 最大平滑算法

图像相邻像素间平滑性可通过二阶导数表征

➤ 二阶导数小，灰度跳变小，图像平滑

所以可作为图像复原时的约束条件 Qf

二阶导数可用拉普拉斯算子表示，
即
$$\left(\frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2}\right) f$$

对于数字图像可写成差分形式

$$\left(\frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2}\right) f = 4f(x, y) - [f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1)]$$


定义准则为

$$E = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} \|C \cdot f\|^2$$

同时定义 $Q = C \Rightarrow Q \cdot f = C \cdot f$ **可得最优解**

问题变成了在满足条件 $\|n\|^2 = \|g - H \hat{f}\|^2$

使 $E = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} \|C \cdot \hat{f}\|^2$ 最小，即最大平滑约束




称为有约束最小平方复原

在实际图像采集处理过程中，像素间空间位置关系会发生变化 → 需要进行几何失真校正

处理步骤

- (1) 空间变换：对图像平面上的像素重新排列，以恢复原有的空间关系。
- (2) 灰度插值：对空间变换后的像素赋予相应的灰度值，以恢复原位置的灰度值。



预祝同学们期末考试取得好成绩！