

数字图像处理

Digital Image Processing

第3讲 图像特征点检测

Feature point detection



清华大学电子系 王生进



3.1 特征点检测概述

3.2 Harris角点检测


3.3 主动轮廓模型与主动形状模型

3.4 基于深度学习的人脸关键点检测

- 图像特征点检测，是计算机视觉、图像分析与物体检测和识别的基础，它是将高维的图像数据进行简化表达最有效的方式
- 点特征主要指图像中的明显点，如突出的角点、边缘端点、极值点等
- 从一幅图像的的数据矩阵中，机器看不出任何信息，所以需要根据这些数据提取出图像中的关键、不变信息



- **局部特征**点是图像特征的局部表达，它反映图像上具有的局部特殊性，所以它适合于对图像局部进行匹配应用。
- **全局特征**易受环境的干扰，光照、旋转、噪声等不利因素都会影响全局特征。相比而言，局部特征点受到的干扰少。



局部匹配


区域匹配

全局匹配

- 通常，局部极值点（斑点）、极值区域与角点是三类局部特征点。
- 局部极值点通常是指与周围有着颜色和灰度差别的稳定点或区域，如后面要讲的SIFT特征点、MSER（最大稳定极值区域）。
- 而角点则是图像中一边物体的拐角或者线条间的交叉部分。



Darker MSERs



- **SIFT**算法 [1999, 2004]

SIFT 算法(Scale-invariant Feature Transform)

由University of British Columbia的David Lowe在1999年提出，并在2004改进。

- **Harris Corner Detector** [1988, 1992]

- Wide-baseline stereo, Long-range tracking [Torr 1995, Zhang 1995], Object recognition [Schmid 1997]

- **SUSAN** (Smallest Univalued Segment Assimilating Nucleus) 角点检测 [Smith S M 1997]


- **SIFT** [Lowe 1999]

- Object recognition, multi-view geometry, ...






- **MSER** (Maximally Stable Extremal) [Matas 2002]

- **SURF**算法 [2006, 2008]

- SURF 全称 speed up robust feature ，加速稳健特征），是加速版的SIFT。
- 最初由Herbert Bay发表在2006年欧洲计算机视觉国际会议（European Conference on Computer Vision, ECCV），并在2008年发表在Computer Vision and Image Understanding期刊上。



应用场景：刚体目标检测



3.1 特征点检测概述

3.2 Harris角点检测


3.3 主动轮廓模型与主动形状模型

3.4 基于深度学习的人脸关键点检测

1. Harris角点特征

► 在图像匹配和识别中，**角点是一个有效的特征点**。角点易在图像中定位局部特征，并且大量存在于人造物体中（例如墙壁、门、窗户、桌子等）。


算法核心，是利用局部窗口在图像上进行移动，判断灰度是否发生较大变化。如果窗口内的灰度值（在梯度图上）都有较大的变化，那么这个窗口所在区域就存在角点



2、Harris角点特征检测的步骤

Harris 角点检测算法分为以下三步

- (1) 当窗口（局部区域）同时向 x （水平）和 y （垂直）两个方向移动时，计算窗口内部的像素值变化量 $E(x,y)$
- (2) 对于每个窗口，都计算其对应的一个角点响应函数 R
- (3) 然后对该函数进行阈值处理，如果 $R > \text{threshold}$ ，表示该窗口对应一个角点特征。



第一步 建立数学模型

首先确定哪些窗口会引起较大灰度值变化。让一个窗口的中心位于灰度图像的一个位置，然后该窗口沿各方向移动一个小的位移到一个新位置，计算位置的窗口移动引起的灰度值变化。窗口函数表示窗口内各像素权重，可设所有像素的权重为1，也可以窗口中心为原点的高斯分布。如果窗口中心点像素是角点，那么窗口移动前后，中心点的灰度值变化非常强烈。

将图像窗口平移 $[u,v]$ 产生灰度变化 $E(u,v)$

$$E(u,v) = \sum_{x,y} w(x,y) [I(x+u, y+v) - I(x,y)]^2$$

3 窗口函数 2 平移后的图像灰度 1 图像灰度

4 窗口函数 $w(x,y) =$

1 in window, 0 outside 或 Gaussian

The diagram illustrates the mathematical model for edge detection. It shows the equation for gray度 change $E(u,v)$ and two types of window functions: a rectangular function (1 in window, 0 outside) and a Gaussian function.

为提高计算效率，对上述公式进行简化，利用泰勒级数展开，得到该公式的近似形式：

$$I(x + u, y + v) = I(x, y) + uI_x + vI_y$$

$$E(u, v) = \sum_{(x,y)} w(x, y) \times [I(x, y) + uI_x + vI_y - I(x, y)]^2$$

$$= \sum_{(x,y)} w(x, y) \times (uI_x + vI_y)^2$$

图像梯度出现

$$= \sum_{(x,y)} w(x, y) \times (u^2 I_x^2 + v^2 I_y^2 + 2uv I_x I_y)$$

得到最终的近似形式： $E(u, v) \approx [u, v] M \begin{bmatrix} u \\ v \end{bmatrix}$

$$\text{其中 } M = \sum_{(x,y)} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \rightarrow R^{-1} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} R$$

实对称矩阵对角化后结果，可把R看为旋转因子，不影响两个正交方向的变化分量¹³

第二步 角点响应函数R

至此已得灰度变化的最终形式E，目的是要找到引起较大灰度值变化的窗口。灰度值变化的大小则取决于矩阵M，为梯度的协方差矩阵。实际中定义一个角点响应函数R，通过判定其大小来判断像素是否为角点。

计算每个窗口对应的得分（角点响应函数R定义）：

$$R = \det(M) - k(\text{trace}(M))^2$$

$$\text{其中 } \det(M) = \lambda_1 \lambda_2 \quad \text{trace}(M) = \lambda_1 + \lambda_2$$

矩阵的特征值，是一个经验常数，在范围 (0.04, 0.06) 之间

R 值取决于的特征值，对于角点很大，平坦的区域很小，边缘的为负值。


第三步 角点判定

根据R值，可判定窗口所在区域划分为平面、边缘或角点。因为特征值决定了R值，所以可以用特征值来决定

•**平面**：窗口在平坦区域滑动，窗口内灰度值基本不发生变化，值很小，在水平和竖直方向的变化量均较小，即特征值都较小

•**边缘**：R值为负数，仅在水平或竖直方向有较大的变化量，特征值只有一个较大

•**角点**：R值大，在水平、竖直两方向上变化均较大，即特征值都较大，也即R值大



Harris角点特征提取算法步骤

```
1      # 14.19 角点检测之 Harris 算法
2      img = cv2.imread("../images/Chess01.png", flags=1)
3      gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY) # (600, 540)
4      # gray = np.float32(gray) # uint8, float32 都支持
5
6      blockSize = [2, 3, 5] # 滑动窗口大小
7      ksize = [3, 5, 9] # Sobel 核函数大小
8      plt.figure(figsize=(9, 9))
9      for i in range(len(blockSize)):
10         for j in range(len(ksize)):
11             dst = cv2.cornerHarris(gray, blockSize[i], ksize[j], k=0.04)
12             imgCorner = np.copy(img)
13             imgCorner[dst > 0.01*dst.max()] = [0, 0, 255] # 筛选角点, 红色标记
14             plt.subplot(3,3,i*len(ksize)+j+1), plt.axis('off')
15             plt.imshow(cv2.cvtColor(imgCorner, cv2.COLOR_BGR2RGB))
16             plt.title("blockSize={},ksize={}".format(blockSize[i], ksize[j]))
17
18     plt.tight_layout()
19     plt.show()
```

3. Harris角点检测的性质

(1) 阈值决定角点的数量

算子对亮度和对比度变化不敏感（光照不变性）。Harris角点检测使用了微分算子对图像做微分，而微分运算对图像密度的拉升或收缩和对亮度的增加或减少不敏感。即，对亮度和对比度的仿射变换并不改变Harris响应的极值点出现的位置，但由于阈值选择，会影响角点检测数量


(2) Harris角点检测算子具有旋转不变性

算子使用的是角点附近的区域灰度二阶矩矩阵。而二阶矩矩阵可表示成一个椭圆，椭圆的长短轴正是二阶矩矩阵特征值平方根的倒数。当特征椭圆转动时，特征值并不发生变化，所以判断角点响应值也不发生变化，由此说明Harris角点检测算子具有旋转不变性。

(3) Harris角点检测算子不具有尺度不变性

尺度的变化会将角点变为边缘，或者边缘变为角点，Harris的理论基础并不具有尺度不变性。

4. Harris角点特征提取实验示例









- 3. 1 特征点检测概述
- 3. 2 Harris角点检测
- 3. 3 主动轮廓模型与主动形状模型
- 3. 4 基于深度学习的人脸关键点检测

关键点定位是诸多CV任务和应用的基础技术。

以人脸为例，心理学研究表明，眼睛、嘴等器官在人脸面部状态感知过程中起着重要作用，其中眼睛的作用尤为重要。

器官定位也是人脸识别和人机交互中一个重要步骤。人机交互研究，如表情理解、表情合成等，都需要先进行眼睛、嘴的定位




1、传统关键点定位方法

- 基于灰度及关键点先验知识结构特征：
 - 对称性检测、谷点检测等。投影方法（脸部灰度投影+波峰波谷分析等） [H. Zhou, PR 2004](#)



- 模板匹配法（各种匹配滤波器如局部对称算子、Hough变换、DoG算子法，变形模板法） [Yali Li, PRL2010](#)



常用关键点定位方法

- 基于Active Contour Model (ACM, 主动轮廓模型, Snake)
- 基于Active Shape Model (ASM, 主动形状模型)
- 基于Active Appearance Model (AAM, 主动表观模型)
- 基于样本学习法 (如Eigeneye, Eigennose等方法)
F.Smeraldi, PRL 2002
- SDM方法, 深度学习方法DCNN (cvpr2013)

2、主动轮廓模型 (ACM , snake)

- 由图像特征如边缘、直线，改变一条闭合曲线的形状，使其收敛到物体的边缘位置
- 围线的形状变化由两种因素控制：

一是曲线形状，称为内力 (internal force)，内力改变围线形状，


$$\begin{aligned} E_{\text{int}} &= [\alpha(s) |\mathbf{v}'(s)|^2 + \beta(s) |\mathbf{v}''(s)|^2] / 2 \\ &= (\alpha_i \|v_i - v_{i-1}\|^2 + \beta_i \|2v_i - v_{i-1} - v_{i+1}\|^2) / 2 \end{aligned}$$

二是图像特征，称为外力 (external force)：外力使围线收敛到图像的特征位置，如边缘等，例如定义为灰度梯度


$$E_{\text{ext}}(v(s)) = -|\nabla I(v(s))|^2$$

- 能量的最小值对应的围线就是最后的求解结果


$$E_{\text{snake}}(\mathbf{v}) = \sum_{i=1}^n [w_i E_{\text{int}}(\mathbf{v}(s)) + (1 - w_i) E_{\text{ext}}(\mathbf{v}(s))]$$




(a)



(b)



(c)




(d)

3、主动形状模型（ASM）

ACM容易陷入局部极值点。ASM 利用参数化的采样形状，构成对象形状模型

(1) 形状建模

- 样本归一化
 - 中心归一化
 - 尺度归一化
 - 角度归一化
- PCA建模
 - 由统计学习样本，建立描述形状的控制点的运动模型



样本

归一化

轮廓点的 PCA 建模:

- 标记样本 $A = [s_1, s_2, s_3, s_4, \dots, s_N]$

- 均值 $\bar{s} = \frac{1}{N} \sum_{i=1}^N s_i$

- 协方差 $R = \sum_{i=1}^N (s_i - \bar{s})(s_i - \bar{s})^T$

- 特征模型 $u_i R = \lambda_i R, \quad u_i^T \cdot u_j = 0$
($\lambda_1 > \lambda_2 > \lambda_3 > \dots > \lambda_m > 0$)

轮廓点的 PCA建模:

$$\bar{s} + u_1 \Delta c$$

$$\bar{s} + u_2 \Delta c$$

$$\bar{s} + u_3 \Delta c$$

$$\bar{s} + u_4 \Delta c$$


$$X = \bar{S} + U \cdot c$$



其中, $\bar{S}$ 是均值向量, U 是基向量, C 是参数矩阵

(2) 灰度分布建模

考虑到标记点周围环境的复杂性，Tim Cootes 后来引进了局部灰度分布模型^{[1][2]}，从训练图像中每个标定点点沿轮廓法线方向采样灰度，以获得标定点点附近的典型局部灰度分布模型 $f(p)$



[1] T.F.Cootes, C.J.Taylor, Active Shape Models - 'Smart Snakes'. in Proc. British Machine Vision Conference. Springer-Verlag, 1992, pp.266-275.

[2] T.F.Cootes, C.J.Taylor, Active Shape Model Search using Local Grey-Level Models: A Quantitative Evaluation, in Proc. British Machine Vision Conference, (Ed. J. Illingworth), BMVA Press, 1993, pp.639-648.

➤ 局部纹理模型（即梯度分布）

在训练阶段从数据集中统计得到。在模型学习阶段则用来进行 Landmarks 位置的自动更新。即，对 p 点 Profile 邻域内的每个候选点 s ，都计算其局部纹理采样 g_s 与训练集合中 p 点局部纹理分布之间的马氏距离，该距离最小的候选点 p^* 作为新的特征点。




图 3.1 局部纹理模型图示

Fig. 3.1 Profile model for each landmark

➤ 对 p 点Profile邻域内的每个候选点 s ，都计算其局部纹理采样 g_s 与训练集合中 p 点局部纹理分布之间的**马氏距离**，该距离最小的候选点 p^* 作为新的特征点。

S_g 为样本协方差矩阵

$\bar{f}_p$ 为样本均值向量

$$f(g_s) = (g_s - \bar{f}_p)^T S_g^{-1} (g_s - \bar{f}_p)$$




图 3.1 局部纹理模型图示

Fig. 3.1 Profile model for each landmark

若协方差矩阵为单位阵，则马氏距离简化为欧式距离

➤ 调整变换参数，使轮廓线上所有对应的Landmarks点与新的特征点 p^* 具有最小均方误差 $\left| X' - T_{X_t, Y_t, s, \theta} (\bar{s} + Uc) \right|^2$

(3) ASM 算法步骤

- 对于图像中每个标记点 X_i ，在其轮廓法向邻域中寻找最优点 X'_i (马氏距离最小)；
- 更新当前的 (X_t, Y_t, s, θ, c) ，获取最优表征参数，即满足下式2组点群间距离最小：


$$\left| X' - T_{X_t, Y_t, s, \theta}(\bar{s} + Uc) \right|^2$$

- 重复1，直至收敛（两次叠代最优点误差足够小）。

ASM形状模型实验结果



<https://blog.csdn.net/shiyongraow>




- 3. 1 特征点检测概述
- 3. 2 Harris角点检测
- 3. 3 主动轮廓模型与主动形状模型
- 3. 4 基于深度学习的人脸关键点检测

1、DCNN (CVPR2013)

- 一种从粗到精的定位思想

《Deep Convolutional Network Cascade for Facial Point Detection》, CVPR2013

RCNN回顾: RCNN也是一种从粗定位, 到精识别的过程, 跟本篇paper的思想很相似



DCNN (CVPR2013)

- 一种从粗到精的定位思想

(1) level 1


CNN模型的输入为人脸矩形框，输出为五个特征点的估计位置，然后预测出新的bounding box，level 1由3个CNN组成，3个CNN都包含了9层。Level-1的输出由三个CNN输出取平均得到

Level 1的输入图像




(1) level 1

CNN模型的输入为人脸矩形框，输出为**五个特征点估计位置**，然后预测出新的bounding box，level 1由3个CNN组成，3个CNN都包含了9层。Level-1的输出是由三个CNN输出取平均得到。



Level 1的输出图像

裁剪



输入区域分别为包含整张脸（F1），眼睛和鼻子（EN1），鼻子和嘴（EM1）

(2) level 2




Level 2的输出结果红色，蓝色GT

以第一层级预测到的5个预测特征点为中心，用一个较小的bbox，预测出**5个特征点初始位置**，然后重新裁剪小矩形区域。level 2 由10个CNN组成。一对CNN对一个关键点进行预测，预测结果同样是采取平均。





Level 2输出的裁剪小矩形结果作为Level 3的输入



(3) level 3

level3进行精定位，分别设计5对CNN模型（实际是用了10个CNN，每两个组成一对。一个CNN只定位1个特征点，一个特征点包含了(x, y)两维），各个部位的CNN模型参数不共享，用于分别定位5个点。



部分定位实验结果



1. 讨论题（不需要交）

进一步阅读和学习多种图像特征点检测算法原理

2. 准备本课程布置的上机作业——project，分阶段提交调研报告，算法方案设计，中间结果，最终报告。