


数字图像处理

Digital Image Processing

第4讲 物体检测

Object Detection



清华大学电子系 王生进

4.1 计算机视觉基本任务之一

4.2 运动物体检测

4.3 统计学习物体检测

4.4 深度学习物体检测



YOLOv8: 一种 One-Stage、Anchor-Free 的目标检测算法

➤ 物体检测是计算机视觉的基本任务之一

计算机视觉解决什么问题

人能够理解图像中的场景。不仅是检测到图像中有四个人、一条街道和几辆车。除了这些信息，人还能够推断出图中人物没有被车撞击的危险，白色的大众汽车没有停好。人类还可以描述图中人物的穿着，不止是衣服颜色，还有材质与纹理。



➤ 物体检测是计算机视觉的基本任务之一

典型的计算机视觉任务

图像分类

匹配问题


物体检测

物体识别


目标跟踪

图像分割

语义描述



图源: <https://cdn.pariscityvision.com/media/wysiwyg/tour-eiffel.jpg>



4.1 计算机视觉的基本任务之一

物体检测（目标检测）、识别与跟踪技术涉及计算机视觉的特征提取技术，模式识别技术，及目标跟踪等多个图像处理领域的关键技术

物体检测、识别与跟踪技术涵盖了公共安全，人机交互，军事技术，工业自动化，娱乐等多个重要应用领域。

对应背景


输入图像



检测结果



- 物体检测






- 物体跟踪



跟踪：给定目标当前时刻的信息（Location + Appearance），估计下一时刻该目标的位置

- 医学图像病变检测



物体检测，是计算视觉中的关键技术

主要应用领域

- 智能视频安防(公共安全和重点场景)
- 虚拟现实、人机交互
- 机器人、无人汽车
- 图像视频检测、网络富媒体分析
- 军事国防 (卫星侦察与武器制导)
- 医学图像和生物医学



• 虚拟现实、人机交互

- 人脸检测与面部状态识别
- 姿势估计与动作识别
- 手势识别



• 智能视频分析

- 侵入目标的自动检测和报警
- 生物特征识别、人脸识别
- 行为识别、异常检测



• 机器人

- 机器视觉物体检测
- 物体实例分割、姿态估计
- 物体抓取关键点检测



- **运动目标检测：** 具有运动信息
- **类目标检测：** 例如，人脸、汽车等
 - 可获得大量图像样本
 - 利用离线学习训练类别分类检测器
- **特定刚体目标检测；** 某建筑物，确定的车辆
 - 仅有少量样本的典型目标
 - 特征提取与图像匹配方法，仿射变换
- **特定可变形目标检测：** 某个人脸, 行人ReID
 - 仅有少量样本，目标表象发生时变



➤文字

从图像中提取、切分、识别文字，从而理解文本所要表达的内容信息

➤人体生物特征（如人脸、虹膜、指纹和掌纹等）

采集生物特征图像，进行认证，识别人物ID

➤人脸

对一段图像序列观测，检测出这一段图像序列中的主要人物。例如，对于影视和新闻，我们可以表达主人公或新闻人物；对于智能视频安防，可以发现需要查找的人物

➤车辆（含车牌）

分析其行驶状态，根据行驶状态，判断车辆是否违章，或是否发生交通事故

➤行人（行人再识别 ReID）

检测行人出现，分析和识别动作，进而表达ID信息

● 物体检测所面对的瓶颈问题

物体检测是当前计算机视觉和机器学习领域的研究热点和前沿课题，众多国际期刊和国际会议都将其列为重要内容。目前仍然诸多问题未解决

- 目标类内差异大
- 视角变化
- 方位、尺度变化
- 遮挡与截断
- 复杂背景干扰



● 物体检测所面对的瓶颈问题

目标类内差异大



● 物体检测所面对的实际问题

视角变化多



● 物体检测所面对的实际问题

方位、尺度变化



● 物体检测所面对的实际问题

遮挡与截断





● 物体检测所面对的实际问题

复杂背景干扰



人脸检测






$(-78^\circ, 52^\circ)$ $(-31^\circ, -11^\circ)$ $(12^\circ, -27^\circ)$ $(52^\circ, 11^\circ)$ $(0^\circ, 23^\circ)$

获ECCV2018无人机目标检测赛道挑战赛冠军



Tsinghua

Yali Li, Jianqiang Wang, Zhaoyue Xia, Shengjin Wang, HAL-Retina-Net: Hybrid attention based low-resolution retina-net, 2018



➤ 2018年11月，实验室在国际权威测试集KITTI上刷新国际最高水平

	Method	Setting	Code	<u>Moderate</u>	Easy	Hard	Runtime
1	<u>THU CV-AI</u>			91.97 %	91.96 %	84.57 %	0.38 s
2	<u>DH-ARI</u>			91.48 %	90.87 %	82.25 %	4s
3	<u>HRI-SH</u>			90.71 %	91.34 %	84.28 %	3.6 s
4	<u>BM-NET</u>			90.50 %	90.81 %	83.92 %	0.5 s
5	<u>MVRA</u>			90.36 %	90.78 %	80.48 %	0.18 s
6	<u>TuSimple</u>		<u>code</u>	90.33 %	90.77 %	82.86 %	1.6 s



物体检测主要方法:

- 按特征不同分为:

- (1) 运动目标检测

- (背景建模+前景检测)

- (2) 刚性目标模型




- (模板匹配, 特征点匹配)

- (3) 基于统计学习的目标检测

- (AdaBoost)

- (4) 深度学习目标检测

- (5) 深度学习实例分割



物体检测的过去、现在和未来



- 从目标状态上分：基于运动信息，基于表观信息
- 从特征提取上分：颜色，SIFT，HoG，Haar，CNN
- 从分类器上分：SVM，AdaBoost，CNN
- 从检测阶段分：One-S:YOLO，SSD，Two-S:Fast RCNN
- 从检测结果分：Bbox检测，Mask RCNN，实例分割

物体检测的过去、现在和未来



算法发展



YOLOv8: 一种 One-Stage、Anchor-Free 的目标检测算法


4. 1 计算机视觉基本任务之一

4. 2 运动物体检测

4. 3 统计学习物体检测

4. 4 深度学习物体检测

运动信息作为目标的一类特征，是目标检测中的一个重要研究内容。



- 物体与相机的关系

根据摄像头数量及摄像头静止与否，可将对应的采集摄像头分为静止单摄像头、运动单摄像头、静止多摄像头和运动多摄像头。（本课讲静止单）

- 背景建模与前景提取

检测对象是场景中的运动物体，因此对视频采集的图像序列进行背景建模和前景检测，区分图像中的前景和背景，将前景物体从背景中分割出来。

- 运动目标跟踪
- 目标识别与分类
- 目标定位与轨迹分析
- 行为识别



利用视频图像进行前景检测，常用的有背景法和帧差法。实质是把序列图像的运动目标检测问题转化为一个二分类问题，将所有像素分为背景和运动前景两类

利用背景进行前景检测，
→ 将当前帧图像与对应的背景相减，
→ 在差值图像中提取前景。



该方法称为背景法 (Background subtraction)

➤ 背景法，可以解决帧差法不能检测运动停止或缓慢运动物体的缺陷；

➤ 背景法相对帧差法，背景法更加稳定、鲁棒。但要求背景必须随时间更新；

因此，目前的运动目标检测，较多都采用背景法。



1、像素累积平均法背景建模

- 利用N帧图像的平均来求取背景 $BK(n) = \sum_{i=n-N}^{i=n-1} I(i) / N$
- 背景的更新:

获得初始背景图像后，需不断更新，以保证背景图像的变化可跟上当前输入图像中光照等外界因素的变化。

使用当前检测结果作为更新依据，在前景检测区域内的像素点不作更新，被认为是背景的像素则更新。

$$B_A(k+1) = \begin{cases} (1-\alpha)B_A(k) + \alpha I_A(k), & A \text{ 不是物体像素点} \\ B_A(k), & A \text{ 是物体像素点} \end{cases}$$


α 更新率由实验确定，一般取0.2


2、基于高斯模型的背景建模

高斯分布背景模型分单高斯和混合高斯。单高斯适用于单模态背景情形；混合高斯用于变化背景。

即对一个背景图像，像素亮度的分布满足高斯分布，如对背景图像 **B**，每个 **(x, y)** 点的像素灰度值满足高斯分布 $\beta(x, \mu_t, \sigma_t)$ ，则可建立高斯模型。

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$





示意图： 实际场景中某个背景像素点的颜色变化曲线。
下图左上角小圆圈的圆心是观测点。

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

背景模型中每个像素有2个参数：均值 μ 和方差 σ
可通过统计一段时间内该像素值的变化获得。

►对像素属性的判别：

对于一幅 t 时刻图像 I ，如果


$$e^{-\frac{[I_t(x,y)-\mu_t(x,y)]^2}{2\sigma_t(x,y)^2}} > T$$

则认为 (x,y) 是背景点，反之是前景点。

T 为分割阈值。

➤更新模型参数

在实际场景中，随着时间的变化，背景图像也会发生缓慢的变化，如不同时间段的光照变化等。



因此，需要不断更新每个像素点的模型参数。



day



night

每一个高斯分布背景模型的更新，是指各图像点高斯分布参数的更新。

引入表示更新快慢的常数——**更新率 α** ，则该点高斯分布参数的更新可表示为

~~$$\mu_{t+1}(x, y) = (1 - \alpha)\mu_t(x, y) + \alpha[I_t(x, y) - \mu_t(x, y)]$$~~

$$\mu_{t+1}(x, y) = (1 - \alpha)\mu_t(x, y) + \alpha \cdot I_t(x, y)$$

$$\sigma_{t+1}(x, y) = (1 - \alpha)\sigma_t(x, y) + \alpha[I_t(x, y) - \mu_t(x, y)]^2$$

α 表示背景变化的速度。一般情况下，可以不更新 **σ** （实验表明更新 **σ** 与否，效果变化不大）

场景图像



背景建模结果



实例演示 Demo



➤ 背景建模的研究现状

- 背景建模经典算法：
 - GMM（混合高斯模型）
 - CodeBook
 - KDE（核密度估计）
 - ViBe（2012）
 - PBAS及其改进
Pixel-Based Adaptive Segmenter
- 背景建模优秀算法大多集中在2004年之前，但现在仍有很多优秀的机构进行相关研究，近几年，CVPR，PAMI等高水平会议和期刊是仍能看到背景建模的文章。
- IEEE workshop on change detection in conjunction with CVPR 2012

3、差值法前景目标提取

前景目标，是指场景中与背景不同的目标部分。当摄像头静止时，固定不动的场景一般是背景，运动对象是前景目标

前景目标检测的目的是获取正确的前景物体，
不希望检测结果中出现大量的离散像素点，
也不希望部分前景像素点被误检为背景。

前景目标的精确提取是一个难点，光线干扰，阴影干扰，会使得前景获取准确性受到影响。为此，必须尽可能好地消除干扰，获取准确的前景物体。

➤ 前景目标提取方法

• 差值法

- 计算图像与背景差值，再采用聚类和后处理算法消除噪声，获取前景区域
- 相关文献：Haritaoglu 2000, Elgammal 1999, Durucan 2001
- 对环境噪声敏感，与背景颜色相近的前景点容易被检测为背景

• Snake算法

- 围线的形状变化由两种因素控制，一是曲线的形状，称为内力；二是图像的特征，称为外力。内力改变围线形状，而外力使围线收敛到图像的某些特殊位置，如直线、边缘，进而求得前景像素点

(1) 差值法前景点提取


提取背景，采用背景差法。即使用当前帧图像 $I(t)$ 和背景图像 $B(t)$ 的差值，得到前景区域获得目标： $F(t)=I(t) - B(t)$




(a) 背景图像



(b) 输入图像



(c) 前景点
(阈值=15)






(d) 前景点 (阈值=30)

差值大于给定阈值的点设为前景点，用白色显示，其他点为背景点。

(2) 基于连通域的目标提取

- 对前景目标像素点进行处理：删除干扰噪声像素点，通过膨胀或腐蚀等方法，使目标前景点能较好地聚合；
- 搜索连通域种子，确定连通区域，判断是否符合前景；
- 确定前景像素块，获得矩形围线，得到运动目标参数（中心位置、上下边界）






(a) 输入图像

(b) 未加入后处理的结果

(c) 最终的检测结果

示意图：文献[1]的前景检测结果。图（b）中未对噪声点作处理，大量的离散点被检测为前景。图（c）采用聚类等后处理，噪声点数量已大大减少，但仍然存在，并有大量前景点被误检为背景。

[1] Elgammal A, Harwood D, and Davis L. Non-parametric model for background subtraction. European Conference on Computer Vision, 2000, 751-757.



示意图：CMU的VASM系统的前景聚类结果[2]，左图为输入图像，右图为检测结果，前景区域已经聚为两块，分别对应两个物体，图中相当多的物体像素点被检为背景。

[2] Collins R T, Lipton A J, Kanade T, et. al. System for video surveillance and monitoring. Technical Report, Carnegie Mellon University, the Robotics Institute, 2000. 43

4、动态轮廓法目标提取 (ACM, snake)

- 由图像特征如边缘、直线，改变一条闭合曲线的形状，使其收敛到物体的边缘位置
- 围线的形状变化由两种因素控制：
 - (1) 曲线形状（曲率），称为内力 (internal force)，内力改变围线形状，由计算边缘点的一次、二次导数获得：


$$\begin{aligned} E_{\text{int}} &= [\alpha(s) |\mathbf{v}'(s)|^2 + \beta(s) |\mathbf{v}''(s)|^2] / 2 \\ &= (\alpha_i \| \mathbf{v}_i - \mathbf{v}_{i-1} \|^2 + \beta_i \| 2\mathbf{v}_i - \mathbf{v}_{i-1} - \mathbf{v}_{i+1} \|^2) / 2 \end{aligned}$$

(2) 图像特征（梯度），称为外力 (external force), 外力使围线收敛到图像的特征位置，如边缘等。通常，定义为沿边缘点垂直方向的灰度梯度：


$$E_{\text{ext}}(\mathbf{v}(s)) = -|\nabla I(\mathbf{v}(s))|^2$$

➤ 能量的最小值，对应的围线就是最后的求解结果


$$E_{\text{snake}}(\mathbf{v}) = \sum_{i=1}^n [w_i E_{\text{int}}(\mathbf{v}(s)) + (1 - w_i) E_{\text{ext}}(\mathbf{v}(s))]$$




(a)



(b)



(c)



(d)

轮廓法前景检测结果



(a) 输入差值图像



(b) 前景检测结果 ($E=10$)



(c) 前景检测结果 ($E=25$)



(d) 自适应检测结果 ($E=17$)

改进snake法
前景检测结果

轮廓法前景检测结果



输入彩色图像



对应背景




差值图像



高于给定阈值的像素点



轮廓围线



最终的前景轮廓和像素点


运动物体检测实例——室外侵入检测



- 4. 1 计算机视觉基本任务之一
- 4. 2 运动物体检测
- 4. 3 统计学习物体检测
- 4. 4 深度学习物体检测

对物体检测和跟踪问题，可将视频目标分为2大类型：**类别目标、特定目标。**


对于类别目标（例如，人脸和汽车等），通常可以预先收集大量的相关图像样本）。然后采用统计学习方法，离线训练目标的类别检测器，



物体检测问题的目标分为2大类型：类别目标、特定目标

对于类别目标（例如，人脸和汽车等），通常可以预先收集大量的相关图像样本）。然后采用统计学习方法，离线训练目标的类别检测器，典型的方法有PCA、AdaBoost、SVM等

针对特定目标，预先没有大量样本用于离线学习的情况，因此需要采用特征提取的方法，如模板法，SIFT特征法。



1、基于PCA的物体检测

统计学习物体检测的典型的方法有PCA、AdaBoost、SVM等


在类目标识别中，可以将主成分分析（PCA）析用于类别目标表象图像的检测与识别问题。

- ◆ PCA分析的最大特点是去相关性好。

可以在 N 维特征向量中，提取 K 个主要特征， $K \ll N$ 。

K 个主要特征具有独立描述图像的性能。

- ◆ 获得 K 个具有较强分类能力的特征；
且因为特征个数减少，可降低算法复杂度。



➤ 基于PCA的人脸检测与人脸识别

以人脸检测为例，介绍PCA类目标检测算法

对人脸图像 $f(x,y)$ ，图像中的像素可以用 b_{ij} 表示

一幅 $N \times N$ 的人脸图像按列相连，构成一个 N^2 维向量：



$$\mathbf{x} = (b_{11} \ b_{21} \ b_{31} \ \dots b_{N1} \ b_{12} \ b_{22} \ \dots b_{N2} \ \dots b_{1N} \ b_{2N} \ \dots b_{NN})$$

可将其视为 N^2 维空间中的一个点

(1) 图像的归一化处理

由于PCA变换本质上依赖于图像灰度在空间分布上的相关性，因此，需要对图像在位置和灰度上进行归一化校准。

- 图像旋转：转正图像
- 图像裁减：保留公共的人脸区域
- 图像缩放：所有样本具有同样尺寸



获得人脸表示几何不变性，消除头发和背景干扰

图像的归一化处理结果



(2) PCA变换

以归一化后的标准图像作为训练样本集，计算协方差矩阵

$$C_x = E\{(\mathbf{x} - \mathbf{m}_x)(\mathbf{x} - \mathbf{m}_x)^T\} = \frac{1}{M} \sum_{k=1}^M (\mathbf{x} - \mathbf{m}_x)(\mathbf{x} - \mathbf{m}_x)^T$$

其中 $\mathbf{x}_k$ 为第 i 个训练样本图像向量， $\mathbf{m}_x$ 为训练样本集平均图像向量， M 为训练样本总数


可以采用构造降维矩阵方法,计算 $N^2 \times N^2$ 矩阵的特征值和特征向量，可降维为 $M \times M$

(3) 获得特征向量 u_i

通过计算获得特征值后，按降序排列，从大到小排列

$$\lambda_0 \geq \lambda_1 \geq \dots \geq \lambda_{M-1} \quad \lambda_i \text{ 为非零特征值}$$

其对应的特征向量为 u_i ，因此每一幅人脸图像都可以投影到由 $u_0, u_1, \dots, u_{M-1}$ 所构成的子空间中。




每一幅人脸图像对应于子空间中的一个点

(4) 特征脸 Eigenface

$u_0, u_1, \dots, u_{M-1}$ 对应的是作为基向量的图像。由于这些图像很像人脸，所以称之为特征脸 **Eigenface**（美国麻省理工学院（MIT）媒体实验室的特克（Turk）和潘特兰德（Pentland）提出）

[1]M. Turk and A. Pentland. Eigenfaces for recognition. *Journal of Cognitive Neuroscience*, 3 (1), 1991.

[2]M. A. Turk and A. P. Pentland. Face recognition using eigenfaces. In *Proc. of Computer Vision and Pattern Recognition*, pages 586-591. IEEE, June 1991.



通过PCA变换进行人脸识别的方法被称为“特征脸”法



$u_0, u_1, \dots, u_7$ 的特征脸

➤利用ORL人脸数据集（400张人脸图像）进行PCA训练，获得特征脸的基空间


前50个PCA基向量



(5) 基于特征脸的人脸检测

在特征脸构成的子空间中，任何一幅人脸图像都可以向其作投影，获得一组坐标系数

这组系数表明了该图像在子空间中的位置，从而可以作为人脸识别的依据



任何一幅人脸均可表示为这组特征脸的线性组合，其加权系数就是PCA变换的展开系数

(6) 待识别样本的检测和识别

对于任意一个待识别的样本 x ，可以通过向“特征脸”子空间投影求出其系数向量

$$y = A^T f$$

→ 可通过计算向量距离，判定待识别样本的属性，进行人脸识别


或者重建图像

$$\hat{f} = Ay$$

计算信噪比

$$R = 10 \lg \left(\frac{\|f\|^2}{\|f - \hat{f}\|^2} \right)$$

如果小于阈值 θ ，可判定 f 不是人脸






— 考虑信噪比 $R = 10 \lg \left(\frac{\| \mathbf{f} \|^2}{\| \mathbf{f} - \hat{\mathbf{f}} \|^2} \right)$ — 如果小于阈值 θ ,
说明重构噪声误差大,
可判定 $\mathbf{f}$ 不是人脸

实验表明，如果选取前 K 个特征向量构成特征脸空间

当 K 在一定范围内时，PCA对人脸模式的重构能力强
($K=6$ 最好)，误差的下降速度比非人脸模式的重构误差下降速度大。

特别地，当 K 增大到等于或 N^2 时，PCA 对所有图像都能完全重构，所以不管是人脸模式、非人脸模式，重构误差都为0。

人脸检测结果



2、基于Adaboost的目标检测方法

- AdaBoost算法是一种新的分类器融合方法，该算法可以将任意**略强于随机猜测的弱分类器**融合成为强分类器，并且操作简单、实用性强。
- **Viola2004**^[1]首先将AdaBoost应用于人脸检测，提出了一种基于AdaBoost算法的快速目标检测方法—**Boosting Cascade**方法。

[1] Viola P., Jones M. J., Robust Real-Time Face Detection, International Journal of Computer Vision 57(2), 137-154, 2004

Adaboost分类器可从场景中检测出人脸类别，提高检测效率



Adaboost算法源于一个赛马的故事


- 一个赛马的赌徒，为了使其赌赢的机会最大化，决定开发一个电脑程序，系统能通过分析一些比赛的常规数据。
- 为此，他向一位非常成功的赌马专家咨询他的赌马策略。
在向这位专家提供一些特定的比赛数据后，专家很容易就能得出一个针对这一系列比赛的一个优势策略（如押注在最近赢得最多的马匹身上，或者押注在最具有优势的马匹身上等）。
- 尽管这样得到的一个最优策略非常粗糙和不精确的，**但是不管怎么说，它始终还是要优于我们随机的猜测**。同时，通过反复向专家咨询多场比赛的意见，赌徒还可以从中抽取许多的优势策略。

- 为了能利用这些优势策略来获得最大的实际优势，赌徒还需要在收集到了许多优势策略之后将这些策略合并成一个高度精确的实际的预测规则。
- Adaboost算法，正是这样一种将多个粗糙和不精确的优势策略合并为一个高度精确的实际预测规则的有效方式。




- 以下图为例，分析Adaboost的实现过程。
- 图中，“+”和“-”分别表示两种类别

在此分类过程中，
作为简化，使用水
平或者垂直的直线
作为线性分类器，
对2个类别进行分
类。



应考虑：权值和风险


- 第一步：求取第一个子分类器，并计算新的样本分布



找最小错误率 ε ，分错3个

$$\varepsilon_1 = 0.30$$

$$\alpha_1 = 0.42$$



权值 α 与 ε 成反比例

$$\alpha = \frac{1}{2} \ln \left(\frac{1-\varepsilon}{\varepsilon} \right)$$

$$D_1 = (w_{11}, w_{12}, \dots, w_{1i}, \dots, w_{1N}), \quad w_{1i} = \frac{1}{N}, \quad i = 1, 2, \dots, N$$

错误率定义 $\varepsilon = \frac{\text{未正确分类的样本数目}}{\text{所有样本数目}}$

$$D_{m+1} = (w_{m+1,1}, w_{m+1,2}, \dots, w_{m+1,i}, \dots, w_{m+1,N})$$

$$w_{m+1,i} = \frac{w_{mi}}{Z_m} \exp(-\alpha_m y_i G_m(x_i)), \quad i = 1, 2, \dots, N$$

Z_m 是归一化因子， G_m 为分类器 h

根据最小错误率，得到一个子分类器 h_1 ，形成新的样本分布 D_2 ，其中划圈的样本表示被分错的。在右边图中，比较大的“+”表示对该错分样本做了加权


计算分类器 $G_m(x)$ 在训练数据集上的
加权分类误差率：

$$\varepsilon_m = P(G_m(x_i) \neq y_i) = \sum_{i=1}^N w_{mi} I(G_m(x_i) \neq y_i)$$

错误率定义 $\varepsilon = \frac{\text{未正确分类的样本数目}}{\text{所有样本数目}}$

其中 $m = 1, 2, \dots, M$ ，代表第 m 轮迭代。 i 代表第 i 个样本。 w 是样本权重。 I 指示函数取值为1或0，当 I 指示函数括号中的表达式为真时， I 函数结果为1；当 I 函数括号中的表达式为假时， I 函数结果为0。


取分类误差率最小的弱分类器为当前迭代的最优弱分类器。



找最小错误率 ε ，分错3个
分类器权值 α 与 ε 成反比例

$$\alpha = \frac{1}{2} \ln \left(\frac{1-\varepsilon}{\varepsilon} \right)$$

比较大的“+”表示对该错分样本做了加权




提高错误点权值，当下一次分类器再次分错这些点后，将提高整体错误率，表明下次计算时会更加重视该错分样本。

$$D_{m+1} = (w_{m+1,1}, w_{m+1,2}, \dots, w_{m+1,i}, \dots, w_{m+1,N}),$$


$$w_{m+1,i} = \frac{w_{mi}}{Z_m} \exp(-\alpha_m y_i G_m(x_i)), \quad i = 1, 2, \dots, N$$

- 第二步：根据新样本分布，寻找最小错误率第二个子类器



根据分类最小错误率，得到一个子分类器 h_2 ，形成新的样本分布 D_3 ，其中划圈的样本表示被分错的。在右边的图中，比较大的“—”表示对该错分样本做了加权。

- 第三步：求取第三个子分类器



$$\alpha = \frac{1}{2} \ln \left(\frac{1-\epsilon}{\epsilon} \right)$$


$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right)$$

根据分类最小错误率，得到一个子分类器 h_3

提高错误点的权值，当下一次分类器再次分错这些点后，将提高整体错误率，因此就会使这次的权值 α 变小，最终导致该分类器在整个集成分类器的权值变低。即，算法让优秀的分类器占整体的权值更高，而错的分类器权值更低

- 第四步，集成：
$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right)$$

$$H_{\text{final}} = \text{sign} \left(0.42 \left[\begin{array}{|c|} \hline \text{blue} \\ \hline \end{array} \right] + 0.65 \left[\begin{array}{|c|} \hline \text{blue} \\ \hline \end{array} \right] + 0.92 \left[\begin{array}{|c|} \hline \text{blue} \\ \hline \end{array} \right] \right)$$



说明：2.权重 α 求导获得，
3.虽然 h_3 也分错3个，但带小权重使错误率小，故 α 大。
4.虽然第3轮有3个被误分，但其权重很小，可理解为可不太被关注，前面已经分的很好。这几个最终的分分类结果是由集成的强分类器共同来完成

前面的系数可以理解为投票的价值或分量


- 学习过程：


- 不断地学习多个最优弱分类器

$$H_{\text{final}} = \text{sign} \left(0.42 \begin{array}{|c|} \hline \text{blue} \\ \hline \text{red} \\ \hline \end{array} + 0.65 \begin{array}{|c|} \hline \text{blue} \\ \hline \text{red} \\ \hline \end{array} + 0.92 \begin{array}{|c|} \hline \text{blue} \\ \hline \text{red} \\ \hline \end{array} \right)$$

- 识别的过程：


- 分别检验每个分类器






By 刘建平Pinard

- 基于Adaboost的人脸检测，滑窗




人脸总数 7; 检测 7; 误检 0

图 1 人脸检测效果图



- 基于Adaboost的人脸检测，滑窗




- Adaboost分类器

- 特征提取：类haar特征
- 分类方法：Adaboost算法
- Haar特征结构简单，计算快速，算力要求低

1. Edge features




2. Line features



3. Center-surround features




- 基于Adaboost的人脸检测



Viola等人将Adaboost算法应用于人脸检测，同时将Haar特征和Cascade算法和Adaboost算法结合，大大提高了检测的速度和检测的精确率

- 首先，使用类Haar小波的微结构来提取目标的特征，主要为边缘特征。
- 微结构特征能够构成一个很高维的特征集； 24×24 窗口检测器的矩形特征数量超过160000个。




构建弱分类器的微结构

➤ Sample collection:



➤ Edge feature



局部块
图像



水平梯度




垂直梯度




梯度幅值
大于阈值的
像素点

➤ Haar-like feature structure:


1. Edge features



2. Line features



3. Center-surround features



➤ Haar-like feature extraction



样本图像





第1层第1个特征



第2层第1个特征



第2层第2个特征




从78460个特征中选取

2706个人脸样本



4381个非人脸样本

说明上述特征不能可靠地区分人脸和非人脸




特征分类能力（续）

人脸图像特征值分布




**93.4%的特征在0点一侧
与非人脸相差34%**

非人脸图像特征值分布



说明上述特征能相当可靠地区分人脸和非人脸



优势矩形特征在人脸上的特征匹配位置；

上图是 24×24 子窗口内选出的优势矩形特征，
下行是子窗口检测到的与矩形特征的特征匹配结果。

- 然后，将特征选择与AdaBoost训练方法结合起来，从大量的目标特征中选择使分类错误率最小的特征构建弱分类器。
- 即在AdaBoost分类器训练的每一轮，对每个特征构建一个分类器，选择使错误率 ε_j 最小的分类器作为这一轮所选用的弱分类器。

$$\varepsilon_j = \sum_i w_i |h_j(x_i) - y_i|$$

最后，由多个弱分类器组成一个强分类器

A. 给定一组训练样本 $(x_1, y_1)(x_2, y_2) \dots (x_n, y_n)$ ，其中 $y_i=0$ 表示其为负样本（非人脸）， $y_i=1$ 表示其为正样本（人脸）；

B. 初始化权重 $w_{1,i}=1/n$ ；

C. 对 $t=1 \dots T$ ：

(1) 归一化权重： $q_{t,i} = w_{t,i} / \sum_{j=1}^n w_{t,j}$

(2) 对每个特征 f ，训练一个弱分类器 $h(x, f, \theta)$ ；计算对应所有特征的弱分类器的加权(q_t)错误率 ε_f ： $\varepsilon_f = \sum_i q_i |h(x_i, f, \theta) - y_i|$

(3) 选取最佳的弱分类器 $h_t(x) = h(x, f_t, \theta_t)$ ，拥有最小错误率 ε_t ：

$$\varepsilon_t = \min_{f, \theta} \sum_i q_i |h(x_i, f, \theta) - y_i| = \sum_i q_i |h(x_i, f_t, \theta) - y_i| = \sum_i q_i |h(x_i, f_t, \theta_t) - y_i|$$

(4) 按照这个最佳弱分类器，调整权重： $w_{t+1,i} = w_{t,i} \beta_t^{1-e_i}$


其中 $e_i = 0$ 表示 x_i 被正确地分类， $e_i = 1$ 表示 x_i 被错误地分类； $\beta_t = \varepsilon_t / (1 - \varepsilon_t) < 1$

D. 最后的强分类器为：

$$h(x) = \begin{cases} 1 & \sum_{t=1}^T \alpha_t h_t(x) \geq \frac{1}{2} \sum_{t=1}^T \alpha_t \\ 0 & \text{others} \end{cases} \quad \text{其中 } \alpha_t = \log \frac{1}{\beta_t}$$

近似 $\alpha_t = \frac{1}{2} \ln \frac{1}{\beta_t}$

- 另外，还可通过建立一个级联分类器结构，将多个强分类器级联，应用一种由粗到细的检测策略，实现目标的快速检测。






$$D = \prod_{i=1}^M d_i$$

$$F = \prod_{i=1}^M f_i$$


通常，级联分类器的第一级、第二级的强分类器中的弱分类器数量很少，1或2

AdaBoost 分类器检测结果





CNN Cascade for FaceDetection框架

Tsinghua



- 一共6个CNN，3个detection-net用于判断输入的区域是否是人；3个calibration-net对输入的人脸框进行校正，得到更加准确的人脸框
- 检测过程中采用NMS消除高度重叠的窗口



- 4. 1 计算机视觉基本任务之一
- 4. 2 运动物体检测
- 4. 3 统计学习物体检测
- 4. 4 深度学习物体检测

4.4 深度学习物体检测

目录

- 1.深度学习的起源与发展
 - 1.1 深度学习的起源
 - 1.2 网络结构发展
 - 1.3 应用与前景
- 2.基于深度学习的物体检测算法
 - 2.1 物体检测方法框架
 - 2.2~2.4 关键算法
 - 2.5 算法实例
 - 2.6 深度学习算法的优越性
 - 2.7 算法的广泛应用
- 3.未来发展方向





1. 深度学习的起源与发展

1.1 深度学习的起源

- ◆ **理论的提出**：1943年，心理学家W·Mcculloch和数理逻辑学家W·Pitts在分析、总结神经元基本特性的基础上首先提出神经元的数学模型。
- ◆ **感知机**：50年代末，F·Rosenblatt设计制作了“感知机”，这项工作首次把人工神经网络的研究从理论探讨付诸工程实践。但由于其拟合能力差、描述力不佳，研究一度被搁置。
- ◆ **多层感知机**：1986年，Rumelhart, Hinton, Williams发展了BP算法，重新点燃了基于NN (Neural Network)的光芒。
- ◆ **深度学习**：深度学习的概念由Hinton等人于2006年提出。深度学习是机器学习研究中的一个新的领域，它模仿人脑的机制来解释数据，例如图像，声音和文本。其在模式识别、智能机器人、自动控制、预测估计、生物、医学、经济等领域已成功地解决了许多现代计算机难以解决的实际问题，表现出了良好的智能特性。近年来，深度学习手段已成为解决各类任务的一大利器。

1. 深度学习的起源与发展


1.2 网络结构发展 —— go deeper and perform better



1. 深度学习的起源与发展

1.3 应用与前景

图像分析



人工智能



安全保障



机器人



人机交互



2. 基于深度学习的物体检测算法

2.1 物体检测方法框架 —— 三步走

物体检测是图像领域的一个主要研究方向，物体检测算法也多种多样。大多数基于深度学习的物体检测算法按照以下三个步骤进行：

- (1) 候选区域生成
- (2) 区域特征提取与分类
- (3) 物体定位




图2.1 基于深度学习的物体检测算法流程图

2. 基于深度学习的物体检测算法

2.2 候选区域生成:

➤ 算法功能：根据图像显著性等特性对图像进行预处理，提出可能包含物体的候选区域供后续算法处理。

算法将候选窗口数量从数万（滑动窗算法）降至数十至数千，加快了检测速度，减少了虚警率。

➤ 评价指标：#win-Recall曲线

#win：提出的候选区域数量；Recall：物体召回率

*在实际应用中也会考虑时间因素



图2.2 候选区域生成示例

2. 基于深度学习的物体检测算法

2.2.1 候选区域生成算法：

➤ 常用算法 – Selective Search^[1]

原理：物体有区域一致性

步骤：

- 将图像过分割得到超像素
- 使用贪婪算法两两组合超像素区域，直至区域大小达到全图
- 根据组合得出的区域，在不同尺度上得出候选框




图2.3 Selective Search算法在不同尺度上得到候选框——蓝色为候选框，绿色为候选框圈中物体

2. 基于深度学习的物体检测算法

2.2.2 候选区域生成算法：

➤ 常用算法 – EdgeBox^[2]

原理：物体具有边界

步骤：

- 提取图像中边界
- 对提取出的边界进行聚类
- 按照边界聚类结果对选择框进行评分，评分高的输出为候选框




图2.4 EdgeBox算法——第一行至第四行分别为：原图、边界图、边界聚类图、候选框提出

2. 基于深度学习的物体检测算法

2.2.3 候选区域生成算法：

➤ 常用算法 – BING^[3]

原理：物体有闭合边界

步骤：

- 提取物体区域和非物体区域的二值化梯度特征
- 根据这些特征训练分类器
- 在待测图像中随机生成不同尺度的窗口，使用分类器评分判断是否包含物体，评分高的为候选框




图2.5 BING原理 —— 所有物体均有闭合边界并因此具有相似特征的梯度图（a、c中红框为物体，绿框为非物体）

2. 基于深度学习的物体检测算法

2.2.4 候选区域生成算法：

➤ 常用算法小结

名称	原理	召回率 (1000 windows)	候选区域质量 (与物体贴合程度)	速度 (sec/img)
Selective Search [1]	无需学习，直接将图片打散为superpixel，然后根据人为定义的距离进行聚合，得出候选区域。	97%	很好	22
EdgeBox [2]	结合滑窗，通过计算窗口内边缘个数进行打分，最后排序输出。	96%	较好	1.8
BING [3]	训练了一个基于物体二值化梯度特征的简单的线性分类器来过滤候选框。	96.2%	一般	0.3

2. 基于深度学习的物体检测算法

2.3 卷积神经网络 (CNN)

- 算法功能：在物体检测中，CNN实现对候选框的特征提取+分类的作用。
- 评价指标：分类准确率




图2.6 卷积神经网络组成

2. 基于深度学习的物体检测算法

2.3.1 卷积神经网络的发展

➤ 出现和发展：

- 20世纪60年代，Hubel和Wiesel在研究猫脑皮层中用于局部敏感和方向选择的神经元时发现其独特的网络结构可以有效地降低反馈神经网络的复杂性，继而提出了卷积神经网络
- K.Fukushima在1980年提出的新识别机是卷积神经网络的第一个实现网络。
- 20世纪末，卷积神经网络首先在手写体识别上，取得惊人的效果
- 卷积神经网络是第一个真正成功训练多层网络结构的深度学习算法。近年来，CNN以其优异的性能取得了广泛的重视，在物体检测、人脸识别等领域得到广泛的应用。

2. 基于深度学习的物体检测算法




图2.7 传统CNN架构

➤ 基本架构:

CNN是一个多层的神经网络，每层由多个二维平面组成，而每个平面由多个独立神经元（filter）组成。常见CNN网络通常由卷积层、亚采样层和全连接层构成：卷积层提取特征，亚采样层降低减少计算量，全连接层实现分类。

2. 基于深度学习的物体检测算法

➤ CNN的优势:

自动特征学习

分层特征表达

提取全局信息

2.基于深度学习的物体检测算法

➤ CNN的优势:

- 自动特征学习

模式识别系统: 特征描述+分类器

人工设计的特征: 物体识别SIFT, 人脸检测HAAR, 行人检测HOG

- ✓ 蕴含了设计者足够的智慧与经验

- ✗ 依赖手工调参, 特征的复杂度一般较低

传统分类器: SVM、Boosting、KNN等

CNN特征表示:

- ✓ 从大数据中自动学习特征表示

- ✓ 可以包含成千上万个参数

CNN特征表示和分类器联合优化 (传统模式识别中特征和分类器分别进行优化)

2. 基于深度学习的物体检测算法

➤ CNN的优势：

- 分层特征表达

三层神经网络模型可以近似大多数分类函数

针对特定任务，如果模型深度不够，其所需要的计算单元会呈指数增加

例如物体分类中的网络输出

最底层的滤波器输出——局部的边缘和纹理特征

中（间）层滤波器输出——不同类型的物体部件

（最）高层特征——物体的语义特征，例如猫狗、颜色、材质等


- 提取全局特征

感受野的缩放


2. 基于深度学习的物体检测算法

2.3.2 深入解析CNN


➤ CNN的基础：神经元




The pyramidal cell



Nonlinear model of a neuron



Threshold function




Sigmoid function for varying slope parameter a

Activation Function

2. 基于深度学习的物体检测算法

- CNN的三个核心概念：**局部感受野**、**权值共享**、**池化操作**
- **局部感受野**：每个神经元只关注图像局部区域，符合人类视觉特性和图像的局部时空相关性。



因此，卷积网络降低了网络模型的复杂度，减少了权值的数量

图2.8 全部感受野（左）vs局部感受野（右）



上图左：全连接网络。如果我们有1000x1000像素的图像，有1百万个隐层神经元，每个隐层神经元都连接图像的每一个像素点，就有 $1000 \times 1000 \times 1000000 = 10^{12}$ 个连接，也就是 10^{12} 个权值参数

上图右：局部连接网络，每一个节点与上层节点同位置附近10x10的窗口相连接，则1百万个隐层神经元就只有100w乘以100，即 10^8 个参数。其权值连接个数比原来减少了四个数量级

2. 基于深度学习的物体检测算法

➤ CNN的三个核心概念：

- **权值共享**：滑动过程中的卷积核参数共享，即同一层隐含神经元检测完全一样的特征，只不过是输入图像的不同位置。权值共享减少了网络参数。



1 x1	1 x0	1 x1	0	0
0 x0	1 x1	1 x0	1	0
0 x1	0 x0	1 x1	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		

Convolved Feature


图2.9 权值独立（左）vs权值共享（右）

图2.10 权值共享的卷积过程


2. 基于深度学习的物体检测算法

➤ CNN的三个核心概念：

- **池化操作**：池化的过程通常也被称为特征映射的过程，将不同位置的特征进行局和统计。该过程减少了整体计算量，以及网络对变形和扭曲的敏感性。



Convolved
feature



Pooled
feature

图2.11 池化（pooling）过程

2. 基于深度学习的物体检测算法


2.3.3 常用CNN网络

网络名称	层数	网络特点	准确率 (mAP) Cited from ILSVRC2015 挑 战赛Detection
AlexNet [4]	7	卷积层数设置仿人类视觉通路，每层卷积结果均有对应解释。	0.34843
VGGNet [5]	16~19	filter小，特征提取精细，网络参数多，训练慢，分类准确度高。	0.418272
GoogleNet [6]	22	每层使用多尺度的filter提取特征，在同准确率时模型参数少。	0.588451
Deep Residual Network [7]	可达到100+	添加short cut防止梯度消失，网络深度可以达到非常深，且网络性能随深度增加而增加。	0.620741

2. 基于深度学习的物体检测算法


2.3.3 常用CNN网络

➤ 网络结构




AlexNet^[4]


each conv includes 3 convolutional layers



VGG^[5]



GoogLeNet^[6]



Deep Residual Network^[7]

2. 基于深度学习的物体检测算法

2.4 非极大值抑制NMS:

2.4.1 Non-Maximum Suppression (NMS):

- 算法功能：消除多余检测框，输出物体最佳位置。
- 评价指标：物体位置准确率。
- 算法流程：
 - 检测框按照评分从高到低排序，最高分的检测框直接设为输出框
 - 对余下检测框，依次进行操作：若检测框与之前某个输出框的交并比大于阈值，则抑制该检测窗，否则将其设为输出框




图2.12 NMS算法作用——从检测框（左）得到输出框（右）

2. 基于深度学习的物体检测算法

2.5 算法实例 —— 从R-CNN到Faster R-CNN:

2.5.1 R-CNN^[8]: 物体检测的基础性框架

- Selective Search做region proposal
- AlexNet提取region的feature, SVM对region分类
- NMS筛选窗口并输出




图2.13 R-CNN物体检测框架

2. 基于深度学习的物体检测算法

2.5.2 Fast R-CNN^[9]: 共享的卷积层特征

- Selective Search做region proposal (2k个object proposal)
- AlexNet conv5 ROI pooling得到region的feature, 统一到一样的尺度 (对于AlexNet是6x6)。
- 网络的Softmax层对region分类
- Bounding Box Regression 规范窗口并输出





图2.14 Fast R-CNN流图

2. 基于深度学习的物体检测算法

2.5.3 Faster R-CNN^[10]: 一步到位的检测网络

- 与检测网络共享卷积层的region proposal network (RPN)提出窗口
- ROI pooling得到窗口特征
- Bounding Box Regression 规范输出窗口



2. 基于深度学习的物体检测算法

2.5.3 Faster R-CNN^[10]: 一步到位的检测网络

- 与检测网络共享卷积层的region proposal network (RPN)提出窗口
- ROI pooling得到窗口特征
- Bounding Box Regression 规范输出窗口





图2.15 Faster R-CNN中的窗口提出机制RPN

2. 基于深度学习的物体检测算法

锚点及其在原图对应位置


如原始图像的大小是 256×256 ,特征提取网络中含有4个pool层, 然后最终获得的特征图的大小为 $256/16 \times 256/16$, 即获得一个 16×16 的特征图, 该图中的最小单位即是锚点, 由于特征图和原始图像之间存在比例关系, 在特征图上面密集的点对应到原始图像上面是有16个像素的间隔,



2. 基于深度学习的物体检测算法

锚点定出候选的ROI


对每一个锚点，根据不同面积尺度（ 128^2 、 256^2 、 512^2 pixel）和不同的长宽比（1:1、0.5:1、1:0.5）产生9个候选框，对于 16×16 的特征图，最终产生 $16 \times 16 \times 9$ 个候选的ROI。即特征图上的最小单位点，比如原始图像的大小是 256×256 ，特征提取网络中含有4个pool层，则下采样 2 的 4 次方 $=16$ ，然后最终获得的特征图的大小为 $256/16 \times 256/16$ ，即获得一个 16×16 的特征图，该图中的最小单位即是锚点。（在python demo中，会把任意大小的输入图像reshape成 800×600 ）



2. 基于深度学习的物体检测算法


在原文中，使用的是ZF model中，其Conv Layers中最后的conv5层num_output=256，对应生成256张特征图，所以相当于feature map每个点都是256-dimensions。

在conv5之后，每个点都做3x3卷积(rpn_conv)且输出维数仍为256，相当于每个点又融合了周围3x3信息，同时256-d不变



2. 基于深度学习的物体检测算法


假设在conv5 feature map中每个点上有 k 个anchor（默认 $k=9$ ），对应到原图获得anchor矩形框位置，与ground truth box的IoU大于0.7的作为正样本，负样本为与ground truth box的IoU小于0.3的样本，其他的舍弃



2. 基于深度学习的物体检测算法

至此，每个anchor有了标签；假设在conv5 feature map中每个点上有k个anchor(默认k=9)，一路cls layer对256维做 $1*1*18$ 卷积，每个anchor要给foreground和background两个得分，所以每个锚点由256d feature转化为cls=2k scores(18d)；

另一路reg layer对256维做 $1*1*36$ 卷积，每个anchor都有[x, y, w, h]对应的4个偏移量 $\Delta x, \Delta y, \Delta w, \Delta h$ ，得到reg=4k coordinates(36d)。至此得到Region Proposal 结果框



最右侧的18层中，每两层代表了某个anchor的特征图上所有点的前景背景概率

RPN的损失函数

RPN Multi-task loss

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*)$$

分类损失 边界框回归损失

p_i 表示第*i*个anchor预测为真实标签的概率



p_i^* 当为正样本时为1, 当为负样本时为0

t_i 表示预测第*i*个anchor的边界框回归参数


t_i^* 表示第*i*个anchor对应的GT Box

N_{cls} 表示一个mini-batch中的所有样本数量256


N_{reg} 表示anchor位置的个数(不是anchor个数)约2400



2. 基于深度学习的物体检测算法





最右侧的36层中，每4层代表了某个anchor的特征图上所有点的偏移量的值







绿色框是标注框，是样本中标注好的，代表了飞机的真实存在框范围，红色框可以看成是候选框的初值，针对特征图上的某个点，这样的框有9个。上面的蓝色是在红色框基础上回归修正得到的


一些检测示例



一些检测示例



2.5.4 基于Cascade CNN 的人脸检测框架




本篇文章的方法是对经典的Viola jones方法的深度卷积网络实现

• 级联的工作原理和优势

- 最初阶段的网络可以比较简单，判别阈值可以设得宽松一点，这样就可以在保持较高召回率的同时排除掉大量的非人脸窗口；
- 最后阶段网络为了保证足够的性能，因此一般设计的比较复杂，但由于只需要处理前面剩下的窗口，因此可以保证足够的效率；
- 级联的思想，可以帮助我们去组合利用性能较差的分类器，同时又可以获得一定的效率保证。






级联框架结构


- 一共6个CNN，3个detection-net 用于判断输入的区域是否是人；3个 calibration-net对输入的人脸框进行校正，得到更加准确的人脸框
- 检测过程中采用 NMS 消除高度重叠的窗口
- 检测特点
 - 优化网络结构
 - 将第一层的12-net改进为全卷积的实现，大幅提升了检测的速度
 - 将calibration-net改进为回归的实现方式，提升了检测窗口的稳定性





12net最后得到全连接层结果(16个结点)与24net concat成(16+128)维

calibration-net



如图展示了Fddb上的检测结果，3阶段平均剩下的窗口数量及对应的召回率：

Stage	# windows	Recall
sliding window	5341.8	95.9%
12-net	426.9	93.9%
12-calibration-net	388.7	94.8%
24-net	60.5	88.8%
24-calibration-net	53.6	89.0%
48-net	33.3	85.8%
global NMS	3.6	82.1%
48-calibration-net	3.6	85.1%





Figure 5: Calibrated bounding boxes are better aligned to the faces: the blue rectangles are the most confident detection bounding boxes of 12-net; the red rectangles are the adjusted bounding boxes with the 12-calibration-net.

2.5.5 目标检测YOLO_v1

YOLO(You Look only once)是基于图像全局信息进行预测。与基于sliding window以及region proposal等检测算法不同。YOLO算法把物体检测 (object detection) 问题作为回归问题，用一个卷积神经网络结构就可以从输入图像直接预测 bounding box和类别概率。




2.5.5 目标检测YOLO_v1

论文里使用了7*7

算法步骤:

将图像分成 $S \times S$ 格子，每个格子预测**B**个bounding boxes，每个 bounding box 包含**5**个预测值：**x, y, w, h**和**confidence**。x, y是 bounding box 中心坐标，与grid cell对齐（相对于当前grid cell偏移值），使范围为0到1；w和h做归一化（分别除以图像w和h，这样最后的w和h在0到1范围）




2.5.5 目标检测YOLO_v1

算法步骤:


每个bounding box对应一个confidence score, 如果grid cell里面没有object, confidence就是0, 若有 (object中心点在该grid cell中), 则confidence score等于预测box和ground truth的IOU值。每个grid cell都预测C个类别概率, 表示一个grid cell在包含object时属于某个类别的概率

论文里是20类

grid cell



Tensor values interpretation



deepsystems.io





Figure 3: The Architecture. Our detection network has 24 convolutional layers followed by 2 fully connected layers. Alternating 1×1 convolutional layers reduce the features space from preceding layers. We pretrain the convolutional layers on the ImageNet classification task at half the resolution (224×224 input image) and then double the resolution for detection. <http://blog.csdn.net/u014380165>

YOLO损失函数

对应于两个检测框


对应于20个类



YOLO v1 损失函数

批注：同济子豪兄

loss function:



负责检测物体的bbox
中心点定位误差

$$\lambda_{\text{coord}} \sum_{i=0}^S \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right]$$

负责检测物体的bbox
宽高定位误差
求根号能使小框对误差更敏感

$$+ \lambda_{\text{coord}} \sum_{i=0}^S \sum_{j=0}^B \mathbb{1}_{i,j}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right]$$

负责检测物体的bbox
Confidence 误差

$$+ \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left(C_i - \hat{C}_i \right)^2$$

不负责检测物体的bbox
Confidence 误差

$$+ \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2$$

负责检测物体的grid cell
分类误差

$$\text{类别预测误差} + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \quad (3)$$

2. 基于深度学习的物体检测算法


2.6 深度学习算法的优越性


使用深度学习办法做物体检测具有如下优点：

- 远超传统算法的分类准确率——在ILSVRC2012上，CNN网络的分类准确率比传统方法高11%。
- 实时的检测速度——GPU并行加速，使得CNN网络的运算速度基本可满足实时的检测需求。
- 随数据量上升的网络性能——CNN网络性能随数据量的增大而上升，符合大数据时代潮流
- SSD, YOLO, YOLO9000 (V2) , YOLO V3 等新检测算法不断发展

2. 基于深度学习的物体检测算法

2.6 深度学习算法的优越性





<https://www.cnblogs.com/guoyaohua/p/8534077.html>

图片参照博客:

http://blog.csdn.net/cyh_24/article/details/51440344

2. 基于深度学习的物体检测算法

2.7 算法的广泛应用



➤ 多姿多彩的生活娱乐



2. 基于深度学习的物体检测算法

2.7 算法的广泛应用


➤ 简单方便的学习与教育



2. 基于深度学习的物体检测算法

2.7 算法的广泛应用

➤ 机械智能化



2. 基于深度学习的物体检测算法

2.7 算法的广泛应用


➤ 互联网大数据



3. 未来发展方向

➤ 大规模的物体检测

- ImageNet Large Scale Visual Recognition (ILSVRC) 竞赛:
 - 分类-定位数据库: 1000类, 1.2 million 训练集图片, 5万张验证集图片, 10万张测试集图片 (2013年停止更新)
 - 物体检测数据库: 200类, 45.6万张训练图片with 47.9万 bounding box 标注, 2.1万张验证集图片和5.5万张测试集图片 (2015年开始停止更新)
- YOLO9000 9000类



3. 未来发展方向

➤ 仿人脑的巨型网络

- Google Brain

使用 1000 台电脑创造出包含 10 亿个连接的“神经网络”，使机器系统学会自动识别猫，成为国际深度学习领域广为人知的案例。



3. 未来发展方向

➤ 神经网络专属芯片

- IBM SyNAPSE类人脑芯片



IBM科学家日前发布首款前所未有的超大规模神经突触计算机芯片，其中含有100万个可编程神经元、2.56亿个可编程突触，每消耗一焦耳的能量，可进行460亿突触运算。这款由54亿支晶体管组成的功能齐全、可大规模生产的芯片是迄今建造的最大的CMOS芯片之一。并且在进行生物实时运算时，这款芯片的功耗低至70毫瓦(mW)，比现代微处理器功耗低数个数量级。神经突触超级计算机芯片如同一枚邮票大小，其工作电源相当于助听器电池，这种支持视觉、听觉和多感官应用的技术将给科技、商务和社会带来全新的变化。

3. 未来发展方向

➤ 结合实际需求的多样化设计

- 人脸检测
- 飞行物探测
- 宠物品种查询
- 同款衣物查询
- 以图搜图

...



• 物体检测指标

物体检测器，通常使用mAP(mean Average Precision)指标评价一个模型的性能。
AP指的是一个类别检测精度，mAP则为多个类别平均精度。

$$precision = \frac{TP \text{ 正检}}{TP + FP \text{ 误检}}$$

$$recall = \frac{TP}{TP + FN \text{ 误分为背景}}$$





图1.13 正、负样本判别示例



曲线下的面积

$$AP = \sum_{i=1}^{n-1} (r_{i+1} - r_i) p_{interp}(r_{i+1})$$

$$mAP = \frac{\sum_{i=1}^K AP_i}{K}$$

• 人脸识别指标

人脸识别指标: 多数情况下, 以基于FAR (错误接受率, 又称误识率, 即把某人误识为其他人的概率) 和FRR (错误拒绝率, 即本人注册在底库中, 但比对相似度达到不预定的值) 的DET曲线作为评判参考。


错误拒绝率FRR

$$FRR = \frac{\text{本人的比对相似度低于阈值的次数}}{\text{总的本人比对次数}}$$

错误接受率FAR

$$FAR = \frac{\text{与非本人比对的相似度高于阈值的次数}}{\text{总的与非本人比对次数}}$$

知乎 @光之电
CSDN @wongts44tl



知乎 @光之电
CSDN @wongts44tl

References

- [1] Uijlings J R R, van de Sande K E A, Gevers T, et al. Selective search for object recognition[J]. International journal of computer vision, 2013, 104(2): 154-171.
- [2] Zitnick C L, Dollár P. Edge boxes: Locating object proposals from edges[M]//Computer Vision–ECCV 2014. Springer International Publishing, 2014: 391-405.
- [3] Cheng M M, Zhang Z, Lin W Y, et al. BING: Binarized normed gradients for objectness estimation at 300fps[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014: 3286-3293.
- [4] Krizhevsky, Alex, Ilya Sutskever, and Geoffrey E. Hinton. "Imagenet classification with deep convolutional neural networks." Advances in neural information processing systems. 2012.
- [5] Simonyan, Karen, and Andrew. "Very deep convolutional networks for large-scale image recognition." arXiv preprint arXiv:1409.1556 (2014).
- [6] Szegedy, Christian, et al. "Going deeper with convolutions." Proceedings of the IEEE Conference on CVPR. 2015.
- [7] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J]. arXiv preprint arXiv:1512.03385, 2015.
- [8] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [9] Girshick R. Fast r-cnn[C]//Proceedings of the IEEE International Conference on Computer Vision. 2015: 1440-1448.
- [10] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[C]//Advances in Neural Information Processing Systems. 2015: 91-99.

1. 讨论题（不需要交）

了解类物体检测与特定物体检测的特征提取算法，及其对应的应用场合。

2. 准备本课程布置的上机作业—project，文献调研，思考算法方案。