


数字图像处理

Digital Image Processing

第6讲 图像分割

Image segmentation



清华大学电子系 王生进

6.1 图像分割概述


6.2 基于梯度和阈值的图像分割

6.3 GraphCut图像分割

6.4 深度学习图像语义分割FCN



本章的数字图像处理研究图像构成成分的划分

其特点是→输入是一幅图像，输出是从该图像中提取出的区域属性，即区域边界



图像分割是数字图像处理中一个重要技术

图像分割的目标，是将图像分为构成它的子区域或对象，当感兴趣的目标被分离出来后，分割任务完成




目标:

- 将图像划分为多个图像子区域，即对每个像素加标签的过程，
- 使得具有相同标签的像素具有某种共同的视觉特性



人像分割




图像分割应用领域


- ✓ 人脸识别、表情识别、指纹识别等
- ✓ 图像搜索、图像压缩编码等
- ✓ 立体视觉重建、三维模型重建
- ✓ 机器视觉、物体检测等视觉问题
- ✓ 医学图像：肿瘤和其它病理的定位、组织体积的测量
- ✓ 交通控制系统：路况勘察和路标识别等
- ✓ 卫星图像：定位道路、建筑物、农作物森林等
- ✓

1. 图像分割应用




- 工业检测：
 - 零件识别，机械组装





- 基于机器视觉的破损检测




➤ 医学诊断： 组织提取，细胞分割





➤ 图像编码：ROI编码，MPEG4/MPEG7



➤ 军事侦察：红外图像目标，目标检测




➤ 图像编码：ROI编码，MPEG4/MPEG7




➤ 军事侦察：红外图像目标，物体目标检测

From Gonzalez' book



<http://www.gissky.net/Article/3481.htm>





原图像

Mean Shift分割结果






<http://www.imagetekinfo.com/technical/technical3.html>

➤ 公共安全：侵入、越界目标检测，生物特征识别，交通监控




2. 图像分割的主要方法


➤ 图像分割，是从图像处理到图像分析的一个关键技术。




➤ 图像分割的种类和方法很多，有些分割算法可直接用于任何图像，而另一些算法只能适用于分割一些特殊类别的图像，如基于肤色分割。



➤ 有些算法，需要先对图像进行粗分割，因为它们需要从图像中提取出来的信息作为初始值。






基于知识约束的分割：如形状




Object: Efficient Segmentation Using Top-Down and Bottom Cues, PAMI, 2010
Using Segmentation to Verify Object Hypotheses, CVPR, 2007

图像分割方法可以分为两大类:

➤ 一类是边界方法，这种方法假设图像分割结果的某个子区域，在原来图像中一定会有边缘存在；



➤ 另一类是区域方法，这种方法假设图像分割结果的某个子区域，一定具有相同的性质，而不同区域的像素则没有共同的性质。



实际应用中，这两种方法都有优点和缺点，可以考虑把两者结合起来，进行图像分割。


目前，随着计算机处理能力的提高，很多方法不断涌现，如：

- 基于彩色分量分割、
- 纹理图像分割、
- 运动目标分割、
- 深度学习像素分割等




图像分割主要包括4种技术:

- 并行边界分割技术;
- 串行边界分割技术;
- 并行区域分割技术;
- 串行区域分割技术



(1) 并行边界分割技术;

对图像的每一点上所做的处理，不依赖于其它的点处理结果，逐点独立计算。如求导，Sobel算子，Laplacian算子。



(2) 串行边界分割技术;

串行边界分割技术，通常是通过顺序的搜索边缘点先求梯度，找到梯度最大点，进行边界跟踪。


(3) 并行区域分割技术;

并行区域分割主要有两种方法：阈值分割，聚类。


(4) 串行区域分割技术

串行区域分割一般可分为两种方法：

一种是区域生长，二是分裂合并。



SAM: 分割看到的一切



6.1 图像分割概述

6.2 基于梯度和阈值的图像分割

6.3 GraphCut图像分割

6.4 深度学习图像语义分割FCN

6.2 基于梯度和阈值的图像分割


Tsinghua

6.2.1 边缘检测与梯度算子

1. 边缘检测的概念

边缘检测，对于灰度级变化的检测是最为有效的检测方法。颜色变化也有灰度变化表现。

Model of an ideal digital edge



➤直观上，一个边缘，是一组相连的像素组合，这些像素位于两个区域的边界上。

➤边缘与边界的区别：

边缘是局部概念；边界是对于区域整体概念。



2. 边缘建模


理想边缘所具有模型特性：

每个像素都处在灰度跃变的垂直台阶上


➤ 由于噪声等干扰获得的实际边缘的模型特性：

边缘模型为具有“类斜面”的剖面，边缘为一组彼此相连的点集→边缘宽度取决于斜坡长度

Model of an ideal digital edge



Model of a ramp digital edge



a b

FIGURE 10.5

(a) Model of an ideal digital edge.
(b) Model of a ramp edge. The slope of the ramp is proportional to the degree of blurring in the edge.

3. 边缘检测


一阶导数可以用于检测图像中的一个点是否是边缘上的点。

二阶导数的符号可以用于判断一个边缘像素是在边缘亮的一边还是暗的一边

a b


FIGURE 10.6

(a) Two regions separated by a vertical edge.
(b) Detail near the edge, showing a gray-level profile, and the first and second derivatives of the profile.



有噪声的边缘附近的一阶、二阶导数性质

无干扰



$\sigma=0.1$

$\sigma=1$

$\sigma=10$


第一列：被均值=0， $\sigma=0.0, 0.1, 1.0, 10$ 的噪声干扰

第二列：左边图像的一阶导数图像，导数对噪声敏感

第三列：是二阶导数图像，对于噪声更为敏感

4. 边缘检测算子应具有的特性


➤ 为了对有意义的边缘点进行分类，与这个点相关的灰度级变换，必须比在这一点**周围**的背景上的变换更为有效，即能突出边缘点。



➤ 决定一个值是否有效的选择方法，是使用
阈值，导数响应阈值。

→ 如果一个点的二维一阶导数 大于 指定阈值门
限

→ 则 此点为图像中的边缘点



一组相连的
边缘点定义为
一条边缘。

5. 一阶梯度算子

(1) $f(x, y)$ 在 (x, y) 的梯度定义

$$\bar{\nabla} f = \begin{bmatrix} G_x \\ G_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix}$$


向量的模
称为梯度

$$|\nabla f| = \sqrt{G_x^2 + G_y^2}$$

梯度向量的分量本身是线性算子，但模不是线性的，因为用到了平方和开方运算

(2) 近似处理

$$|\nabla f| = \sqrt{G_x^2 + G_y^2}$$



$$|\nabla f| \approx |G_x| + |G_y|$$

左式的计算量较大，可以对梯度采用数值近似

一阶微分最简单的近似处理


$$G_x = z8 - z5 \quad G_y = z6 - z5$$

z1	z2	z3
z4	z5	z6
z7	z8	z9

Robert在1965年提出了交叉差分定义

$$G_x = z9 - z5 \quad G_y = z8 - z6$$

z1	z2	z3
z4	z5	z6
z7	z8	z9



Robert算子模板

$$|\nabla f| \approx |z9 - z5| + |z8 - z6|$$

-1	0
0	1

0	-1
1	0

Sobel算子

$$|\nabla f| \approx |(z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3)| \\ + |(z_3 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7)|$$

-1	-2	-1
0	0	0
1	2	1

-1	0	1
-2	0	2
-1	0	1

见 Canny算子 !

原图像

x-方向的梯度分量 $|G_x|$

a	b
c	d

FIGURE 10.10

(a) Original image. (b) $|G_x|$, component of the gradient in the x -direction. (c) $|G_y|$, component in the y -direction. (d) Gradient image, $|G_x| + |G_y|$.

y-方向的梯度分量 $|G_y|$ 梯度 $|G_x| + |G_y|$

6. 二阶梯度算子-拉普拉斯算子

二维函数 $f(x, y)$ 的拉普拉斯算子是如下定义的二阶导数

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

拉普拉斯算子的一种模板

$$\begin{aligned} \nabla^2 f = & -[f(x+1, y) + f(x-1, y) \\ & + f(x, y+1) + f(x, y-1) \\ & - 4f(x, y)] \end{aligned}$$

0	-1	0
-1	4	-1
0	-1	0



拉普拉斯算子的第二种模板

$$\begin{aligned}\nabla^2 f = & -[f(x-1, y-1) + f(x-1, y+1) \\ & + f(x+1, y) + f(x-1, y) \\ & + f(x, y+1) + f(x, y-1) \\ & + f(x+1, y-1) + f(x+1, y+1) \\ & - 8f(x, y)]\end{aligned}$$

-1	-1	-1
-1	8	-1
-1	-1	-1

上式为拉普拉斯扩展算子，包括对角线
邻域

实例：人脸边缘提取



原图像

拉普拉斯二阶导数图像

a	b
c	d


FIGURE 3.40

(a) Image of the North Pole of the moon.

(b) Laplacian-filtered image.

(c) Laplacian image scaled for display purposes.

(d) Image enhanced by using Eq. (3.7-5). (Original image courtesy of NASA.)





计算出图像中每个点的梯度值后，进入下一步的边缘提取处理

6.2.2 边缘连接与边界检测

理论上，边缘检测仅能得到处在边缘上的一组像素点

由于噪声、不均匀照明产生的边缘间断、以及其他虚假亮度间断产生的影响，使得到的一组像素很少能完整地描绘一条边缘



因此，需要采用连接处理，将边缘像素点组合成有意义的边缘

1. 局部处理

连接边缘点最简单的方法之一，是分析每一个边缘点 (x, y) 的一个邻域 $(3 \times 3, 5 \times 5)$ 内像素的梯度特性（如强度、方向），

然后

- 依据事先预定的准则，
- 连接相似的边缘点，
- 形成由共同满足准则的像素组成的一条边缘

确定边缘点相似性的两个主要性质：

- (1) 用于生成边缘点的梯度算子的强度
- (2) 梯度向量的方向

对梯度算子强度，(1) 的性质由 ∇f 值给定

即当 $|\nabla f(x, y) - \nabla f(x_0, y_0)| \leq E$ E 为非负门限

则在 (x, y) 的邻域内，坐标为 (x_0, y_0) 的边缘点在幅度上相似于位于 (x, y) 的像素点

对梯度向量的方向，(2) 的性质由下式给定，即当

$$|\alpha(x, y) - \alpha(x_0, y_0)| < A \quad \text{A 为非负角门限}$$


其中 $\alpha(x, y) = \arctan\left(\frac{G_y}{G_x}\right)$

则在 (x, y) 的邻域内坐标为 (x_0, y_0) 的边缘点在角度上相似于位于 (x, y) 的像素点

且 (x, y) 处的边缘方向垂直于此点处的梯度向量方向

如果梯度大小和梯度方向准则得到满足，

则在 (x, y) 的邻域内的点 (x_0, y_0) 就与位于 (x, y) 的像素点连接



在图像中每个位置重复这一操作，邻域的中心从一个像素转移到另一个像素，并记录下两个相连接点，


→由此即获得有意义的边缘

实例1：在图像中搜索车牌照大小的矩形

a b
c d

FIGURE 10.16

(a) Input image.
(b) G_y component of the gradient.
(c) G_x component of the gradient.
(d) Result of edge linking. (Courtesy of Perceptics Corporation.)




水平Sobel算子
检测垂直边缘

垂直Sobel算子
检测水平边缘

连接同时具有大于
25的梯度值且梯度
方向差不超过15度
的所有边缘点


实例2：眼睑和瞳孔边缘检测



Sobel算子检测结果


2. Canny边缘检测算子

Canny 边缘检测算子是John F. Canny于 1986年提出的一个多级边缘检测算法。



Canny边缘检测基本原理

- (1) 图象边缘检测必须满足两个条件：一能有效地抑制噪声；二必须尽量精确确定边缘的位置。
- (2) 根据对信噪比与定位乘积进行测度，得到最优化逼近算子。这就是Canny边缘检测算子。
- (3) 类似LoG边缘检测方法，也属于先平滑后求导数的方法。




Canny边缘检测算法步骤

step1: 用高斯滤波器平滑图象；

step2: 用一阶偏导的有限差分来计算梯度的幅值和方向；

step3: 对梯度幅值进行非极大值抑制；

step4: 用双阈值算法检测和连接边缘。



step1: 高斯平滑函数

$$h(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

令 $g(x,y)$ 为平滑后的图像，用 $h(x,y,\sigma)$ 对图像 $f(x,y)$ 的平滑可表示为

$$g(x, y) = h(x, y, \sigma) * f(x, y)$$

$$h(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

令 $g(x,y)$ 为平滑后的图像，用 $h(x,y,\sigma)$ 对图像 $f(x,y)$ 的平滑可表示为：

$$g(x, y) = h(x, y, \sigma) * f(x, y)$$



其中：*代表卷积。

step2: 使用一阶偏导有限差分计算梯度幅值和方向

已平滑图像 $g(x,y)$ 的梯度，可以使用 $2*2$ 的一阶有限差分近似式，计算 x 与 y 的偏导数， $f'_x(x,y)$ 与 $f'_y(x,y)$ ：

$$f'_x(x,y) \approx G_x = [f(x+1,y) - f(x,y) + f(x+1,y+1) - f(x,y+1)]/2$$

$$f'_y(x,y) \approx G_y = [f(x,y+1) - f(x,y) + f(x+1,y+1) - f(x+1,y)]/2$$

 G_x  G_y

利用如图的差分计算算子，在图像中的同一点计算x和y的偏导数梯度，其中，幅值和方位角可用以下计算公式得到

G_x		G_y	
1	-1	-1	-1
1	-1	1	1

$$M[x, y] = \sqrt{G_x(x, y)^2 + G_y(x, y)^2}$$


$$\theta[x, y] = \arctan(G_x(x, y) / G_y(x, y))$$


$M(x, y)$ 反映了图像的边缘强度，角度反映了边缘的方向，当 $M(x, y)$ 取得最大值时，方向角即反映了边缘的方向信息

step3: 非极大值抑制

仅仅得到全局的梯度，并不足以确定边缘，因此为确定边缘，需要保留局部梯度最大的点，而抑制非极大值（ Non-Maximum Suppression, NMS ）。

解决方法：利用梯度方向





将梯度角离散为圆周的四个扇区之一，以便使用 3×3 的窗口做抑制运算。四个扇区的标号为0-3，对应 3×3 邻域的四种可能组合。

在每一点上，邻域的中心像素 $M(x,y)$ 与沿着梯度线的2个像素相比，如果 $M(x,y)$ 的梯度值不比沿梯度线的2个相邻像素梯度值大，则令 $M(x,y)=0$ ，完成非极大值抑制处理

step4: 用双阈值算法检测和连接边缘

对非极大值抑制图像，作用两个阈值 th_1 和 th_2 ，两者关系 $th_1 = 0.4 * th_2$ 。 th_2 值大。


把梯度值小于 th_1 的像素的灰度值设为0，得到图像1。然后把梯度值小于 th_2 的像素的灰度值设为0，得到图像2，阈值高，图像噪音少。


由于图像2的阈值较高，去除大部分噪音，但同时也损失了有用的边缘信息。而图像1的阈值较低，保留了较多的信息，因此，可以以图像2为基础，以图像1为补充来连结图像的边缘。

链接边缘的具体步骤如下：

对图像2扫描，当遇到一非零的像素 $p(x,y)$ 时，跟踪以 $p(x,y)$ 为开始点的边线，直到轮廓线的终点 $q(x,y)$

考察图像1中与图像2中 $q(x,y)$ 点位置对应的点 $q'(x,y)$ 的8邻域。若在 $q'(x,y)$ 点的8邻域中有非零像素存在，则将其加到图像2中，作为 $r(x,y)$ 点。从 $r(x,y)$ 开始，重复第一步，直到在图像1和图像2中都无法继续为止






当完成对包含 $p(x,y)$ 的边缘线的连结之后，将这条边缘线标记为已经访问。

回到第一步，寻找下一条边缘线。重复第一步、第二步、第三步，直到图像2中找不到新边缘线为止。


至此，完成canny算子的边缘检测。









Source image



Canny



GSnake






Tsinghua

一般

GSnake

canny




1. 门限概念

所示直方图对应于一幅图像：亮目标和深背景

►对象和背景具有的灰度像素分成2组不同模式

从背景中**提取目标**的一种方法是选择门限阈值**T**，将模式分开。



a b


FIGURE 10.26 (a) Gray-level histograms th old, and (b) multiple thresholds.



从背景中提取目标的一种方法是选择门限值 T ，将模式分开

目标点：
 $f(x,y) > T$ 的点

背景点：
 $f(x,y) \leq T$ 的点



a b

FIGURE 10.26 (a) Gray-level histograms that can be partitioned by (a) a single threshold, and (b) multiple thresholds.

多目标场合：


$T_1 \leq f_1(x,y) \leq T_2$, $T_1 \leq f_2(x,y) \leq T_2$ 的点

2. 全局门限

即使用单一的一个全局门限分割图像全体。

→ $f(x, y) > T$ 的点是对象点； $f(x, y) \leq T$ 的点是背景点

➤ 分割成功的关键在于图像直方图能否很好分割



处理步骤：

- (1) 找到图像直方图的灰度级最大值，最小值
- (2) 确定最大值和最小值的中间值 T 为门限
- (3) 令背景为黑，目标对象为白，生成2值图像




FIGURE 10.28
(a) Original image. (b) Image histogram. (c) Result of global thresholding with T midway between the maximum and minimum gray levels.

(a)原图像，(b)图像的直方图，(c)使用全局门限 T 处理图像得到的结果。 T 是灰度级最大最小值的中间值，127

前景检测中的门限分割




输入彩色图像



对应背景



差值图像



高于某个给定阈值的象素点
阈值=15

门限可以从直方图视觉检测确定，也可以自动确定



算法步骤：

- (1) 选择一个**T**的初始值
- (2) 用**T**分割图像，获得**2**组像素**G₁**(灰度**>T**)和**G₂**(灰度**≤T**)
- (3) 计算区域**G₁**和**G₂**中所有像素平均灰度**g₁,g₂**
- (4) 计算新门限 $T = \frac{1}{2}(g_1 + g_2)$
- (5) 重复步骤**2—4**，直到逐次迭代所得的**T**值之差小于事先定义的参数**T₀**

通常,迭代算法在初始时使用平均灰度级作为**T**的初始值

设阈值参数 $T_0=0$
迭代3次得到
 $T=125.4$

取 $T=125$, 分割结果如图所示



a b
c

FIGURE 10.29

(a) Original image. (b) Image histogram. (c) Result of segmentation with the threshold estimated by iteration. (Original courtesy of the National Institute of Standards and Technology.)




$T=125$

3. 自适应门限

使用单一的全局门限无法进行有效分割图像时，
可以将图像细分为子图像


→对不同的子图像使用不同的门限

关键在于如何细分，如何为子图像估计门限



由于用于每个像素的门限，取决于像素在子图像中的位置→这类门限处理是自适应的

实例



原图像



全局门限分割结果



➤ 将图像细分为子图像

如划分为 4×4 的16个子图像

然后计算图像方差；

对于 方差 <100 的所有子图像，作为一幅合成图像
用上述算法估计的单一门限进行分割。

原图像




16分割子图像

对方差>100的每个子图像，**T**的初值取最大最小值的中间值，


$$T = \frac{1}{2}(g_1 + g_2)$$



其次，采用自动确定门限值的方法，重复处理每一个子图像



**16分割子
图像**




分割结果

分割结果比较

原图像

全局门限结果




16分割子图像

分割结果

分割的目的是将图像划分为不同区域。

前面几种方法所依据的物理基础：

- 根据灰度不连续性，进行边缘检测
- 通过搜寻区域之间的边界划分区域
- 用以像素性质的分布为基础的阈值分割



本节讨论以直接寻找区域为基础的分割

1. 区域生长

是一种根据事先定义的准则，将像素或子区域聚合成更大区域的过程。

基本方法：


以一组“种子”点开始，将与种子性质相似(如灰度或颜色)的相邻像素附加到生长区域的每个种子上，

- 有关连通性和相邻性的信息用于区域生长；
- 在没有像素满足加入某个区域条件时，生长停止。

实例：区域生长在焊缝检测中的应用


① 确定种子：

应用中已知有缺陷的焊缝像素为最大灰度值（此时取255）



② 因此选所有255的像素为起点

③ 选区域生长准则：





③ 选区域生长准则：

(1) 任何像素与种子间灰度差小于65

此数字是根据图像直方图得来的。

(2) 添加入每一个区域的像素必须至少与此区域中一个像素是8连通的

(3) 如果某个像素与多于一个区域相联系，就将这些区域合并



右图所示为采用上述
准则获得的区域生长
的结果。




区域生长过程确实以
可以接受的精度对缺
陷焊缝进行了分割




无须制定终止规则，因
为区域生长准则足以分
离出关心的特征。


原图像



提取255的点



区域生长结果



获得的分割边界

2. 区域分离与合并


区域生长是从一组种子点开始的。

作为替换方法，是在开始时，也可以将图像分割为一系列任意不相交的区域。

然后，通过一定的规则，对它们进行聚合合并，或分拆，以满足相应条件。

→ 四叉树分割方法：

2. 区域分离与合并



首先，将图像分割为4个区域，

(1) 如果区域内像素满足一定性质（如，具有相同灰度级）→ 分割停止

(2) 不满足一定性质 → 继续分割下去，直到满足



(3) 相邻区域满足同样性质 → 进行聚合合并

原始图像与相应的四叉树结构

a b

FIGURE 10.42

(a) Partitioned image.
(b) Corresponding quadtree.



被分割图像

相应的四叉树

如果区域 R_i 内80%像素具有性质： $|z_j - m_i| < 2\sigma_i$ 则构成一个区域。

其中 z_j 是 R_i 内第 j 个像素的灰度级， m_i 灰度是区域 R_i 的灰度级均值， σ_i 是区域内灰度级标准差。

a b c

FIGURE 10.43

(a) Original image. (b) Result of split and merge procedure. (c) Result of thresholding (a).



原图像




拆分和聚合的结果
保留了叶茎



比较：对(a)门限处理的结果：叶茎被
错误消除了



原图像



拆分和聚合的结果
保留了叶茎



比较：对(a)门限处理的结果：叶茎被
错误消除了

- 6. 1 图像分割概述
- 6. 2 基于梯度和阈值的图像分割
- 6. 3 GraphCut图像分割
- 6. 4 深度学习图像语义分割FCN

一种图像分割是抠图，是把图片或影像的某一部分从原始图片或影像中分离出来。主要功能是为了后期的合成做准备。用于人像抠图、物品抠图、图形抠图、通用抠图。



通用抠图

复杂背景精准识别，无需手动选区操作



人像抠图

达到发丝级抠图效果，处理人像细节毫不含糊



物品抠图

精确识别物品主体轮廓，适应复杂背景与光线



图形抠图

平滑的边缘处理与镂空抠图，达到令人惊叹效果



人像抠图API



商品抠图API



批量抠图API



通用抠图API

GraphCut, 作为传统图像分割算法的一个经典, 是一个非常有用的免训练、可交互的图像分割算法。原论文为: Interactive Graph Cuts for Optimal Boundary & Region Segmentation of Objects in N-D Images [1]

[1] Boykov Y Y, Jolly M P. Interactive graph cuts for optimal boundary & region segmentation of objects in ND images[C]//Proceedings eighth IEEE international conference on computer vision. ICCV 2001. IEEE, 2001, 1: 105-112.


GraphCuts是一种十分有用和流行的能量优化算法, 在计算机视觉领域普遍应用于前背景分割 (Image segmentation)、立体视觉 (stereo vision)、抠图 (Image matting) 等。



1. Graph Cut 分割的基本原理

GraphCut是一种性能出色的基于能量优化的图像分割算法，在[计算机视觉](#)领域广泛用于前景分割（Image segmentation）、立体视觉（stereo vision）、抠图（Image matting）等。

它把分割问题与图最小割（min cut）问题相关联。用无向图 $G = \langle V, E \rangle$ 表示要分割的图像， V 和 E 分别是顶点和边的集合




每条边都有一个非负权值 w_e ，可理解为cost（代价）。一个cut（割）若是边集合 E 的一个子集 C ，则这个割的cost（表示为 $|C|$ ）就是边子集 C 的所有边的权值的总和

若一个割的边的所有权值之和最小（称为最小割），则分成的两个子集就对应于图像的前景和背景，相当于完成了图像分割。

图像标签（每个像素）为 $L = \{l_1, l_2, \dots, l_p\}$ ，其中 l_i 为0（背景）或1（目标），则图像分割为 L 时，图像能量可表示为：

$$E(L) = aR(L) + B(L)$$



2. 损失函数的构成

$$E(L) = aR(L) + B(L)$$

区域能量项 $R(L) = \sum_{p \in P} R_p(l_p)$

$$\begin{aligned} R_p(l_p=1) &= -\ln \Pr(l_p | \text{'obj'}) \\ R_p(l_p=0) &= -\ln \Pr(l_p | \text{'bkg'}) \end{aligned}$$

其中， $R_p(l_p)$ 表示为像素 p 分配标签 l_p 的惩罚， $R_p(l_p)$ 能量项的权值可以通过比较像素 p 的灰度和给定的目标和前景的灰度直方图来获得，换句话说就是像素 p 属于标签 l_p 的概率

说明，Graph Cut 是有用户输入的信息的，我们会在一开始就利用这些输入信息，即哪些是前景区域 ‘obj’，哪些是背景区域 ‘bkg’，进而构建对应的概率模型 $\Pr(l_p | \text{'obj'})$ 和 $\Pr(l_p | \text{'bkg'})$ （最简单的就是灰度直方图），基于这些概率模型，我们就能计算 像素 p 的后验概率啦。从而计算出 $R_p(l_p)$ 的值了。

2. 损失函数的构成

$$E(L) = aR(L) + B(L)$$

边界平滑能量项



$$B(L) = \sum_{\{p,q\} \in N} B_{\langle p,q \rangle} \cdot \delta(l_p, l_q)$$

$$\delta(l_p, l_q) = \begin{cases} 0, & \text{if } l_p = l_q \\ 1, & \text{if } l_p \neq l_q \end{cases} \quad B_{\langle p,q \rangle} \propto \exp\left(-\frac{(I_p - I_q)^2}{2\sigma^2}\right)$$

其中， p 和 q 为邻域像素，边界平滑项主要体现分割 L 的边界属性， $B_{\langle p,q \rangle}$ 可以解析为像素 p 和 q 之间不连续的惩罚，一般来说如果 p 和 q 越相似（例如它们的灰度），那么 $B_{\langle p,q \rangle}$ 越大，如果他们非常不同，那么 $B_{\langle p,q \rangle}$ 就接近于0

3. 分割结果

黄线标注前景，红线标注背景，之后进行分割



3. 分割结果

说明：使用鼠标左键标注前景，右键标注背景，之后进行分割






图 1: GraphCut 和 Grabcut 分割结果。

➤ 图像分割：从GraphCut到GrabCut

GrabCut是对Graph Cut的改进版，是迭代的Graph Cut。OpenCV中的GrabCut算法是依据《"GrabCut" - Interactive Foreground Extraction using Iterated Graph Cuts》文章实现。

- (1) 只需在目标外面画一个框，把目标框住即可完成分割
- (2) 如果增加额外的用户交互（由用户指定一些像素属于目标），那么效果就可以更完美
- (3) 其Border Matting（边界抠图）技术使目标分割边界更加自然和平滑



- 6. 1 图像分割概述
- 6. 2 基于梯度和阈值的图像分割
- 6. 3 GraphCut图像分割
- 6. 4 深度学习图像语义分割FCN


6.4.1 基于CNN的图像分割

以服饰人物分割为例。

传统的行人分割方法，往往采用条件随机场（CRF）模型对标签的鉴别能力和几何关系进行建模，特征则采用传统特征，例如颜色、纹理等。这类方法往往是启发式的，而拓展性不强，效果不佳。


利用深度学习中的卷积神经网络（Convolutional Neural Network, CNN）对图像中的物体目标进行分割 实现对物体进行准确的像素级分割；

一个经典的卷积神经网络模型如下图所示。在卷积神经网络中，输入是图像块，即行人矩形框中的小区域；输出则是该图像块所属的类别。在分割中，类别数等于要标注的标签数。




样本标注和训练

对该卷积神经网络进行训练。在训练之前，我们需要对行人矩形框样本进行区域标注，标注出行人区域和背景区域，然后利用卷积神经网络进行训练。在训练过程中，我们提出采用下图所示的采样方法。



通过深度学习的方法，可以训练一个基于分类的卷积神经网络。对于卷积神经网络来说，最重要的一点就是要要有足够多的训练样本。



初步的分割结果

采用上述的方法，进行初步的实验。训练阶段是在百度行人分割数据集上进行的。目前在测试集上的实验结果是：行人前景的召回率=81.79%，准确率=75.09%，总体分类错误率=7.89%。下图显示了初步的几组分割结果。






6.4.2 图像语义分割FCN算法

- 计算机视觉任务:

分类classification 检测 detection 分割segmentation 识别recognition



(a) Image classification



(b) Object localization




(c) Semantic segmentation



(d) This work

1、语义分割(semantic segmentation):

语义分割是对图像中的每个像素加标签的过程，而实例分割则能更好的理解个体（进一步区分同类个体）




语义分割



实例分割


2、全卷积神经网络(FCN)

- CNN对分类效果好，不适合直接做分割（前面的CNN分割例子）
- CNN模型的输入维度固定
- FCN是对CNN改进，适合直接用于分割的模型
- 输入：任意大小图片
- 输出：各个像素对应的类别




3、网络结构

- 只有卷积层，没有全连接层
- 上采样(upsampling)




FCN将这3层表示为卷积层，卷积核的大小(通道数，宽，高)分别为(4096,1,1)、(4096,1,1)、(1000,1,1)。所有的层都是卷积层，故称为全卷积网络

FCN采用反卷积层对最后一个卷积层的**feature map**进行**上采样**,使它恢复到输入图像相同的尺寸,从而可以对每个像素都产生了一个预测,同时保留了原始输入图像中的空间信息,最后在上采样的特征图上进行逐像素分类。



• 上采样（up sampling）


普通池化缩小了图片的尺寸
通过反卷积得到和原图等大的分割图



对于最后一层的输出图像，需要进行32倍的上采样，以得到原图一样的大小。


• 反卷积 Deconvolution

普通池化缩小了图片的尺寸，通过反卷积得到和原图等大的分割图



• 上池化和上采样


普通池化缩小了图片的尺寸，过反卷积得到和原图等大的分割图



两种方式

(a)

上池化




(b)


上采样

- FCN- x_S 的网络结构

- 卷积化 (Convolutional)
- 上采样 (Upsample)
- 跳跃结构 (Skip Layer)



对于FCN-32s，直接对pool5 feature进行32倍上采样获得32x upsampled feature，再对32x upsampled feature每个点做softmax prediction获得32x upsampled feature prediction（即分割图）



实验数据集：The PASCAL Visual Object Classes Challenge 2012 (VOC2012)



a.



b.

训练样本数：2913

补充样本数：10582

测试样本数：1456

评测方式：Jaccard Index

B-ground	Aero plane	Bicycle	Bird	Boat	Bottle	Bus
Car	Cat	Chair	Cow	Dining-Table	Dog	Horse
Motorbike	Person	Potted-Plant	Sheep	Sofa	Train	TV/Monitor



4. 实验与分析

• 实验一

- Baseline
- 网络结构:vgg16
- Pascal VOC平均得分: **62.04**

类别	电视	飞机	单车	鸟类	船	瓶子	巴士	轿车	猫	椅子
得分	53.19	70.11	39.77	74.35	53.06	57.06	79.50	74.90	73.54	22.35
类别	牛	餐桌	狗	马	摩托	人	盆栽	羊	沙发	火车
得分	61.99	53.49	67.07	62.90	75.81	74.30	46.62	70.01	38.57	63.50

- 分割实验结果







原图

Baseline

Baseline+多尺度

进一步提升



随后，又提出了多种改进的分割方法，SegNet/DeconvNet，DeepLab
以及引入后端的进一步处理，如全连接条件随机场(**DenseCRF**)、MRF-
马尔科夫随机场、高斯条件随机场(**G-CRF**)



给某公司做的基于FCN的工件分割

4. 实验与分析

- 难点问题原因



1. 思考：图像分割中，无语义分割与有语义分割的区别