

数字图像处理

Digital Image Processing

第9讲 图像复原

Image restoration



清华大学电子系 王生进

9.1 图像退化和复原模型

Image degradation and restoration model

9.2 无约束复原 Unconstrained restoration

9.3 有约束复原 Constrained restoration

9.4 交互式复原 Interactive restoration


9.5 几何失真校正 Geometric distortion correction

9.6 深度学习图像复原

9.1 Image degradation and restoration model

Tsinghua

实际应用中，无论是由光学，光电方法，还是电子方法获得的图像，都会有不同程度的退化。



由于获得图像的方法不同，其退化形式也是多种多样的，如：传感器内部噪声；摄像机未聚焦；物体与镜头之间的相对移动；胶片的非线性和几何畸变，等。

图像退化产生原因





<http://www.cctime.com/html/2012-4-16/20124161156222780.htm>

随机噪声



http://bc.hangzhou.com.cn/content/2013-03/30/content_4673245.htm

运动模糊



<http://www.netposa.com/Home/New/detail/id/323>

散焦模糊



<http://zhidao.baidu.com/question/570416834.html>

图像复原也称为图像恢复，是数字图像处理中一个重要的技术，最大限度恢复图像原貌

(1) 图像复原的目的


与图像增强相同，最终目的是改善给定图像质量，有一定交叉的领域。

(2) 与图像增强的区别

增强主要是一个主观过程，复原大部分是一个客观过程。




通常，**图像增强**被认为是一种对比度拉伸，因为其主要基于提供给观看者**喜欢接受的图像**



图像增强是一个探索过程，为了人类的主观视觉系统的特点而进行的一种改善图像的方法；

图像复原有明确的，客观的，统一的评价标准，
以便对结果作出最佳估计




例如：


通过去模糊函数去除图像的模糊，被认为是属于图像复原技术的范畴。

图像复原概念:


图像复原,是利用退化现象的某种先验知识,
复原被退化的模糊图像,



因而,复原技术就是把退化过程模型化,然后,采用相反的过程处理,复原原图像。



图像复原方法 关系示意图




9.1.1 Degradation and restoration model

Tsinghua

1. 退化和复原过程的物理模型

一个简单的通用图像退化模型如下：


输入图像为 $f(x, y)$ ，外加噪声 $n(x, y)$ ，
退化图像为 $g(x, y)$ ，



(1) 图像退化过程的模型化

- 1) 一个作用在输入图像 $f(x, y)$ 上的退化函数 H ,
- 2) 它与一个外加噪声 $n(x, y)$ 共同作用,
- 3) 产生一个退化图像 $g(x, y)$ 。

图像复原的目的, 就是获得关于原始图像 $f(x, y)$ 的近似估计 $\hat{f}(x, y)$




(2) 关于系统H（即退化函数）的线性

系统分类方法很多，如
线性系统和非线性系统，
离散/连续，
时变/时不变。



在图像复原处理中，尽管非线性系统模型更具有普遍性，

但它却常常无解，或难于计算，给处理带来很大困难，

⇒ 因此，在图像复原处理中，往往用线性系统加以近似，




线性系统理论，可以直接用于图像复原，即在图像复原处理中，主要采用线性复原技术。



(3) 数学模型描述

线性系统就是具有均匀性和相加性的系统



对于系统 H ，输入和输出具有如下关系

$$g(x, y) = H[f(x, y)] + n(x, y)$$

若不考虑噪声, 即有 $n(x, y)=0$, 系统H有如下性质

1) 相加性

$$H[f_1(x, y) + f_2(x, y)] = H[f_1(x, y)] + H[f_2(x, y)]$$

2) 一致性

$$H[k_1 f_1(x, y)] = k_1 H[f_1(x, y)]$$


3) 线性

$$H[k_1 f_1(x, y) + k_2 f_2(x, y)] = k_1 H[f_1(x, y)] + k_2 H[f_2(x, y)]$$

4) 位置(空间)不变性: 对任意 $f(x, y)$ 和 a, b


$$H[f(x-a, y-b)] = g(x-a, y-b)$$

空间不变性表明, 线性系统在图像任意空间位置的响应,










只与在该空间位置的输入值有关, 而与空间位置本身无关

如目标运动造成的模糊退化



2. 常见具体退化模型

4种常见退化模型示意图。其中，
(a), (b), (c) 为空间不变：只与输入有关，与位置无关；
(b), (c), (d) 为线性退化。



(a)

(b)

(c)


(d)

图(a)是一种非线性退化的情景




摄影胶片的曝光过程可用这种退化模型表示。

表示原来亮度光滑或形状规则的图案，变得不太规则了，原来线性变化的亮度变得非线性了。


原因如下



原图像



退化图像 (a)



摄影胶片的光敏特性为：

胶片上的银密度是曝光量的对数函数。除中段外，两端为非线性。


图(b)表示一种模糊造成的退化。

原图像

在许多实用的光学成像系统中，由于孔径衍射所产生的退化，

可用右图所示的这种退化模型来表示




退化图像




(b)

图(c)为一种目标运动造成的模糊退化，较常见。

原图像




(c)



退化图像

图(d)表示随机噪声叠加产生的退化，产生了空间变化



空间发生变化，不满足

$$H[f(x-a, y-b)] = g(x-a, y-b)$$

退化图像

(d)

3. 离散退化模型的计算

(1) 首先用一维函数说明基本概念:


$$g(x) = H[f(x)] + n(x)$$

假定有两个函数 $f(x)$, $h(x)$, 被采样后形成A维和B维阵列, 于是

$f(x)$ 变成在 $x=0, 1, 2, \dots, A-1$ 范围内的离散变量;

$h(x)$ 变成在 $x=0, 1, 2, \dots, B-1$ 范围内的离散变量。

根据退化模型



$g(x)$ 可以由 $f(x)$ 和 $h(x)$ 的卷积来计算。


这里，如果 $f(x)$ ， $h(x)$ 都是周期为 N 的序列，那么时域离散卷积可定义如下

$$g(x) = \sum_{m=0}^{N-1} f(m)h(x-m) \quad x = 0, 1, 2, \dots, N-1$$

$$g(x) = \sum_{m=0}^{N-1} f(m)h(x-m) \quad x = 0, 1, 2, \dots, N-1$$

卷积结果 $g(x)$ 也是周期为 N 的序列。周期卷积可以利用卷积定理进行快速计算，即求两函数的傅里叶变换之乘积的反变换。

如果 $f(x)$ ， $h(x)$ 均为非周期的序列，则需要用扩展法将它们扩展为周期序列



这样，就可以将非周期的卷积问题转换为周期卷积问题来解决。

➤对非周期函数进行周期序列扩展

这里，特别注意DFT的一个性质：

即DFT自动将输入信号周期化，该周期是函数的长度。如果两序列点数不同，将产生混叠。


设采样周期为M，这里为避免周期重叠，取 $M \geq A+B-1$ ，用 $f_e(x)$, $h_e(x)$ 表示扩展后的函数，则由退化模型可得卷积：



$$g_e(x) = \sum_{m=0}^{M-1} f_e(m)h_e(x-m) \quad x = 0,1,2,\dots,M-1$$

由于DFT自动将信号周期化，在利用DFT将空域卷积计算转换为频域乘积计算时，对非周期输入信号函数的自动周期化，周期化处理不当，将产生问题。


下面，讨论2个不同计算方法做2个离散函数卷积的例子

2个离散函数






$x=0$ 的一个计算周期，注意虚线内乘积不为0，导致



用扩展函数 $M \geq A+B-1$
进行卷积计算的结果

比较正确结果



$$g_e(x) = \sum_{m=0}^{M-1} f_e(m)h_e(x-m) \quad x = 0,1,2,\dots,M-1$$

$g_e(x)$ 的周期也为M

在利用DFT将空域卷积计算转换为频域乘积计算时，
对非周期输入信号函数的要做扩展处理；

经过这样的扩展处理，一个非周期的卷积问题，转换为了一个周期卷积问题，因此可以利用卷积定理进行快速计算。

$$g_e(x) = \sum_{m=0}^{M-1} f_e(m) h_e(x-m) \quad x = 0, 1, 2, \dots, M-1$$


将上式采用矩阵形式表述离散退化模型，可以表示成如下形式

$$\mathbf{g} = \mathbf{H}\mathbf{f}$$

$$\begin{bmatrix} g_e(0) \\ g_e(1) \\ \dots \\ g_e(M-1) \end{bmatrix} = \begin{bmatrix} h_e(0) & h_e(-1) & \dots & h_e(-M+1) \\ h_e(1) & h_e(0) & \dots & h_e(-M+2) \\ \dots & \dots & \dots & \dots \\ h_e(M-1) & h_e(M-2) & \dots & h_e(0) \end{bmatrix} \begin{bmatrix} f_e(0) \\ f_e(1) \\ \dots \\ f_e(M-1) \end{bmatrix}$$

利用 $h_e(x)$ 的周期性, $h_e(x) = h_e(x \pm M)$ 将
H 矩阵改写成如下形式

$$\begin{bmatrix} h_e(0) & h_e(-1) & \dots & h_e(-M+1) \\ h_e(1) & h_e(0) & \dots & h_e(-M+2) \\ \dots & & & \\ h_e(M-1) & h_e(M-2) & \dots & h_e(0) \end{bmatrix}$$



$$H = \begin{bmatrix} h_e(0) & h_e(M-1) & \dots & h_e(1) \\ h_e(1) & h_e(0) & \dots & h_e(2) \\ h_e(2) & h_e(1) & \dots & h_e(3) \\ \dots & \dots & \dots & \dots \\ h_e(M-1) & h_e(M-2) & \dots & h_e(0) \end{bmatrix}$$

可看出**H**是一个循环矩阵

(2) 向二维图像模型的推广

周期扩展

$$f_e(x, y) = \begin{cases} f(x, y) & 0 \leq x \leq A-1, 0 \leq y \leq B-1 \\ 0 & A \leq x \leq M-1, B \leq y \leq N-1 \end{cases}$$

$$h_e(x, y) = \begin{cases} h(x, y) & 0 \leq x \leq C-1, 0 \leq y \leq D-1 \\ 0 & C \leq x \leq M-1, D \leq y \leq N-1 \end{cases}$$

◆ $f(x, y)$ 为 $A \times B$, $h(x, y)$ 为 $C \times D \Rightarrow$ 扩展

◆ M, N 为周期, $M \geq A+C-1$, $N \geq B+D-1$

$$g_e(x, y) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} f_e(m, n) h_e(x-m, y-n)$$

$x = 0, 1, 2, \dots, M-1, y = 0, 1, 2, \dots, N-1$

$$g_e(x, y) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} f_e(m, n) h_e(x-m, y-n)$$

$x = 0, 1, 2, \dots, M-1, y = 0, 1, 2, \dots, N-1$

经上述推导，获得的二维退化模型为上式的二维卷积形式。它也可以用矩阵表示成如下形式

$$g = Hf$$

其中， g, f 为 MN 维列向量； H 为 $MN \times MN$ 维矩阵

$$H = \begin{bmatrix} h_e(0) & h_e(M-1) & \dots & h_e(1) \\ h_e(1) & h_e(0) & \dots & h_e(2) \\ h_e(2) & h_e(1) & \dots & h_e(3) \\ \dots & \dots & \dots & \dots \\ h_e(M-1) & h_e(M-2) & \dots & h_e(0) \end{bmatrix} \quad \text{一维场合}$$

类似于一维场合，对于二维有H的循环矩阵：

$$H = \begin{bmatrix} H_0 & H_{M-1} & H_{M-2} & \dots & H_1 \\ H_1 & H_0 & H_{M-1} & \dots & H_2 \\ H_2 & H_1 & H_0 & \dots & H_3 \\ \dots & \dots & \dots & \dots & \dots \\ H_{M-1} & H_{M-2} & H_{M-3} & \dots & H_0 \end{bmatrix}$$

$$H = \begin{bmatrix} H_0 & H_{M-1} & H_{M-2} & \dots & H_1 \\ H_1 & H_0 & H_{M-1} & \dots & H_2 \\ H_2 & H_1 & H_0 & \dots & H_3 \\ \dots & \dots & \dots & \dots & \dots \\ H_{M-1} & H_{M-2} & H_{M-3} & \dots & H_0 \end{bmatrix}$$


H是分块循环矩阵

其中, **H_j**
是**N×N**的一个循环矩阵

$$H_j = \begin{bmatrix} h_e(j,0) & h_e(j,N-1) & \dots & h_e(j,1) \\ h_e(j,1) & h_e(j,0) & \dots & h_e(j,2) \\ h_e(j,2) & h_e(j,1) & \dots & h_e(j,3) \\ \dots & \dots & \dots & \dots \\ h_e(j,N-1) & h_e(j,N-2) & \dots & h_e(j,0) \end{bmatrix}$$

9.1.2 Unconstrained and constrained restoration

1. 无约束复原概念



由退化模型可以得到

$$g = Hf + n \Rightarrow n = g - Hf$$

当 $\hat{n}$ 未知时，希望找到一个 f 的估计 $\hat{f}$ ，使得 $H\hat{f}$ 在最小平方意义上近似于 g

即使得 $\|n\|^2 = \|g - H\hat{f}\|^2$ 为最小。

实际上是求 $L(\hat{f}) = \|g - H \hat{f}\|^2$ 的最小值问题。


这里选择 f 的估计 $\hat{f}$ ，使得 $L(\hat{f})$ 最小时，除了要求 $L(\hat{f})$ 最小以外，没有其他任何条件的约束，因此，称为无约束复原。

◆ 对上式求极小值的方法，就是利用一般的求极值的方法，即把 $L(\hat{f})$ 对 $\hat{f}$ 微分，并使其结果为零 $\Rightarrow$ 7.2节介绍


2. 有约束复原概念

无约束复原没有考虑噪声。在最小平方复原处理中，为了在数学上更准确处理，常常附加约束条件——如:根据噪声统计特性。

➤ 如果知道原始图像的某种变换 Qf 具有某种性质，例如，选择 f 的一个微分算子 Q ，作为一种约束，当噪声较大时， Qf 较大。因此可令 Qf 最小作为一种约束




此概念即为：有约束复原



因此，有约束复原也可以看作：

寻找一个最优估计 $\hat{f}$ ，使形式为 $\|Q\hat{f}\|^2$ 的函数，
在服从约束条件 $\|g - H\hat{f}\|^2 = \|n\|^2$ 的情况下为
最小。

寻找一个最优估计 $\hat{f}$ ，使形式为 $\|Q\hat{f}\|^2$ 的函数，
在服从约束条件 $\|g - H\hat{f}\|^2 = \|n\|^2$ 的情况下为
最小



即最小平方复原问题，可看成是使形式为
 $\|Q\hat{f}\|^2$ 的函数，服从约束条件

$$\|g - H\hat{f}\|^2 = \|n\|^2$$

的最小化问题。 $\Rightarrow$ 即为有约束复原

这种有附加条件的极值问题，可用拉格朗日乘数法解决。将约束条件表示为 $\lambda(\|g - H \hat{f}\|^2 - \|n\|^2)$

即寻找一个 $\hat{f}$ ，使下列准则函数为最小

$$L(\hat{f}) = \|Q \hat{f}\|^2 + \lambda(\|g - H \hat{f}\|^2 - \|n\|^2)$$

其中，常数 λ 为拉格朗日系数。

◆用一般求极值的方法，将上式对 $\hat{f}$ 求微分，使其结果为零 $\Rightarrow$ 7.3节介绍

9.1 图像退化和复原模型

Image degradation and restoration model

9.2 无约束复原 Unconstrained restoration

9.3 有约束复原 Constrained restoration


9.4 交互式复原 Interactive restoration

9.5 几何失真校正 Geometric distortion correction

9.6 深度学习图像复原

由退化模型可以得到

$$g = Hf + n \Rightarrow n = g - Hf$$



在频域表示为

$$G(u, v) = H(u, v) \cdot F(u, v) + N(u, v)$$

当 n 未知时, 希望找到一个 f 的估计 $\hat{f}$, 使得 $H\hat{f}$ 在最小平方意义上近似于 g


即使得 $\|n\|^2 = \|g - H\hat{f}\|^2$ 为最小。

即求 $L(\hat{f}) = \|g - H \hat{f}\|^2 = (g - H \hat{f})^T (g - H \hat{f})$ 最小

◆ 把 $L(\hat{f})$ 对 $\hat{f}$ 微分，并使其结果为零



$$\frac{\partial L(\hat{f})}{\partial \hat{f}} = \frac{\partial \|g - H \hat{f}\|^2}{\partial \hat{f}} = 0 \quad (1)$$



$$\frac{\partial L(\hat{f})}{\partial \hat{f}} = \frac{\partial (\|g\|^2 - 2g^T H \hat{f} + \|H \hat{f}\|^2)}{\partial \hat{f}} = 0 \quad (2)$$

$$-2g^T H + 2(H \hat{f})^T H = 0 \quad (3)$$

$$\frac{\partial(\|g\|^2 - 2g^T H \hat{f} + \|H \hat{f}\|^2)}{\partial \hat{f}} = 0$$

$$-2g^T H + 2(H \hat{f})^T H = 0$$


另一方法

$$\frac{\partial(\|g - H \hat{f}\|^2)}{\partial \hat{f}} = 0 \quad (4)$$


$$2(g - H\hat{f})^T (-H) = 0 \Rightarrow -2H^T (g - H\hat{f}) = 0 \quad (5)$$

$$-2g^T H + 2(H \hat{f})^T H = 0 \quad (6)$$

$$-(H^T g)^T + (H^T H \hat{f})^T = 0 \quad (7)$$



$$-H^T g + H^T H \hat{f} = 0 \quad (8)$$



$$H^T H \hat{f} = H^T g \quad (9)$$

$$\hat{f} = (H^T H)^{-1} H^T g \quad (10)$$

令 $M=N \Rightarrow H$ 为方阵, 且 H^{-1} 存在, 可得

$$\hat{f} = H^{-1}(H^T)^{-1}H^T g = H^{-1}g \quad (11)$$

即得到原图像的估计

$$\hat{f} = H^{-1}g$$

在后面的逆滤波中可推导出，上式在频域有

$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)}$$

它表明，如果知道 $g(x, y)$ 和 $h(x, y)$ ，即可求出 $\hat{F}(u, v)$ ，再经过傅里叶反变换， $\hat{f}(x, y)$ 可得。


1. 基本原理

$$\hat{f} = H^{-1}g$$

$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)}$$

逆滤波中讨论 $\hat{F}(u, v), G(u, v), H(u, v)$ 的求解方法，也称反向滤波，是一种无约束复原。

可利用矩阵运算解决复原问题；但分块循环矩阵H较大，计算量大。将其对角化后的运算较为简单




可利用变换，将分块循环矩阵H对角化。推导可得

$$H = WDW^{-1}$$

其中，D是MN × MN对角阵，元素与h的傅里叶变换有关，

W是由 $\exp[j2\pi **/*]$ 构成的MN × MN维矩阵。

将 $H = WDW^{-1}$ 带入 $\hat{f} = H^{-1}g$ 中



$$\hat{f} = H^{-1}g \Rightarrow \hat{f} = WD^{-1}W^{-1}g \quad (1)$$

(1) 两边乘以 W^{-1} 逆 $W^{-1} \hat{f} = D^{-1}W^{-1}g \quad (2)$

可以证明, $W^{-1}g$ 中的各元素为 $G(u, v)$, 是 $g_e(x, y)$ 的二维傅里叶变换。

同理，可以证明， $W^{-1} \hat{f}$ 中的各元素为 $\hat{F}(u, v)$
而D的对角元素由H(u, v) 构成。（忽略系数）

因此可将 $W^{-1} \hat{f} = D^{-1}W^{-1}g$ 写成如下形式

两边乘以 **D**，得 $W^{-1}g = D \cdot W^{-1} \hat{f}$ (3)

$$G(u, v) = H(u, v) \cdot \hat{F}(u, v) \quad (4)$$

由此可得 $\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)}$ (5)

经由傅里叶反变换，可得原图像的估计：

$$\hat{f}(x, y) = \mathcal{F}^{-1}[\hat{F}(u, v)] = \mathcal{F}^{-1}\left[\frac{G(u, v)}{H(u, v)}\right]$$

由此可知，**已知退化图像的傅里叶变换和“滤波”传递函数**，可得原图像傅里叶变换，

对原图像的傅里叶变换求反变换，即可得原图像的估计 $\hat{f}(x, y)$

在此公式中， $G(u, v)$ 乘以 $1/H(u, v)$ ，

$$\hat{F}(u, v) = \frac{1}{H(u, v)} G(u, v)$$

求得 $\hat{f}(x, y) = \mathcal{F}^{-1}[\hat{F}(u, v)] = \mathcal{F}^{-1}\left[\frac{G(u, v)}{H(u, v)}\right]$

$1/H(u, v)$ 起了逆向滤波的作用，相当于一个逆滤波过程，（通常，乘 $H(u, v)$ 表示正向滤波）

⇒上述过程称为逆滤波。

2. 当考虑噪声时 (前面的讨论未考虑噪声)

则有 $G(u, v) = H(u, v) \cdot F(u, v) + N(u, v)$

带入前式, $\hat{F}(u, v) = \frac{1}{H(u, v)} G(u, v)$ 可得

$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)} = F(u, v) + \frac{N(u, v)}{H(u, v)} \quad \text{若} N \text{为} 0, \text{则} \hat{F} \text{即为} F$$

即 $G(u, v)$ 的组成项中, 一部分可以经逆滤波还原为 $F(u, v)$, 一部分将形成 $\frac{N(u, v)}{H(u, v)}$

下面，对上式表达式进行分析

$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)} = F(u, v) + \frac{N(u, v)}{H(u, v)}$$

问题1：

$N(u, v)$ 为随机噪声，其傅里叶变换未知。所以，即使已知退化函数 $H(u, v)$ ，也不能准确复原未退化的原始图像。

因此要准确复原图像需要增加约束条件

$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)} = F(u, v) + \frac{N(u, v)}{H(u, v)}$$

问题2：如果 $H(u, v)$ 很小或为0，则导致复原结果不稳定；且 $N(u, v)/H(u, v)$ 值过大，掩盖真实信号 $F(u, v)$ ，使复原图像失真

⇒实际中的确存在这种情况：

$H(u, v)$ 随 u, v 与原点距离增加而迅速减小，而噪声 $N(u, v)$ 却变化缓慢。

必须采取一种折衷方法解决 $H(u, v)$ 零点问题


3. 实际逆滤波处理

为避免上述0点问题，逆滤波不直接采用 $1/H(u, v)$ ，而是采用另外一个关于 u, v 的函数 $M(u, v)$ 。 $M(u, v)$ 定义如下：

$$M(u, v) = \begin{cases} \frac{1}{H(u, v)} & u^2 + v^2 \leq \omega_0 \\ 1 & u^2 + v^2 > \omega_0 \end{cases}$$

ω_0 的选择基准，是将 $H(u, v)$ 的零点排除在此邻域之外。

◆实际逆滤波处理框图



因此，实际的原始图像傅里叶估计为

$$\hat{F}(u,v) = [F(u,v)H(u,v) + N(u,v)] \cdot M(u,v)$$

◆逆滤波实例

模糊图像



◆逆滤波实例

选取退化函数

$$H(u, v) = e^{-k[(u-M/2)^2 + (v-N/2)^2]^{5/6}}$$

$$k = 0.0025, \quad M = N = 480$$


大气湍流造成的退化
模糊图像



a	b
c	d

FIGURE 5.27

Restoring
Fig. 5.25(b) with
Eq. (5.7-1).
(a) Result of
using the full
filter. (b) Result
with H cut off
outside a radius of
40; (c) outside a
radius of 70; and
(d) outside a
radius of 85.



截止半径70

截止半径80

9.2.2 Eliminate linear uniform motion blur

本小节以运动模糊为例，讨论如何估计 $H(u, v)$

1. 运动模糊模型

获取图像时，由于景物和摄像机之间相对运动，往往造成图像模糊。

- 假设图像 $f(x, y)$ 有一个平面运动；
- $x_0(t), y_0(t)$ 为 x, y 方向上的变化分量；
- 记录介质的总曝光量是在快门打开到关闭这段时间 T 的积分， $g(x, y)$ 为模糊图像

如果模糊图像是匀速直线运动造成的，则模糊后图像上任一点值，可以由下式获得

模糊图像

快门时间

x方向变化量

y方向变化量

$$g(x, y) = \int_0^T f[x - x_0(t), y - y_0(t)] dt$$


采集图像

2. 图像的复原

令 $G(u, v)$ 为模糊图像 $g(x, y)$ 的傅里叶变换

$$G(u, v) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) e^{-j2\pi(ux+vy)} dx dy$$

$$= \int_0^T \left[\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x - x_0(t), y - y_0(t)) e^{-j2\pi(ux+vy)} dx dy \right] dt$$



由傅里叶变换的位移性质

$$= \int_0^T \left[F(u, v) e^{-j2\pi[ux_0(t)+vy_0(t)]} \right] dt$$

$$= \int_0^T [F(u, v) e^{-j2\pi[ux_0(t)+vy_0(t)]}] dt$$

$$= F(u, v) \int_0^T e^{-j2\pi[ux_0(t)+vy_0(t)]} dt$$

如果令 $H(u, v)$ 代表右边的部分

$$H(u, v) = \int_0^T e^{-j2\pi[ux_0(t)+vy_0(t)]} dt$$

则可得到熟悉的表达式

$$G(u, v) = H(u, v) \cdot F(u, v)$$

关系式 $G(u, v) = H(u, v) \cdot F(u, v)$

是已知的退化模型的傅里叶变换式。如果 $x_0(t), y_0(t)$ 的性质已知，传递函数可以由

$$H(u, v) = \int_0^T e^{-j2\pi[ux_0(t)+vy_0(t)]} dt$$

获得，则 $f(x, y)$ 可以得到恢复。

3. 只有一维方向运动的场合

当模糊图像是由景物在x方向上的匀速直线运动造成的，则模糊后图像上任意点的值为

$$g(x, y) = \int_0^T f[x - x_0(t), y] dt$$

设图像内景物的总位移量为c，总运动时间为T，则运动位移随时间的变化为 $x_0(t) = \frac{ct}{T}$

由 $H(u, v) = \int_0^T e^{-j2\pi[ux_0(t)+vy_0(t)]} dt$



$$x_0(t) = \frac{ct}{T}$$

$$y_0(t) = 0$$

将其代入上式

得 $H(u, v) = \int_0^T e^{-j2\pi u c t/T} dt$


$$= \frac{T}{\pi u c} \sin(\pi u c) e^{-j\pi u c}$$

现在得到

$$H(u, v) = \frac{T}{\pi u c} \sin(\pi u c) e^{-j\pi u c}$$

从上式可知，当 $u = \frac{n}{c}$ (n 为整数)

会导致 $H(u, v)=0$ ，那么，在这些点上无法用逆滤波方法复原出原图像。



因此不能取 u 在这些点的值，需采用其他方法解决

当允许 y 分量也变化，按


$$y_0(t) = \frac{bt}{T}$$

则退化函数变为

$$H(u, v) = \frac{T}{\pi (u c + v b)} \sin[\pi (u c + v b)] e^{-j\pi (u c + v b)}$$

$$H(u, v) = \frac{T}{\pi (u c + v b)} \sin[\pi (u c + v b)] e^{-j\pi (u c + v b)}$$

$c = b = 0.1, T = 1$ 取值时的模糊结果如图所示
 此时 c 、 b 应为移动所占原图像的比例



a b

FIGURE 5.26 (a) Original image. (b) Result of blurring using the function in Eq. (5.6-11) with $a = b = 0.1$ and $T = 1$.

复原实例

移动32像素生成

取移动距离32复原

移动24复原


移动40复原




(a)



(b)



(c)



(d)

图 5.3.3 消除匀速直线运动造成的模糊

4、运动模糊在频域的复原计算方法

采用维纳滤波处理，

见维纳滤波实例。

9.1 图像退化和复原模型

Image degradation and restoration model

9.2 无约束复原 Unconstrained restoration

9.3 有约束复原 Constrained restoration

9.4 交互式复原 Interactive restoration


9.5 几何失真校正 Geometric distortion correction

9.6 深度学习图像复原


在无约束图像复原中，只要已知退化函数即可进行图像复原。

但是实际图像存在噪声！！

前节提到，在考虑噪声的情况下，存在2个问题：



随机噪声未知； 零点问题



$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)} = F(u, v) + \frac{N(u, v)}{H(u, v)}$$

- $N(u, v)$ 为随机噪声，其傅里叶变换未知。所以，即使已知退化函数 $H(u, v)$ ，也不能准确复原未退化的原始图像。
- 由于退化函数 $H(u, v)$ 存在零点问题，复原计算只能限制在零点附近的有限区域。

1. 有约束复原

有约束复原，是指除了已知退化系统传递函数外，还要根据其他条件作为约束：

- 噪声统计特性，或
- 噪声与图像的相关信息进行复原

有约束复原，即是求有附加条件的极值问题，仍然采用拉格朗日乘数法解决。

有约束复原的计算方法如下：

寻找一个 $\hat{f}$ ，使下述准则函数为最小

$$L(\hat{f}) = \|Q \hat{f}\|^2 + \lambda (\|g - H \hat{f}\|^2 - \|n\|^2)$$

其中，常数 λ 为拉格朗日系数。

同时


用已知原始图像的某种变换性质 Qf ，
作为一种附加的约束，或者 $Qf = d$

寻找一个 $\hat{\mathbf{f}}$ ，使下述准则函数为最小

$$L(\hat{\mathbf{f}}) = \|\mathbf{Q} \hat{\mathbf{f}}\|^2 + \lambda(\|\mathbf{g} - \mathbf{H} \hat{\mathbf{f}}\|^2 - \|\mathbf{n}\|^2)$$

其中，常数 λ 为拉格朗日系数。


或者 $L(\hat{\mathbf{f}}) = \|\mathbf{Q} \hat{\mathbf{f}}\|^2 - \mathbf{d}^2 + \lambda(\|\mathbf{g} - \mathbf{H} \hat{\mathbf{f}}\|^2 - \|\mathbf{n}\|^2)$



◆用一般求极值的方法，将上式对 $\hat{\mathbf{f}}$ 求微分，使其结果为零。

2. 与解无约束复原相似，对上式微分令其为零，可得有约束复原公式：

$$\frac{\partial L(\hat{f})}{\partial \hat{f}} = \frac{\partial [\|Q \hat{f}\|^2 + \lambda(\|g - H \hat{f}\|^2 - \|n\|^2)]}{\partial \hat{f}} = 0$$



$$\hat{f} = [H^T H + s Q^T Q]^{-1} H^T g \quad s = 1/\lambda$$

$$\hat{f} = [H^T H + sQ^T Q]^{-1} H^T g \quad s = 1/\lambda$$

Qf 为原始图像的某种变换，具有某种性质。例如，选择 f 的一个线性算子 Q （如变换矩阵，或微分算子）。

对于不同的原图像的知识，可以获得不同的 Q ，则可求得不同形式的解。

下面，讨论2种重要的最小二乘法约束复原，它们分别是通过选择不同的 Q 而获得的。

➤ 维纳滤波

➤ 最小平方复原

前面讨论的逆滤波，没有很好地解决如何处理噪声的问题。

→ 因为，图像常常伴随有噪声，因此，在复原中，始终存在前面提到的2个问题：

(1) 无法精确复原；

(2) 零点问题

本节讨论，将综合考虑退化函数和噪声统计特性两个方面，讨论复原处理的方法，即

→维纳(Wiener)滤波方法，

也称最小均方误差滤波。


1. 复原特性

该复原方法是建立在认为图像和噪声是随机过程的基础上，目标是找一个未模糊图像 f 的估计 $\hat{f}$ ，并且

⇒能够使两者之间的均方误差为最小

$$e^2 = E\{(f - \hat{f})^2\} \quad \text{即有约束复原}$$

$E\{\bullet\}$ 表示期望值。



即 维纳滤波器

2. 维纳滤波器

假定噪声和图像不相关，误差度量由下式给出 $e^2 = E\{(f - \hat{f})^2\}$

其中 $\hat{f} = [H^T H + sQ^T Q]^{-1} H^T g$

定义： $Q^T Q = R_f^{-1} R_n$

其中， R_f, R_n 分别是原始图像和噪声的相关矩阵

$$\hat{f} = [H^T H + sQ^T Q]^{-1} H^T g$$

定义: $Q^T Q = R_f^{-1} R_n$

其中, R_f, R_n 分别是原始图像和噪声的相关矩阵

结论: 若选用原始图像和噪声的相关矩阵 R_f, R_n 来表示 Q , 则可以得到具有最小均方误差的复原结果 (N. Wiener, 1942)

将式 $\hat{f} = [H^T H + sQ^T Q]^{-1} H^T g$ 中的 $Q^T Q$ 由 $R_f^{-1} R_n$

代替，可得：
$$\hat{f} = [H^T H + sR_f^{-1} R_n]^{-1} H^T g$$

上式在频域的解为：

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + s [S_n(u, v) / S_f(u, v)]} \right] G(u, v)$$

上式在频域的解为：

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + s [S_n(u, v) / S_f(u, v)]} \right] G(u, v)$$

可使式 $e^2 = E\{(f - \hat{f})^2\}$ 中的误差函数取最小值解，
并可在频域用上式计算得到。

提问： R_f, R_n 分别如何计算呢？

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + s [S_n(u, v) / S_f(u, v)]} \right] G(u, v)$$

其中 $R_f = E\{f f^T\}$ $R_n = E\{n n^T\}$ 分别是
f, **n** 的相关矩阵。

R_f, **R_n** 对角化后, 对角阵中元素是其相关元素的傅里叶变换, 称为**f**, **n** 的功率谱, 记为
S_n(u, v), **S_f(u, v)**

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + s[S_n(u, v)/S_f(u, v)]} \right] G(u, v)$$

◆ 方括号中的黄色项组成的滤波器被称为**维纳滤波器**，是N. Wiener在1942年提出的。

通常， $s=1$ 称为维纳滤波器， $s \neq 1$ 时称为参数维纳滤波器。

➤ 也称为最小均方误差滤波器。

◆实际中， $S_n(u, v)$ 和 $S_f(u, v)$ 很少是已知的，
因此，式

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + s[S_n(u, v)/S_f(u, v)]} \right] G(u, v)$$

常用下式近似（ $s=1$ ）

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + K} \right] G(u, v)$$

比逆滤波多的项

比逆滤波多的项

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + K} \right] G(u, v)$$

◆一般将噪声用白噪声近似，则 $S_n(u, v)$ 为常数。

K 是噪声与信号的功率密度比，

$[S_n(u, v) / S_f(u, v)]$ ，通常设定为常数。

3. 逆滤波和维纳滤波的复原比较


(1) 实例1

第一列为模糊图像+噪声
均值**0**; 方差 **8,16,32**

第二列为逆滤波复原图像

第三列为维纳滤波复原图像

结果表明，有噪声时维纳滤波效果好




(2) 实例2

加噪声
均值0，方差650
高斯噪声

噪声幅度方差
小1个数量级

噪声幅度方差
小5个数量级



运动模糊及噪声

采用下式的维纳滤波：

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + K} \right] G(u, v)$$

其中，由于可以判定是匀速直线运动产生的模糊，因此 $H(u, v)$ 取为如下表达式，并迭代选择 K


$$H(u, v) = \frac{T}{\pi (u c + v b)} \sin[\pi (u c + v b)] e^{-j\pi (u c + v b)}$$

模糊图像


逆滤波

维纳滤波

加噪声
均值0, 方差650
高斯噪声



噪声幅度方差
小1个数量级



噪声幅度方差
小5个数量级



9.3.2 Constrained least square restoration

1. 复原特性

维纳滤波，假定原始图像 f 和噪声 n 是随机变量，其图像集形成平稳随机过程，并需要已知未退化图像和噪声的功率谱，


➤ 虽然可以近似，但常数 K 不易估计。

即：维纳滤波器在图像统计平均意义下最优，但对某一具体图像而言不一定最优。



有约束最小平方复原

即：维纳滤波器在图像统计平均意义下最优，但对某一具体图像而言不一定最优。



有约束最小平方复原，只要求噪声方差和均值信息
→ 就可对给定图像复原出最优结果。

提问：如何寻找一种准则函数对每一幅具体图像确定一个最优的评判标准



2. 实现方法

寻找一种准则函数，由此导出的复原对每一幅具体图像确定一个最优的评判标准


个体最优，是不是有点像离散KL变换？

(1) 确定最大平滑测度准则

在逆滤波中，由于 $H(u, v)$ 的病态性质，导致在其零点附近数值变化起伏过大，产生多余噪声和边缘，会造成图像严重失真，




在逆滤波中，由于 $H(u, v)$ 的病态性质，导致在其零点附近数值变化起伏过大，产生多余噪声和边缘，会造成图像严重失真，



而图像的灰度变化是平滑的、少跳变

因此，可采用最大平滑测度准则，进行约束。



(2) 最大平滑算法

图像相邻像素间平滑性可通过二阶导数表征

➤ 二阶导数小，灰度跳变小，图像平滑


所以可作为图像复原时的约束条件 Qf

二阶导数可用拉普拉斯算子表示，
即 $\left(\frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2}\right) f$

对于数字图像可写成差分形式

$$\left(\frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2}\right) f = 4f(x, y) - [f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1)]$$

$$4f(x, y) - [f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1)]$$



上式可看成是图像 $f(x, y)$ 与模板 $p(x, y)$ 卷积的结果

$$p(x, y) = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

在7.1节中讨论过，上述计算过程可以用矩阵可表示为 $C \cdot f$ ，其中 C 为分块循环矩阵，由 p 的周期扩展确定。

周期扩展

$$p_e(x, y) = \begin{cases} p(x, y) & 0 \leq x \leq 2, \quad 0 \leq y \leq 2 \\ 0 & 3 \leq x \leq M-1, \quad 3 \leq y \leq N-1 \end{cases}$$

若 $f(x, y)$ 为 $A \times B$, 取 $M \geq A+3-1$, $N \geq B+3-1$

上式可用矩阵表示。每个子矩阵 C_j 是由第 j 列的 $p_e(x, y)$ 构成的 $N \times N$ 循环矩阵,

$$C = \begin{bmatrix} C_0 & C_{M-1} & \dots & C_1 \\ C_1 & C_0 & \dots & C_2 \\ \dots & \dots & \dots & \dots \\ C_{M-1} & C_{M-2} & \dots & C_0 \end{bmatrix} \quad C_j = \begin{bmatrix} p_e(j, 0) & p_e(j, N-1) & \dots & p_e(j, 1) \\ p_e(j, 1) & p_e(j, 0) & \dots & p_e(j, 2) \\ \dots & \dots & \dots & \dots \\ p_e(j, N-1) & p_e(j, N-2) & \dots & p_e(j, 0) \end{bmatrix}$$

见7.1.1节的分块循环矩阵


根据前面的分析, $f(x, y)$ 也需要周期扩展

定义准则为 $E = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} \|C \cdot f\|^2$

同时定义 $Q = C \Rightarrow Q \cdot f = C \cdot f$ **可得最优解**

问题变成了在满足条件 $\|n\|^2 = \|g - H \hat{f}\|^2$

使 $E = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} \|C \cdot \hat{f}\|^2$ 最小，即最大平滑约束



称为有约束最小平方复原

$$\hat{f} = [H^T H + s Q^T Q]^{-1} H^T g$$

$Q = C$ 与 $\mathbf{P}$ 相关

上述最优化问题在频率域的解，可由如下表达式给出：

$$\hat{F}(u, v) = \left[\frac{H(u, v)^*}{|H(u, v)|^2 + s |P(u, v)|^2} \right] G(u, v)$$

$p_e(x, y)$ 的傅氏变换

s 参数，需要被调整，以满足式

$$\|n\|^2 = \|g - H \hat{f}\|^2$$

3. 与维纳滤波比较

加噪声


噪声幅度方差
小1个数量级

噪声幅度方差
小5个数量级



模糊图像



维纳滤波



最小平方









模糊图像

逆滤波

维纳滤波

最小平方

加噪声

噪声幅
度方差
小1个
数量级噪声幅
度方差
小5个
数量级

9.1 图像退化和复原模型

Image degradation and restoration model

9.2 无约束复原 Unconstrained restoration

9.3 有约束复原 Constrained restoration

9.4 交互式复原 Interactive restoration


9.5 几何失真校正 Geometric distortion correction

9.6 深度学习图像复原

1. 交互复原的概念

在本节之前的复原方法，都是通过对图像进行自动解析后进行复原的。

在实际中，一些具体的图像复原，常需要人机结合，由人控制复原过程，已达到某些特殊效果



以一种二维正弦干扰模式为例说明

2. 正弦干扰及其消除

实际应用中，图像有时会被2D正弦干扰（相关噪声）所覆盖。


设 $n(x, y)$ 是幅度 A ，频率分量为 (u_0, v_0) 的正弦干扰模式 $n(x, y) = A \sin(u_0 x + v_0 y)$

其傅里叶变换为

$$N(u, v) = \frac{-jA}{2} \left[\delta\left(u - \frac{u_0}{2\pi}, v - \frac{v_0}{2\pi}\right) - \delta\left(u + \frac{u_0}{2\pi}, v + \frac{v_0}{2\pi}\right) \right]$$

$$N(u, v) = \frac{-jA}{2} \left[\delta\left(u - \frac{u_0}{2\pi}, v - \frac{v_0}{2\pi}\right) - \delta\left(u + \frac{u_0}{2\pi}, v + \frac{v_0}{2\pi}\right) \right]$$


上式只有虚分量，代表一对在频域上为
坐标在 $(u_0/2\pi, v_0/2\pi)$ ， $(-u_0/2\pi, -v_0/2\pi)$
强度为 $-A/2$ ， $A/2$ 的脉冲



因为退化只由噪声造成，所以无退化系统 H

$$G(u, v) = F(u, v) + N(u, v)$$

当显示
 $G(u, v)$ 时
表现为2个
亮点




- 由视觉观察脉冲在频域上的坐标位置,
- 在该位置设计带阻滤波器,
- 消除脉冲亮点, 以去掉正弦干扰模式。

多个正弦分量时较复杂, 详见p. 209

3. 交互式复原正弦干扰实例

例1

正弦干扰



频谱

2个带阻滤波，半径小



半径大时


有振铃效应

(c)处理后的
复原结果




例2


被正弦噪声干扰图像



被干扰图像频谱



被正弦噪声干扰图像




原图像频谱



a	b
c	d

FIGURE 5.16

(a) Image corrupted by sinusoidal noise.
 (b) Spectrum of (a).
 (c) Butterworth bandreject filter (white represents 1).
 (d) Result of filtering. (Original image courtesy of NASA.)



滤波效果图

巴氏带阻滤波，白色代表1

9.1 图像退化和复原模型

Image degradation and restoration model

9.2 无约束复原 Unconstrained restoration

9.3 有约束复原 Constrained restoration

9.4 交互式复原 Interactive restoration



9.5 几何失真校正 Geometric distortion correction

9.6 深度学习图像复原

1. 概要

在实际图像采集处理过程中，像素间空间位置关系会发生变化 → 几何失真或畸变


广义上归结为一种图像的退化 → 需要校正



2. 处理步骤

(1) 空间变换：对图像平面上的像素重新排列，以恢复原有的空间关系。

(2) 灰度插值：对空间变换后的像素赋予相应的灰度值，以恢复原位置的灰度值。




1. 变换式

设原图像 $f(x, y)$ ，几何失真图像 $g(x', y')$
失真图像坐标可表示为

$$g(x', y') = f(x, y)$$

$$x' = s(x, y)$$

$$y' = t(x, y)$$




最简单的情况， s, t 为产生失真的2个线性空间变换（一次）

$$s(x, y) = k_1x + k_2y + k_3$$

$$t(x, y) = k_4x + k_5y + k_6$$

如果知道 s, t 的解析表达, 即可通过反变换来恢复图像。但通常, 实际中无法事先知道 s, t 的解析表达式, 所以

- 需要在恢复过程中, 找出输入图(失真图)和输出图(校正图)中的一些对应点,
- 利用对应点建立其他像素的空间对应关系



2、四边形区域的几何失真可用双线性方程建模

$$s(x, y) = k_1x + k_2y + k_3xy + k_4$$

$$t(x, y) = k_5x + k_6y + k_7xy + k_8$$

为一般非线性二次
失真的一种特例




$$x' = s(x, y)$$

$$y' = t(x, y)$$

$$x' = k_1x + k_2y + k_3xy + k_4$$


$$y' = k_5x + k_6y + k_7xy + k_8$$



四对点8个方程，可解出系数 $k_i, i=1, \dots, 8$

由求得的系数 K_i ，可对四边形区域所有点的位置进行空间变换，从而恢复原图像形状

►即对每个 (x, y) ，都可以找到 (x', y')



通常对图像的几何失真校正，都是将图像分成四边形集合，然后对每个区域校正完成


1. 插值目的

解方程时，会产生非整系数 K_i ，


因此对区域内点，将产生非整坐标 (x', y')

$$x' = k_1x + k_2y + k_3xy + k_4$$

$$y' = k_5x + k_6y + k_7xy + k_9$$



失真图像 $g(x', y')$ 是数字图像，它仅在整数坐标处有定义，在非整数处没有对应的值，




若原图像对应非整数坐标处的 $g(x', y')$ 值，则需用周围整数坐标处的值计算 → 此过程称为灰度插值

2. 插值算法：主要有2种

(1) 最近邻插值

方法简单， $\Rightarrow$ 取与 (x', y') 最近值，

校正后图像A点对应到原失真图像的 A' 点



取B点的灰度值为A点的灰度值


(2) 双线性插值

为一种精确的插值方法

$g(A), g(B), g(C), g(D)$ 为整数坐标点像素灰度



$$g(E) = d1 \cdot [g(B) - g(A)] + g(A)$$

$$g(F) = d1 \cdot [g(D) - g(C)] + g(C)$$



$$g(x', y') = d2 \cdot [g(F) - g(E)] + g(E)$$

其中, $0 \leq d1 \leq 1, 0 \leq d2 \leq 1$



3. 几何失真变换实例


原图像

失真模型

失真图像

几何失真
变换后的
校正图像

图像有较多纹理时
几何失真不易察觉



9.1 图像退化和复原模型

Image degradation and restoration model

9.2 无约束复原 Unconstrained restoration

9.3 有约束复原 Constrained restoration

9.4 交互式复原 Interactive restoration

9.5 几何失真校正 Geometric distortion correction

9.6 深度学习图像复原

9.6 深度学习图像复原

深度学习图像去运动模糊

- 给定一张模糊图片，设计一个去模糊网络，对模糊图片进行去模糊处理。



- 评价指标
 - 去模糊后图像的峰值信噪比PSNR。PSNR越大，效果越好。
 - 去模糊后图像和参考图像的相似度指标SSIM。SSIM越大，效果越好。
- 选择深度学习网络模型，学习模糊图像到清晰图像的映射。
- 收集训练数据，进行样本标注和预处理
- 训练模型，进行测试，完成评价

一种基于生成对抗网络的图像去模糊模型——DeblurGAN，该模型2018年发表在CVPR上，论文名字是——DeblurGAN: Blind Motion Deblurring Using Conditional Adversarial Networks

一幅模糊的图像 (I_B) 可以建模为:

$$I_B = k(M) * I_S + N$$

其中, I_S 是一张清晰的图像。 $k(M)$ 是一个未知的模糊核, 由运动场 M 决定。 $*$ 代表卷积操作。 N 是加性噪声。



I_B

=



I_S

*



$k(M)$

图像去模糊分两种：

- 非盲去模糊（non-blind deblurring）：模糊核 $k(M)$ 已知
- 盲去模糊（blind deblurring）：模糊核 $k(M)$ 未知


DeblurGAN是利用生成对抗网络进行盲去模糊（blind deblurring）的方法

DeblurGAN包含一个生成器 G 和一个鉴别器 D 。

- 生成器 G 的输入是一张模糊图像，输出是去模糊后的图像
- 鉴别器 D 的输入是生成器输出的图像和真实的清晰图像，输出是对输入图像真实性的得分。
- 训练时，生成器 G 和鉴别器 D 是一个博弈的过程。
 - 生成器 G 的优化目标是：生成的去模糊图像能“骗”过鉴别器 D ，让 D 认为是真实的清晰图片。
 - 鉴别器 D 的优化目标是：能够正确地鉴别出输入的图像是去模糊后的图像还是真实的清晰图像。

优化目标
$$\min_G \max_D \sum_{n=1}^N -D(G(I_B))$$

DeblurGAN的整体结构



DeblurGAN的损失函数包含两部分。

$$L = L_{GAN} + \lambda L_X$$

一部分是生成对抗网络的损失 L_{GAN}


$$L_{GAN} = \sum_{n=1}^N -D(G(I_B))$$

另一部分是关于感知损失 L_X ，计算的是去模糊后图像的feature map和ground truth的feature map之间的欧式距离。

$$L_X = \frac{1}{W * H} \sum_{x=1}^W \sum_{y=1}^H (\phi(I_S)_{x,y} - \phi(G(I_B))_{x,y})^2$$

其中， ϕ 是在ImageNet上预训练的VGG19网络

DeblurGAN的生成器结构





生成器：2个卷积模块 + 9个残差模块 + 2个转置卷积模块


对一张模糊图像 I_B ，生成器输出的是对 I_B 的残差修正图像 I_R ，去模糊后的图像 I_S 为：

$$I_S = I_B + I_R$$

学习残差修正图像 I_R 使训练收敛更快，且方法的泛化性能更好。



Blurred images




DeblurGAN




Ground truth sharp













Blurred images



Nah et al



DeblurGAN



Blurred images


Nah et al

DeblurGAN


将模糊图像去模糊后，进行目标检测，对比不同方法的结果。

采用YOLO上的目标检测基准


Then sharp images are
feed into the YOLO
network



Blurred image



Nah et al



DeblurGAN



Sharp image

1. 深绿色书 第四版教材, p. 123,

二道作业题: 5-7, 5-9