

数字系统设计第三次阅读——Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference

姓名：陈天乐

学号：

班级：无25

随着智能移动设备的普及，深度学习模型的计算成本越来越高，如何高效且准确的基于硬件推理是一个迫在眉睫的问题。本文提出了一种量化方案，允许使用纯整数算术进行推理，比浮点数推理更加高效，延迟更低，而且对于准确率的降低完全在可接受范围之内。先前的工作只是将CNN的权重、激活值从float32转化成更低位宽数据，但是准确率降低较多，并且只是对普通的架构进行量化实验，没有对已经做过tradeoff的模型架构做实验（例如MobileNets）。文中主要从三个方面给出了一套完整的量化训练过程：量化方案、量化推理框架和量化训练框架。

量化方案

本文的量化方案是：将权重和激活值量化成int8，而少数参数（如bias）量化为int32。

设真实值为 $r(\text{float})$ ，量化值为 $q(\text{int8})$ ，零点量化值为 $Z(\text{int8})$ ，放缩系数为 $S(\text{float})$ 。则量化映射关系为：

$$r = S(q - Z)$$

量化推理框架

考虑两个N维矩阵的乘法：

$$r_{\alpha}^{(i,j)} = S_{\alpha}(q_{\alpha}^{(i,j)} - Z_{\alpha}).$$

将量化公式代入：

$$S_3(q_3^{(i,k)} - Z_3) = \sum_{j=1}^N S_1(q_1^{(i,j)} - Z_1)S_2(q_2^{(j,k)} - Z_2)$$

$$q_3^{(i,k)} = Z_3 + M \sum_{j=1}^N (q_1^{(i,j)} - Z_1)(q_2^{(j,k)} - Z_2)$$

再将这个式子展开：

$$q_3^{(i,k)} = Z_3 + M(NZ_1Z_2 - Z_1a_2^{(k)} - Z_2\bar{a}_1^{(i)} + \sum_{j=1}^N q_1^{(i,j)} + q_2^{(j,k)})$$

这上面的式子除了M全是整数，大大节省了运算成本。

为了和int32位的bias相加，计算权重 q_1 和激活值 q_2 时用一个int32位的累加器求和得到最终值，最后做缩放，向下转换为uint8，应用激活函数得到最后的8位输出激活值([0,255])。

量化训练框架

在推理时，一种很简单的方法是直接将训练好的模型参数做量化，但是这种方法往往会让精确度大幅降低。因此本文在训练时就将权重做量化，并且将BN过程折叠到卷积层中，将量化影响带到训练过程。

$$w_{fold} := \frac{\gamma w}{\sqrt{EMA(\sigma_B^2) + \epsilon}}$$

对于每一层而言，量化参数和量化函数如下：


$$clamp(r; a, b) := \min(\max(x, a), b)$$

$$s(a, b, n) := \frac{b - a}{n - 1}$$

$$q(r; a, b, n) := \left\lfloor \frac{clamp(r; a, b) - a}{s(a, b, n)} \right\rfloor s(a, b, n) + a$$

其中，[a;b]是量化范围，n是量化阶数（对于m-bit量化， $n = 2^m$ ）。

对于权重量化， $a := \min(w)$, $b := \max(w)$ 。对于激活值量化，采用EMA方法来汇总激活值[a;b]的范围，并且考虑到EMA在更新激活范围时会出现明显延迟，在一开始训练时先禁用了激活值量化，这样可以让网络进入到一个更稳定的状态。



(b) Training with simulated quantization

Performance

在ResNets, Inception v3, MobileNets等网络上进行测试，得到的效果都非常的好，在正确率下降不大的同时大大降低了推理速度，实现了in-time的推理，便于各种移动设备的应用。