



清华大学电子工程系  
Department of Electronic Engineering, Tsinghua University

严谨 · 勤奋 · 求实 · 创新

# 数字系统设计

## 16-AI驱动的电子设计自动化 (简介)

刘勇攀 & 贾弘洋

2025/6/3

## ➤ 一、AI赋能EDA的背景动因与发展概况

## ➤ 二、面向EDA核心任务的AI方法

# EDA Overview

设计空间巨大,  
约束复杂

迭代周期漫长



## IC设计流程


Source:

<https://www.hisilicon.com/cn/about-us/press/news/chip-design-and-manufacturing>

<https://www.ansys.com/zh-cn/simulation-topics/what-is-asic-design>

# EDA Challenges


- **设计空间庞大、参数复杂、人力调优成本高**
  - 现代芯片设计涉及多种参数，如逻辑门驱动强度、时钟树结构、布局密度、功耗约束等。设计者不仅要在功能正确性与性能指标之间权衡，还需兼顾制造工艺的可实现性，微小的参数变动就可能导致系统级别的连锁反应




# EDA Challenges



- 验证/优化周期长，设计风险高
- 手动设计测试方法费时高，需要重复迭代，难以覆盖特殊测例，无法确保芯片鲁棒性—成熟商业产品的迭代周期以年计



# AI for EDA: Overview



## 架构与前端设计:

设计空间探索 (如功耗、性能、面积的trade off) ,  
代码生成 (RTL、Simulator)  
逻辑综合与优化

## 物理设计与制造:

时钟树综合、电源管理、布局与布线优化

## 验证:

自动化Testbench生成, 提高覆盖率的智能测例生成


...

# AI for EDA: Overview


## 设计参数探索

### Synopsys DSO.ai – Design Space Optimization Loop

Uses reinforcement learning to navigate the design-technology solution space



### Synopsys – DSO.ai



### NVIDIA – NVIDIA Modulus

**原理：**采用强化学习算法，在庞大的设计空间中自动搜索最优解，以提升芯片的功耗、性能和面积（PPA）指标。

**效果：**在设计高性能GPU的测例中，减少12%功耗，加快5倍设计速度。

**原理：**物理学AI框架，可训练并部署基于物理知识与仿真数据相结合的模型，使用户能够根据其需求创建定制化的AI引擎。


**效果：**将芯片的热仿真速度提高100倍以上。

Source: <https://www.synopsys.com/zh-cn/ai/ai-powered-eda/dso-ai.html>


<https://www.ansys.com/zh-cn/news-center/press-releases/11-19-24-ansys-integrates-nvidia-modulus-with-seascope>

# AI for EDA: Overview



## 布局布线



Wirelength reduction vs. human experts



## Google – AlphaChip



## NVIDIA – AutoDMP

**原理：**将芯片布局问题视为强化学习中的棋盘游戏，利用深度强化学习算法自动生成高效的芯片布局方案。


**效果：**在TPU系列产品的设计中得到实际运用，将布局布线的平均线长缩短3.2%-6.2%

**原理：**利用基于强化学习的宏观布局和宏/标准单元格的并行放置，优化芯片设计的宏布局。

**效果：**在大多数设计中，AutoDMP 导线长度、功率、最差负松弛（WNS）和总负松弛（TNS）的PPA指标结果等于或优于商业宏布局结果（正值表示AutoDMP效果更好）。

# AI for EDA: Overview


## 智能验证



## Synopsys – VSO.ai

**原理：**AI驱动验证工具，通过机器学习自动优化测试覆盖率、消除冗余测试并加速芯片验证收敛，显著提升验证效率。

**效果：**进行 AI 驱动验证时，在减少功能覆盖漏洞方面提升高达 10 倍，IP 验证生产率提高达 30%。



# Challenges of AI for EDA

然而，想要将AI成功运用于EDA领域，仍存在以下挑战：

- **数据壁垒与高质量数据获取困难：** 受限于商业竞争，各大公司的芯片设计中间数据不开源，难以打破公司壁垒将这些数据用于训练AI。
- **工艺间可扩展性差：** EDA流程需适应不同工艺节点，但现有方法泛化能力有限。
- **AI模型的可解性差：** AI模型对EDA流程的优化有部分的不可解释性，不利于工程师理解AI决策逻辑以debug。
- **缺乏行业标准：** 传统EDA工具大多闭源，AI模型与这些EDA工具交互存在困难。


...

# / Outlines

➤ 一、AI赋能EDA的背景动因与发展概况

➤ 二、面向EDA核心任务的AI方法

## 二、AI助力解决EDA难题




# / Outlines

- 一、AI赋能EDA的背景动因与发展概况
- 二、面向EDA核心任务的AI方法
  - 数据驱动的预测：设计质量快速评估（回归问题）
  - 智能搜索与优化：引导设计在巨大解空间中搜索与优化（搜索问题）
  - 从学习到创造：设计结构的快速生成和创新（生成问题）

## / 二、AI for EDA

### 1. 回归问题举例 —— 场景说明


- EDA的自动布局布线问题



## 二、AI for EDA

### 1. 回归问题举例 —— 场景说明

#### • EDA的自动布局布线问题




#### • 二维布线:

- 1、确定信号线的整体路径**平面走向** (水平或垂直)
- 2、划分布线区域

#### • 关注:


**资源分配、拥塞预防、路径可行性**



## 二、AI for EDA

### 1. 回归问题举例 —— 场景说明

#### • EDA的自动布局布线问题




#### • 二维布线:

- 1、确定信号线的整体路径**平面走向** (水平或垂直)
- 2、划分布线区域

#### • 关注:

资源分配、拥塞预防、路径可行性




#### • 三维布线:

- 1、在全局布局的指导下, 确定每条路径的**几何路径** (如金属层、通孔位置、线宽等)

#### • 关注:


具体路径几何、工艺规则、信号完整性



## / 二、AI for EDA

### 1. 回归问题举例 —— 回归辅助全局布局快速评估

#### 传统EDA流程



传统布线搜索算法：

**穷举式** —— 遍历所有可能路径

**启发式** —— 基于行之有效策略，提前舍弃次优选择，

(以近似最优为代价)大幅提升搜索效率




**Still Time-Consuming!**

## / 二、AI for EDA

### 1. 回归问题举例 —— 回归辅助全局布局快速评估

#### 传统EDA流程



Still Time-Consuming! —>

#### 传统EDA：

- 严重拥塞需要**手工优化**
- **漫长全局布线**过程成为开发效率的严重瓶颈

—> **人机分离**效率低下（人等机器+机器工作时间不定时）

— 随着芯片规模的上升，单次全局布线可能需数十分钟（占据迭代主要时间），完整迭代设计可能需要**数十小时甚至数天时间** —

## / 二、AI for EDA

### 1. 回归问题 —— 回归辅助全局布局快速评估

#### 基于机器学习的布局优化



- 而基于预测的设计可以把完整迭代过程缩减到数小时甚至是数十分钟。

## / 二、AI for EDA

### 1. 回归问题 —— 核心问题构建

自变量：**特征值  $X$** （ $n$ 维特征张量，如布局相关特征）


因变量：**标签值  $Y$** （指标，如拥塞热力图）

目标：

学习映射  $X \xrightarrow{f(X)} Y$

核心问题：

**如何表征特征值与标签值**



实际维数巨大  
难以解析表示

## / 二、AI for EDA

### 1. 回归问题 —— 拥挤预测实例：特征表征

- 输入布局信息特征：

- ① 空间特征

- (1) 几何位置关系

- (2) 拓扑连接关系

- ② 模块特性 ： 尺寸、Pin数量、内部时序特性等

- 输出拥塞图 → “像素” 热力图

## 二、AI for EDA

### 1. 回归问题 —— 拥挤预测实例：特征表征

#### • 输入布局信息特征：

##### ① 空间特征

(1) 几何位置关系 → Lattice graph


(2) 拓扑连接关系 → Hypergraph

##### ② 模块特性 → 特征向量


#### • 输出拥塞图 → “像素”图(矩阵)

##### ② 模块特征向量集 (构成总布局特征张量)


##### ① 空间特征



##### (2) 拓扑Hypergraph



##### (1) 几何格点图



输出“像素”图

(a) Model Architecture


## / 二、AI for EDA

### 1. 回归问题 —— 再看AI在EDA中的预测能力

传统EDA设计流程的困难：


- 1、 IC前端设计阶段 **设计-反馈延迟大**
- 2、 IC设计 **步骤间耦合关系复杂**
- 3、 跨阶段/部门/工具的 **优化迭代效率低**

(人-机分离+人-人分离)



## 二、AI助力解决EDA难题

### 1. 回归问题 —— 再看AI在EDA中的预测能力



### AI for EDA Estimation


- 提前**评估**设计效果，前端设计快速优化迭代
- 数据驱动模型**学习**到后续步骤“**知识**”，减少跨阶段迭代成本

# / Outlines

- **一、AI赋能EDA的背景动因与发展概况**
- **二、面向EDA核心任务的AI方法**
  - **数据驱动的预测：设计质量快速评估（回归问题）**
  - **智能搜索与优化：引导设计在巨大解空间中搜索与优化（搜索问题）**
  - **从学习到创造：设计结构的快速生成和创新（生成问题）**


## / 二、AI for EDA

### 2. 搜索问题举例



## 二、AI for EDA

### 2. 搜索问题举例



#### • 搜索问题（一）：

过程：搜索更优的**布局选择**（相应模块/块的位置坐标、形状、弹性边界、信号通路优先级等等）

目标：更少的拥塞预估结果


#### • 搜索问题（二/三）：

过程：搜索更优的**布线选择**（布线顺序、二维/三维走线选择等等）

目标：更少的拥塞/满足时序约束/.....

## / 二、AI for EDA

### 2. 搜索问题举例



#### • 搜索问题（一）：

过程：搜索更优的**布局选择**（相应模块/块的位置坐标、形状、弹性边界、信号通路优先级等等）

目标：更少的拥塞预估结果

#### • 搜索问题（二/三）：


过程：搜索更优的**布线选择**（布线顺序、二维/三维走线选择等等）

目标：更少的拥塞/满足时序约束/.....

## 二、AI for EDA


### 2. 搜索问题举例

传统搜索




遍历式搜索

- 穷举所有可能，保证最优解；
- 巨额计算开销；
- 只适用于资源充足或小搜索空间场景



启发式搜索

- 依赖领域专家手动设计的规则
- 对搜索路径进行有效提前剪支
- 牺牲部分最优，提高效率




机器学习

- 数据驱动自发学习复杂数据模式，无需手动设计
- 训练过程漫长，但推理快速
- 牺牲部分最优，显著提升效率

## 二、AI for EDA

### 2. 搜索问题举例


传统搜索



遍历式搜索

- 穷举所有可能，保证最优解；
- 巨额计算开销；
- 只适用于资源充足或小搜索空间场景


启发式搜索



- 依赖领域专家手动设计的规则
- 对搜索路径进行有效的提前剪支
- 牺牲部分最优，提高效率

实际中：

- **超平面** —— 设计空间维度成百上千；
- 传统搜索算法**效率低下**；
- **无法直接构建解析解**；
- **非凸函数**



机器学习

- 数据驱动**自学习复杂数据模式**，无需手动设计
- 训练过程漫长，但推理快速
- 牺牲部分最优，**显著提升效率**



## 二、AI助力解决EDA难题

### 2. 搜索问题 —— 过程构建

定义设计空间 + 评估手段 & 搜索策略 → 最优解

如：某一布局


如：在相邻的几类布局选择中更优



## 二、AI助力解决EDA难题

### 2. 搜索问题 —— 过程构建

定义设计空间 + 评估手段 & 搜索策略 → 最优解



- EDA 搜索问题 “解” 举例:

- 电路综合的结构选择;
- 综合工具约束参数选择
- 版图中各模块布局的顺序、位置、朝向选择
- 版图中模块间布线的顺序、路径选择

.....

## / 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

- 传统EDA搜索困难

1. 高维输入 —— IC设计决策参数量巨大，搜索空间巨大
2. 局部最优陷阱 —— 工程师优化设计依赖经验
3. 迭代周期长，跨阶段协同优化困难

- 基于机器学习实现EDA搜索问题关键

- 预测算法（指标评估） —> 回归问题 （二.1）

- 搜索算法

(1) 对传统EDA搜索工具进行参数优化 / 选择

—— 帮助传统搜索工具用得更好

(2) 直接对搜索空间进行搜索（基于神经网络/强化学习）

—— 直接接触搜索空间寻优

## / 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

- 传统EDA搜索困难

1. 高维输入 —— IC设计决策参数量巨大，搜索空间巨大
2. 局部最优陷阱 —— 工程师优化设计依赖经验
3. 迭代周期长，跨阶段协同优化困难

- 基于机器学习实现EDA搜索问题关键

- 预测算法（指标评估） —> 回归问题 （二.1）

- 搜索算法

(1) 对传统EDA搜索工具进行参数优化 / 选择

(2) 直接对搜索空间进行搜索（基于神经网络/机器学习）

*“Tools and flows have steadily increased in complexity, with modern place and route tools offering more than 10,000 parameter settings.”*




本身构成了巨大的搜索空间

## / 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

#### (1) 对传统EDA搜索工具进行参数优化 / 选择： 举例一




采用随机森林模型，帮助HLS DSE针对不同(输入)待优化选~~择~~择更优配置（如knob-setting）；

## 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

#### (1) 对传统EDA搜索工具进行参数优化 / 选择： 举例二



基于神经网络分类器，针对待优化逻辑电路(输入)，从MIG/AIG两类逻辑优化器中选择较优者进行优化

## / 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

(1) 对传统EDA搜索工具进行优化 / 选择： 举例一


#### 对已有商业搜索工具进行参数优化 / 选择

优势：

- 模型简单，目标明确
- 只需要实现简单分类或回归任务
- 结构清晰，可解释性强

劣势：

- 未能实现独立优化，效果受限于其传统优化器（规则化\Pattern有限\...）



基于神经网络分类器，针对待优化逻辑电路(输入)，从MIG/AIG两类逻辑优化器中选择较优者进行优化

## / 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

- 传统EDA搜索困难

1. 高维输入 —— IC设计决策参数量巨大，搜索空间巨大
2. 局部最优陷阱 —— 工程师优化设计依赖经验
3. 迭代周期长，跨阶段协同优化困难

- 基于机器学习实现EDA搜索问题关键

- 指标评估（预测） ——> 回归问题


- 搜索算法

- (1) 对传统EDA搜索工具进行参数优化 / 选择
- (2) 直接对搜索空间进行搜索（基于神经网络/强化学习）

## / 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

#### (2) 基于强化学习的 Detailed routing —— 背景说明




- 确定各Net大致走向（网格问题）
- 允许轻微拥塞出现
- 仍未确定具体物理实现

## 二、AI助力解决EDA难题


### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

#### (2) 基于强化学习的 Detailed routing —— 背景说明



给定Net, 实现物理布线

Detailed routing



- 确定各Net大致走向 (网格问题)
- 允许轻微拥塞出现
- 仍未确定具体物理实现


- 实现三维物理连线 (三维点阵连线问题)
- 不允许出现线与线间冲突 (短路)
- 考虑物理设计规则

## 二、AI助力解决EDA难题


### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

#### (2) 基于强化学习的 Detailed routing —— 背景说明

- Net布线顺序&各阵点处路径的选择构成**巨大搜索空间**
- 传统启发式搜索：
  - 效率低
  - 依赖顺序决策
  - 规则僵化，难以适应复杂设计规则



Detailed routing



- 确定各Net大致走向 (网格问题)
- 允许轻微拥塞出现
- 仍未确定具体物理实现


- 实现三维物理连线 (三维点阵连线问题)
- 不允许出现线与线间冲突 (短路)
- 考虑物理设计规则

## 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

#### (2) 基于强化学习的 Detailed routing —— 强化学习介绍

训练:



应用:




## 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题

#### (2) 基于强化学习的 Detailed routing —— 强化学习介绍

训练：



应用：



#### • 在EDA中应用的优势：

- **交互驱动**，自主学习状态到动作的映射，无需人工设计规则。
- **无需大量的高质量标注数据库**；
- 可持续与环境**交互**，**适应设计变化**（在线学习）；
- 支持**异步协作**，多Agent独立决策并通过共享信息，适合复杂决策场景。

—— 相比传统算法

—— 相比神经网络

## 二、AI助力解决EDA难题

### 2. 搜索问题 —— 基于机器学习的EDA搜索问题


#### (2) 基于强化学习的 Detailed routing —— 布线路径选择

##### 1、一个Agent负责单个Net

- 异步触发，解决顺序依赖问题

##### 2、局部观察机制

- 存储**全局**引导信息，仅处理**局部**区域，降低搜索空间维度
- 与**邻近Agent**共享局部信息，以减少冲突，并扩大感受野



Agent A

Agent B


# / Outlines

- **一、AI赋能EDA的背景动因与发展概况**
- **二、面向EDA核心任务的AI方法**
  - **数据驱动的预测：设计质量快速评估（回归问题）**
  - **智能搜索与优化：引导设计在巨大解空间中搜索与优化（搜索问题）**
  - **从学习到创造：设计结构的快速生成和创新（生成问题）**

## 二、AI助力解决EDA难题

### 3. 生成问题 —— 布局过程举例


强化学习-布局搜索过程



劣势:

- **迭代式推理和学习**，难以从静态（网表，布局）的端到端数据中进行学习，且每个新电路使用前**需要在线迁移学习或微调**，使用时间成本高；
- 基于马尔可夫过程（MDP）顺序决策，易陷入局部最优，对**early error敏感**（前面一步放错了，后面很难救回来）

生成模型-布局生成过程




优势:

- 采用“**逆向样本生成**”方法形成高质量数据集，训练高泛化性的生成模型（基于**设计空间概率模型**），可**直接地（zero-shot）**部署在新电路上；
- 基于设计空间概率模型，**全局地、一并地**生成全局一致的布局结构，借助**Guided Sampling**技术**平衡多目标**。

## / 二、AI助力解决EDA难题

### 3. 生成问题 —— 生成式模型描述





生成式模型**显示或隐式地**学习观测域X和目标域Y的**联合概率分布 $P(x, y)$**

— X和Y不需要是相同的数据形式，如：文生图

AI 生成式模型：生成对抗网络 (GAN) / 扩散模型 (Diffusion Models) / .....


## 二、AI助力解决EDA难题

### 3. 生成问题 —— 以Diffusion为例




## 二、AI助力解决EDA难题

### 3. 生成问题 —— 以Diffusion为例




## 二、AI助力解决EDA难题

### 3. 生成问题 —— 以Diffusion为例



#### ① 特殊数据结构 —— 电路网表



- 采用 GNN 捕捉网表信息
- Graph Attention 进行跨越更远的结点关系处理，克服纯GNN的过度平滑问题。

#### ② 设计需求约束 —— Guided Sampling

- 去噪过程加入引导项(Bansal et al., [2023](#))

$$\text{噪声预测: } \hat{\epsilon}_{\theta}(z_t, t) = \epsilon_{\theta}(z_t, t) + \underbrace{s(t)}_{\text{传统Diffusion噪声预测}} \cdot \underbrace{\nabla_{z_t} \ell(c, f(\hat{z}_0))}_{\text{*表征电路的合法性和性能的目标函数}}$$

传统Diffusion噪声预测

## 二、AI助力解决EDA难题

### 3. 面向EDA的AI能力建模总结

#### 传统EDA工具链

##### — 分阶段设计优化

- 依赖人工规则与启发式算法，效率较低
- 阶段间信息丢失，协同困难
- 迭代效率低，易出现人机分离问题

#### 神经网络辅助EDA预测

##### — 特征增强，常作为插件使用

- 数据驱动进行模式提取，实现**快速的特征增强**（如拥塞预测）
- 优化单一环节，加速局部阶段优化迭代
- 较难实现端到端优化，作为插件使用（如辅助传统工具或RL）

#### 强化学习驱动EDA搜索

##### — 端到端**自主决策**（面向对象）

- 无需大量训练数据集，自主学习和适应（适合EDA数据困境）
- 面向对象开发范式，支持**异步协作**，适合复杂决策场景
- 可完成**端到端优化**
- 在线学习成本较高，决策依赖顺序，存在**局部最优陷阱**

#### 生成式AI重构EDA设计范式

##### — **端到端生成**

- 基于设计空间概率模型，**直接生成新样本**，无需迁移学习
- **全局优化能力**，可实现多目标协同优化
- 对**训练样本需求高**，质量敏感

## / 总结

- AI在EDA中可以参与解决的三个问题
  - 回归问题，优化问题，生成问题
- Traditional ML: 人工设计特征提取、拟合模型，或设计优化、搜索策略。
  - 优势：可以快速进行预测，敏捷迭代设计。
- CNN: 利用卷积神经网络处理规则输入，适用于回归和生成问题。
  - 优势：可以预测更复杂的性能（IR Drop等）
- GNN: 利用图神经网络建模非规则输入，广泛应用于模拟电路设计。
- RL: 通过价值函数和策略函数的设计，管理EDA的优化策略，使能获得更好的PPA性能
- LLM: 设计agent，生成RTL代码、后端脚本、测试样例等等，自动全流程设计。